

La dirección dominante de W_O no es identificable: órbita de gauge, radio certificado nulo y consecuencias para la poda

Manuel Muñoz Plá

Investigador independiente — Sevilla, España

ORCID: 0009-0000-5714-912X | mmunozpl@uoc.edu

Agosto de 2026

v7.0-dev

Resumen

La factorización valor-salida de una cabeza de atención no es única: para toda $\mathbf{R} \in GL(d_h)$, la sustitución $(\mathbf{W}_v, \mathbf{b}_v, \mathbf{W}_O) \rightarrow (\mathbf{W}_v \mathbf{R}, \mathbf{b}_v \mathbf{R}, \mathbf{R}^{-1} \mathbf{W}_O)$ deja la función intacta, y hace de la dirección dominante $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ un proxy estático tentador para poda, interpretación o routing. Probamos que esa lectura no es identificable: su órbita bajo el gauge es la esfera unitaria completa del espacio fila, y ningún umbral admisible de similitud sobre ella admite radio certificado funcional positivo. Con espectro no degenerado, solo la clase conforme ortogonal la deja invariante para toda $\mathbf{W}_O$, y toda lectura invariante de $\mathbf{W}_O$ sola factoriza por su espacio fila. La consecuencia se mide: el par que la poda por pesos declara más redundante cambia bajo reparametrización genérica en más del 90 % de los casos en un ViT y —por la misma forma cerrada, sin entrenar— en un transformer de lenguaje. En el gauge que el entrenamiento deja, la factorización se acerca al balance sin que las decisiones coincidan. Una sonda angular que separa las direcciones hasta el umbral del simplex no produce coste funcional detectable; la imposición dura sí. La firma de respuesta $\mathbf{v}_1(\mathbf{C}_h^P)$, condicionada a la sonda y gauge-invariante, mide diversidad funcional por cabeza. Código, datos y demo con DOI.

Palabras clave: no-identificabilidad de gauge, circuito OV, poda de cabezas, radio certificado, atención multi-cabeza.

1. Introducción

Una cabeza de atención (Vaswani et al., 2017) escribe en el residuo a través del producto $\mathbf{W}_v^{(h)} \mathbf{W}_O^{(h)}$, pero se implementa como dos matrices. La discrepancia entre el objeto que actúa —el *circuito OV* (*OV circuit*)— y los factores que se almacenan abre una libertad de reparametrización: para toda $\mathbf{R} \in GL(d_h)$, el par $(\mathbf{W}_v \mathbf{R}, \mathbf{R}^{-1} \mathbf{W}_O)$ implementa la misma función. Esa libertad es conocida cualitativamente desde el análisis fundacional de los circuitos de atención (Elhage et al., 2021), y el grupo que la genera está hoy caracterizado: van Nierop (2024) y Hashimoto et al. (2024) lo formalizan, Wang and Wang (2026) prueban su maximalidad — $((GL(d_k))^h \times (GL(d_v))^h) \rtimes S_h$ sobre el estrato genérico (*generic stratum*) de rango completo— y Tran et al. (2026) lo extienden a las codificaciones posicionales. Sin escribir quedaba la órbita que ese grupo induce sobre una *lectura* concreta de los pesos. La factorización hace de $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ un proxy estático tentador —el más barato imaginable, sin forwards ni gradientes, disponible en el checkpoint— para comparar cabezas: decidir cuáles son redundantes y podarlas, interpretarlas por su dirección dominante o enrutar información entre ellas. La pregunta es si esa lectura representa una propiedad de la función o una elección de parametrización.

Este trabajo cierra esa vía con una cota exacta. La proposición 1 prueba que la órbita de $\mathbf{v}_1(\mathbf{W}_O)$ bajo el gauge valor-salida es la esfera unitaria completa de su espacio fila: para cualquier

dirección deseada existe una reparametrización que la produce sin tocar la función. La consecuencia geométrica es que el ángulo entre las direcciones dominantes de dos cabezas recorre, con la función congelada, todo el intervalo que permiten sus espacios fila. La consecuencia práctica es que ningún umbral de similitud sobre esa dirección, dentro del rango que los espacios fila permiten, admite radio certificado positivo. La demostración cabe en un párrafo y el enunciado en una línea: *leer $\mathbf{v}_1(\mathbf{W}_O)$ es leer una elección de gauge, no una propiedad de la función.*

El resultado tiene grano fino en dos direcciones, enunciadas desde el principio. Primera, la frontera: la subclase conforme ortogonal $\{c\mathbf{Q}\}$ —de medida nula en $GL(d_h)$ — deja $\mathbf{v}_1$ invariante (con espectro no degenerado; con la cabeza del espectro degenerada lo invariante es el subespacio dominante), de modo que la libertad de rotación de la base del residuo y las rotaciones ortogonales que la compresión de modelos explota caen del lado inocuo. La imposibilidad exige el gauge completo, y la separación entre ambas clases es parte del enunciado, no un matiz posterior. Segunda, el objeto que sobrevive: el espacio fila es invariante de gauge —se mueve la dirección dentro del subespacio, no el subespacio—, y el circuito OV permanece fijo por construcción. El resultado negativo apunta a toda lectura de $\mathbf{W}_O$ que no factorice por su espacio fila (corolario 1), no a toda lectura estática.

Una imposibilidad sobre el objeto equivocado sería inofensiva si las decisiones construidas sobre él fueran estables en la práctica. Se midió: bajo reparametrización genérica del sector, la pareja de cabezas que el criterio por pesos declara más redundante cambia en más del 90 % de los casos, en un ViT-B/16 afinado sobre ImageNet-100 y —aplicando la misma forma cerrada, sin entrenar nada— en un transformer de lenguaje preentrenado de 24 capas. La imposibilidad no es una patología de gauges adversarios: el barrido de fuerzas muestra la deriva creciendo con la distancia a la familia escalar mientras el error de salida permanece en el suelo de la doble precisión, doce órdenes de magnitud por debajo.

Dos preguntas naturales acotan el alcance del resultado, y ambas se responden empíricamente. ¿Elige el entrenamiento un gauge benigno? En el gauge que el optimizador deja —sin inyectar ninguno— la factorización se acerca al balance (lemma 1): la lectura por pesos se alinea con el objeto identificable hasta 18–35°. Las dos decisiones de poda, sin embargo, no llegan a coincidir, y el par más redundante difiere en el 37–44 % de las capas. La no-identificabilidad no es una posibilidad remota que el entrenamiento esquiva: es un margen que el entrenamiento reduce sin cerrar. ¿Y cuánta separación angular tolera la función? Una sonda que separa las direcciones dominantes hasta el umbral del simplex no produce coste funcional detectable a la intensidad medida. Solo la imposición dura —más allá del umbral— paga en función. El acoplamiento entre esa geometría y la función depende del mecanismo, y los tres regímenes de intervención (libre, suave, dura) lo delimitan.

Como instrumento positivo, la firma de respuesta gauge-invariante $\mathbf{v}_1(\mathbf{C}_h^P)$ —la dirección dominante del segundo momento (*second moment*) de la contribución de la cabeza sobre un conjunto sonda, sin centrar por parche— mide diversidad funcional sin la ambigüedad, admite un radio explícito frente a la perturbación del estimador (lemma 2), de peor caso, y resulta específica de cada cabeza. Es la sustitución concreta que la práctica puede adoptar donde hoy lee pesos.

Contribuciones. (i) La caracterización exacta de la órbita de $\mathbf{v}_1(\mathbf{W}_O)$ bajo el gauge valor-salida —la esfera completa del espacio fila— con su radio certificado nulo y su frontera conforme ortogonal (sección 3); (ii) la certificación numérica de la órbita par a par a precisión de máquina, 3960/3960 pares (sección 7.1); (iii) la consecuencia decisional medida en dos modalidades con la misma forma cerrada (sección 7.2); (iv) la medición del gauge natural del entrenamiento y de su distancia al balance (sección 7.3); (v) el contraste de los tres regímenes de intervención y la firma invariante como instrumento (secciones 4 y 5.2). Código, datos, pesos y una demo interactiva están archivados con DOI (sección de disponibilidad).

2. Trabajo relacionado

El circuito OV como unidad de análisis. Que el sector valor-salida solo sea significativo como producto no es observación de este trabajo. Elhage et al. (2021) organizan el análisis de la atención en dos circuitos —QK y OV— y describen las matrices individuales como resultados intermedios: claves, consultas y valores “can be thought of as intermediate results in the computation of the low-rank matrices $\mathbf{W}_Q^\top \mathbf{W}_K$ and $\mathbf{W}_O \mathbf{W}_V$ ”, de modo que “it can be useful to describe transformers without reference to them”. El mismo trabajo enuncia una libertad de reparametrización, la del flujo residual, que carece de base privilegiada: “we could rotate it by rotating all the matrices interacting with it, without changing model behavior”. Este trabajo parte de ahí y añade cuatro piezas ausentes de esa observación. Primera, la órbita en forma cerrada: no que $\mathbf{v}_1(\mathbf{W}_O)$ “no sea único”, sino que su órbita bajo el gauge del sector es la esfera unitaria completa de su espacio fila (proposición 1); y la rotación del residuo no la alcanza, porque el subgrupo ortogonal deja $\mathbf{v}_1(\mathbf{W}_O)$ fija y es la parte no ortogonal —ajena tanto a esa advertencia como a las rotaciones de la compresión— la que la mueve dentro del subespacio. Segunda, la imposibilidad que se sigue: radio certificado nulo, ningún umbral admisible de similitud sobre esa dirección admite garantía. Tercera, la consecuencia decisional, medida: la decisión de poda cambia bajo reparametrización genérica en el 92,7 % de los pares, en visión y en lenguaje (tabla 5), consecuencia que se mide igualmente en el gauge que el entrenamiento deja (sección 7.3). Cuarta, un contraste empírico independiente de la forma cerrada: la sonda de inercia desplaza la geometría decenas de grados sin mover la función (sección 7.4). La observación cualitativa dice qué objeto mirar. Este trabajo cuantifica qué se pierde al mirar el otro.

El grupo gauge del Transformer. El grupo de reparametrizaciones que dejan la función intacta está caracterizado. Van Nierop (2024) lo enuncia por analogía con la invariancia gauge de la física de partículas. Hashimoto et al. (2024) lo unifican con las redundancias de las redes feedforward y las EDO neuronales. Wang and Wang (2026) prueban que, para la atención multi-cabeza canónica y sobre el estrato genérico de rango columna completo, el grupo maximal es exactamente $((GL(d_k))^h \times (GL(d_v))^h) \rtimes S_h$, con los factores consulta-clave y valor-salida factorizando de forma independiente y la permutación de cabezas como única simetría discreta. Tran et al. (2026) miden cuánto reducen ese grupo las codificaciones posicionales. Este trabajo toma el factor $(GL(d_v))^h$ de ese grupo —independiente por cabeza, sobre el mismo estrato de rango completo que aquí es hipótesis— y no lo caracteriza: caracteriza la órbita que induce sobre $\mathbf{v}_1(\mathbf{W}_O)$, su estabilizador uniforme, el radio funcional nulo y la decisión que rompe. Del grupo usa solo que ese factor es una simetría —hecho elemental—, no la maximalidad ni la controlabilidad de la atención que Wang y Wang exigen para probarla. El factor S_h queda fuera del grupo estudiado: bajo una permutación de cabezas la colección de firmas de respuesta es equivariante —se permutan sus etiquetas—, no una familia invariante cabeza por cabeza (sección 4).

El proxy geométrico de la proyección de salida. Leer el rol o la redundancia de una cabeza desde la dirección dominante de su proyección de salida es el proxy más barato y estático imaginable: no exige forwards ni gradientes, opera directamente sobre el checkpoint. Este trabajo cierra esa vía por anticipado más que corrige una práctica ya extendida en la literatura revisada. Los métodos de poda de vanguardia en este entorno no la usan: HEART-ViT (Uddin et al., 2025) poda cabezas y tokens por sensibilidad Hessiana sobre ViT-B/16 en ImageNet-100, Yang et al. (2023) podan con saliencia Hessiana global, y el análisis de redundancia de cabezas de mayor recorrido lee gradientes o activaciones, no geometría de pesos (Michel et al., 2019; Voita et al., 2019). La interpretabilidad mecanicista más reciente, cuando sí lee geometría de pesos por cabeza, converge además hacia el objeto invariante de gauge y no hacia la dirección dominante aislada: Millidge and Black (2022) descomponen por SVD el circuito OV compuesto y los pesos de las MLP, e interpretan decenas de direcciones singulares, no solo la primera; Dar et al. (2023) proyectan a espacio de embeddings los productos $\mathbf{W}_Q \mathbf{W}_K^\top$ y $\mathbf{W}_V \mathbf{W}_O$, definidos así explícitamente; Ahmad

et al. (2025) descomponen por SVD el circuito OV compuesto $\mathbf{W}_v \mathbf{W}_O$ (y el circuito QK), no $\mathbf{W}_O$ por separado; Franco et al. (2026) descomponen igualmente el circuito $\mathbf{W}_q^\top \mathbf{W}_k$; y Yamagiwa et al. (2026) comparan subespacios de *rango completo* de la proyección de salida —precisamente el objeto que aquí se certifica invariante bajo el gauge del sector valor-salida (proposición 1)—, no su dirección dominante aislada. La corrección que este trabajo aporta es, en consecuencia, corolario de la disociación geometría-función medida (sección 7.4), no la tesis: protege el atajo más barato —leer $\mathbf{v}_1(\mathbf{W}_O)$ solo— del que la práctica más cuidadosa ya se aparta, sin reclamar haber corregido a nadie en particular. La tabla 1 sitúa esas lecturas frente a la firma por sus propiedades, sin afirmación alguna de rendimiento.

Tabla 1: Lecturas del sector valor-salida, por propiedades. Estable por construcción si la lectura factoriza por el espacio fila o por el circuito (corolario 1); *medida* solo donde se indica ($\mathbf{v}_1(\mathbf{W}_O)$ y firma, tabla 5). La raya denota propiedad no medida aquí, no propiedad ausente. La clase inocua es la conforme ortogonal $\{c\mathbf{Q}\}$, bajo la que $\mathbf{v}_1(\mathbf{W}_O)$ ni siquiera se mueve.

Lectura	Inv. de gauge	Datos	Por cabeza	Radio cert.	Estable bajo gauge
$\mathbf{v}_1(\mathbf{W}_O)$	no	no	sí	nulo (proposición 1)	no (92,7 %)
Subespacio dominante de $\mathbf{W}_O$	clase inocua	no	sí	—	no
Espacio fila de $\mathbf{W}_O$	sí	no	sí	—	sí
$\mathbf{v}_1(\mathbf{W}_v \mathbf{W}_O)$, invariante estático	sí	no	sí	—	sí
SVD del circuito OV completo (Millidge and Black, 2022; Dar et al., 2023; Ahmad et al., 2025)	sí	no	sí	—	sí
Kernel de proyección entre subespacios (Yamagiwa et al., 2026)	sí	no	por pares	—	sí
Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	sí	sí	sí	positivo (lemma 2)	sí (tabla 5)

Redundancia y roles de la atención multi-cabeza. El análisis de la atención multi-cabeza ha mostrado que muchas cabezas son prescindibles (Michel et al., 2019) y que cumplen funciones especializadas e identificables (Voita et al., 2019). Una cabeza puede ser importante para la tarea sin que la geometría de su proyección de salida trace ese rol. Si esa especialización es propiedad emergente del entrenamiento o propiedad estática recuperable de los pesos es la cuestión que los resultados de este trabajo abordan (secciones 7 y 8).

La órbita de gauge como recurso, no solo como advertencia. La libertad de gauge que aquí se certifica como fuente de no-identificabilidad (proposición 1) es la misma que la compresión por rotación explota activamente como recurso de diseño. SliceGPT (Ashkboos et al., 2024a) la enuncia como “computational invariance” —transformaciones ortogonales de los pesos que no alteran la salida—, y QuaRot (Ashkboos et al., 2024b) y SpinQuant (Liu et al., 2025) la explotan insertando rotaciones ortogonales que dejan la salida del modelo intacta para eliminar outliers antes de cuantizar. La rotación R_2 de SpinQuant se aplica exactamente al par valor-salida ($\mathbf{W}_v^{(h)} \rightarrow \mathbf{W}_v^{(h)} R_2$, $\mathbf{W}_O^{(h)} \rightarrow R_2^{-1} \mathbf{W}_O^{(h)}$ para toda cabeza h de la capa, con R_2 ortogonal), el mismo gauge de la proposición 1 restringido al subgrupo ortogonal $O(d_h) \subset GL(d_h)$ y, a diferencia de la órbita aquí certificada, compartido entre las cabezas de la capa en vez de independiente por cabeza. Esa restricción es además inocua para la lectura que aquí se examina: bajo un gauge ortogonal $\mathbf{v}_1(\mathbf{W}_O)$ ni siquiera se mueve (sección 3), de modo que la compresión rotada convive con el proxy sin romperlo, y es el gauge completo —con su parte no ortogonal— el que lo rompe. Que esa restricción de la órbita tenga consecuencias operativas medibles en la literatura de compresión es evidencia independiente de que la elección de gauge es un espacio de diseño, además de un

ruido contra el que advertir. Cuantizar el circuito OV a lo largo de esa órbita, y medir cómo se mueve su error con el punto elegido, queda fuera de este trabajo pero es la continuación de diseño más directa. Junto a la atribución por componente sobre $Q \cdot K$, fija el rumbo del trabajo futuro (sección 8). La pregunta simétrica —si el entrenamiento con *weight decay* selecciona por su cuenta un punto casi canónico de esa órbita, y si basta— se mide en la sección 7.3.

Diversidad de cabezas por regularización: el baseline directo. La diversidad entre cabezas se ha promovido con penalizaciones de varios tipos. El antecedente más próximo interviene sobre una señal ligada al comportamiento: un regularizador de ortogonalidad sobre los gradientes de entrada de cada cabeza incrementa la diversidad de los rasgos aprendidos y mejora la generalización fuera de distribución (Nicolioiu et al., 2023). Ese enfoque altera la función —y obtiene ganancia OOD por ello—, frente al cual este trabajo reclama una intervención más simple: separar angularmente la *firma de la respuesta por parche*, sin gradientes de entrada ni segundo orden, con la misma maquinaria del simplex que el regularizador de pesos descartado. El contraste con la intervención sobre $\mathbf{W}_O$ —que no altera la función— es coherente con que la organización que distingue una cabeza de otra resida en la respuesta computada, no en la geometría dominante de los pesos.

Estructura por profundidad en la atención. La estratificación funcional por profundidad en Transformers está documentada. Pan et al. (2024) descomponen la interacción $Q \cdot K$ por SVD de $\mathbf{W}_q^\top \mathbf{W}_k$ y documentan una transición de agrupamiento perceptual (capas tempranas) a contextualización (profundas). Yang et al. (2023), al podar, observan que la proyección de salida y $Q \cdot K$ tienen importancias distintas y una tendencia no monótona en la diversidad de atención por capa. Esta estructura por profundidad es contexto y no contribución de este trabajo: enmarca la costura de la capa 5, donde la organización de la atención deja la escritura residual y pasa a la comparación consulta-clave, y la inversión hacia $Q \cdot K$ que documentamos (sección 7) es vecina de esas observaciones.

Neural collapse, clasificadores fijos y márgenes angulares. El *neural collapse* (Papayan et al., 2020; Zhu et al., 2021) describe la convergencia de medias de clase y clasificador a un marco equiangular ajustado y ha motivado clasificadores *fijos* de geometría predeterminada (Pernici et al., 2022); SphereFace (Liu et al., 2017), CosFace (Wang et al., 2018) y ArcFace (Deng et al., 2019) imponen márgenes angulares sobre prototipos estimados durante el entrenamiento. Aquí el simplex es herramienta del experimento, no contribución: fija una separación garantizada sobre la firma de respuesta de cada cabeza, no sobre sus pesos.

3. El gauge valor-salida y el radio certificado nulo

La práctica que este trabajo examina lee una dirección de los pesos: el primer vector singular $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ de la proyección de salida de cada cabeza, tomado como su dirección representativa para poda por redundancia, interpretación por dirección dominante o routing. Esta sección fija qué de ese sector es identificable y qué no. El instrumento que se apoya en el objeto identificable se deriva en la sección 4.

El sector valor-salida de una cabeza factoriza su contribución al residuo en dos matrices, $\mathbf{W}_v^{(h)} \in \mathbb{R}^{d \times d_h}$ y $\mathbf{W}_O^{(h)} \in \mathbb{R}^{d_h \times d}$, pero esa factorización no es única. Para cualquier $\mathbf{R} \in GL(d_h)$ invertible, la sustitución

$$\mathbf{W}_v^{(h)} \rightarrow \mathbf{W}_v^{(h)} \mathbf{R}, \quad \mathbf{b}_v^{(h)} \rightarrow \mathbf{b}_v^{(h)} \mathbf{R}, \quad \mathbf{W}_O^{(h)} \rightarrow \mathbf{R}^{-1} \mathbf{W}_O^{(h)}, \quad (1)$$

deja la función intacta, porque el producto $\mathbf{W}_v^{(h)} \mathbf{W}_O^{(h)}$ —el *circuito OV*— y el término de sesgo $\mathbf{b}_v^{(h)} \mathbf{W}_O^{(h)}$ no cambian. Sin sesgo de valor el invariante es el circuito solo, y con él es la matriz aumentada $[\mathbf{W}_v^{(h)}; \mathbf{b}_v^{(h)}] \mathbf{W}_O^{(h)}$. Cuanto sigue vale igual en los dos casos, porque solo usa que

$\mathbf{W}_v \mathbf{W}_O$ es invariante. Dentro de la factorización valor-salida, toda propiedad funcional invariante bajo el gauge desciende al circuito OV. La dirección dominante $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ no desciende. Bajo ecuación (1) se desplaza, y la parte del grupo que la mueve se identifica con exactitud. Si $\mathbf{R}$ es ortogonal —o múltiplo escalar de una ortogonal, $\mathbf{R}^{-1} = c\mathbf{Q}$ con $\mathbf{Q} \in O(d_h)$ — entonces $\mathbf{R}^{-1}\mathbf{W}_O = (\mathbf{Q}\mathbf{U})(c\mathbf{\Sigma})\mathbf{V}^\top$ es una descomposición en valores singulares: $\mathbf{Q}\mathbf{U}$ es ortonormal y el escalar queda absorbido en los valores singulares —con $c > 0$ sin pérdida, pues el signo se absorbe en $\mathbf{Q}$ —, de modo que los vectores singulares derechos son los mismos y la dirección no se mueve. La invariancia es del vector mientras $\sigma_1 > \sigma_2$. Con la cabeza del espectro degenerada lo invariante es el subespacio dominante. El recíproco vale de manera uniforme en $\mathbf{W}_O$: si $\mathbf{S} = \mathbf{R}^{-1}$ deja $\mathbf{v}_1(\mathbf{S}\mathbf{W}) = \pm \mathbf{v}_1(\mathbf{W})$ para toda $\mathbf{W}$ de rango completo con $\sigma_1 > \sigma_2$, entonces $\mathbf{S} = c\mathbf{Q}$. Con $\mathbf{W} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ se tiene $\mathbf{v}_1(\mathbf{S}\mathbf{W}) = \mathbf{V} \mathbf{v}_1(\mathbf{S}\mathbf{U}\mathbf{\Sigma})$, y la condición exige que $\mathbf{e}_1$ sea el vector propio dominante de $\mathbf{\Sigma}\mathbf{U}^\top \mathbf{S}^\top \mathbf{S}\mathbf{U}\mathbf{\Sigma}$ para toda $\mathbf{U} \in O(d_h)$ y toda $\mathbf{\Sigma}$ admisible. Con $\mathbf{\Sigma} = \mathbf{I} + \varepsilon \mathbf{e}_1 \mathbf{e}_1^\top$ y $\varepsilon \rightarrow 0$, ese vector propio se acerca al subespacio propio dominante $\mathbf{U}^\top \mathcal{E}$ de $\mathbf{U}^\top \mathbf{S}^\top \mathbf{S}\mathbf{U}$, con $\mathcal{E}$ el de $\mathbf{S}^\top \mathbf{S}$; si $\mathbf{S}^\top \mathbf{S} \neq c^2 \mathbf{I}$, $\mathcal{E}$ es propio, una $\mathbf{U}$ con $\mathbf{U}\mathbf{e}_1 \notin \mathcal{E}$ deja $\mathbf{e}_1$ a distancia positiva de $\mathbf{U}^\top \mathcal{E}$, y la condición falla para ε pequeño. Luego $\mathbf{S}^\top \mathbf{S} = c^2 \mathbf{I}$ y $\mathbf{S} = c\mathbf{Q}$. La unicidad es uniforme, no puntual: sobre una $\mathbf{W}$ concreta, el estiramiento $\mathbf{S} = \mathbf{I} + (a-1)\mathbf{u}_1 \mathbf{u}_1^\top$ a lo largo de su primer vector singular izquierdo, con $a > 1$, también deja $\mathbf{v}_1$ fija sin ser conforme ortogonal. Es la parte no ortogonal, presente en todo gauge genérico, la que mueve la dirección dentro del espacio fila. La libertad de rotación de la base del residuo (Elhage et al., 2021) y las rotaciones ortogonales de la compresión (Ashkboos et al., 2024a,b; Liu et al., 2025) caen por eso del lado inocuo: la no-identificabilidad que aquí se certifica exige el gauge completo. Con él, dos modelos funcionalmente idénticos pueden exhibir cualquier separación angular entre sus $\mathbf{v}_1(\mathbf{W}_O)$. La afirmación admite forma cerrada y cota exacta:

El título de la proposición usa un término que se fija antes de enunciarla. Dada una lectura f del sector con decisión por umbral d_τ , y una clase de perturbaciones $(\mathcal{P}, \text{dist})$ con $\text{dist}(\text{id}) = 0$, el *radio certificado* local en un punto θ del sector es el supremo de los r tales que toda $P \in \mathcal{P}$ con $\text{dist}(P) \leq r$ deja $d_\tau(f(P \cdot \theta)) = d_\tau(f(\theta))$. Para el gauge del sector, la distancia natural es la *dispersión relativa del espectro singular* (*singular-spectrum spread*),

$$d(\mathbf{R}) = \min_{c>0, \mathbf{Q} \in O(d_h)} \frac{\|\mathbf{R} - c\mathbf{Q}\|_F}{\|\mathbf{R}\|_F} = \frac{(\sum_i (\sigma_i - \bar{\sigma})^2)^{1/2}}{(\sum_i \sigma_i^2)^{1/2}}, \quad (2)$$

nula exactamente sobre la clase inocua (*harmless class*) $\{c\mathbf{Q}\}$ que deja $\mathbf{v}_1$ fija ($\mathbf{Q}$ y c óptimos: los de la descomposición polar y la media $\bar{\sigma}$ de los valores singulares de $\mathbf{R}$). Un certificado sobre la *función* exige además *solidez sobre la órbita* (*soundness over the orbit*): $d_\tau \circ f$ debe ser constante sobre la órbita de gauge de θ , cuyos puntos implementan todos la misma función. El radio certificado *funcional* es entonces dicotómico, no graduado: coincide con el radio local si la lectura desciende al cociente por la órbita, y es nulo si no desciende. La dicotomía no es vacua porque separa objetos: el espacio fila, el circuito OV y la firma de respuesta descienden —caen del lado positivo, y para la firma la sección 4 da además radio local positivo frente a la perturbación del estimador (*estimator perturbation*)—. La dirección dominante no desciende, y eso es cuanto la proposición prueba.

Proposición 1 (Radio certificado nulo de la lectura por $\mathbf{v}_1$). *Sea $\mathbf{W}_O^{(h)} \in \mathbb{R}^{d_h \times d}$ de rango completo y $\mathcal{S}_h$ su espacio fila. Para toda dirección unitaria $\mathbf{w} \in \mathcal{S}_h$ existe $\mathbf{R} \in GL(d_h)$ con $\mathbf{v}_1(\mathbf{R}^{-1}\mathbf{W}_O^{(h)}) = \pm \mathbf{w}$, y la sustitución (1) deja el circuito OV intacto. En consecuencia, el ángulo entre las direcciones dominantes de dos cabezas recorre bajo gauge todo ángulo permitido por los espacios fila —desde el primer ángulo principal $\theta_1(\mathcal{S}_h, \mathcal{S}_{h'})$ hasta 90° — con la función fija, y ningún umbral de similitud sobre $\mathbf{v}_1(\mathbf{W}_O)$ dentro del intervalo admisible $(\theta_1(\mathcal{S}_h, \mathcal{S}_{h'}), 90^\circ)$ admite radio certificado positivo.*

Demostración. Con $\mathbf{W}_O = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ y $\mathbf{M} = \mathbf{R}^{-1}\mathbf{U}\mathbf{\Sigma}$ se tiene $\mathbf{R}^{-1}\mathbf{W}_O = \mathbf{M}\mathbf{V}^\top$: cuando el espectro superior de $\mathbf{M}$ es simple ($\sigma_1(\mathbf{M}) > \sigma_2(\mathbf{M})$), el primer vector singular derecho de $\mathbf{M}$ está bien

definido salvo signo y $\mathbf{v}_1(\mathbf{R}^{-1}\mathbf{W}_O) = \mathbf{V} \mathbf{v}_1(\mathbf{M})$. Dada $\mathbf{w} \in \mathcal{S}_h$ unitaria, sea $\mathbf{w}' = \mathbf{V}^\top \mathbf{w} \in \mathbb{R}^{d_h}$ su expresión en la base del espacio fila y $\mathbf{M} = \mathbf{I} + (a - 1) \mathbf{w}' \mathbf{w}'^\top$ con $a > 1$: simétrica, con valores singulares $\{a, 1, \dots, 1\}$, cabeza simple por construcción y $\mathbf{v}_1(\mathbf{M}) = \mathbf{w}'$. La transformación $\mathbf{R} = \mathbf{U} \mathbf{\Sigma} \mathbf{M}^{-1} \in GL(d_h)$ —invertible porque $\mathbf{\Sigma}$ lo es, por el rango completo— realiza ese $\mathbf{M}$, y entonces $\mathbf{v}_1(\mathbf{R}^{-1}\mathbf{W}_O) = \mathbf{V} \mathbf{w}' = \pm \mathbf{w}$. La órbita de $\mathbf{v}_1$ es la esfera unitaria completa de $\mathcal{S}_h$. Con gauges independientes por cabeza, el par de direcciones dominantes recorre el producto de las dos esferas, que es conexo, y el ángulo entre ellas —continuo— toma todo valor entre su mínimo, $\theta_1(\mathcal{S}_h, \mathcal{S}_{h'})$ por definición del primer ángulo principal, y 90° , alcanzado por dos vectores principales de índice distinto (basta $d_h \geq 2$). Para todo umbral del intervalo abierto, $d_\tau \circ f$ no es constante sobre la órbita: la lectura no descende al cociente y su radio funcional es nulo. $\square$

La proposición 1 no reenuncia la observación cualitativa de que el circuito OV es la unidad de análisis (Elhage et al., 2021): la convierte en cota. Nombra la órbita —la esfera completa de $\mathcal{S}_h$ —, la separa de la libertad ortogonal ya conocida —bajo la cual $\mathbf{v}_1(\mathbf{W}_O)$ es invariante— y de ahí extrae el radio certificado nulo: para todo umbral dentro del intervalo admisible, la decisión $d_\tau \circ f$ no es constante sobre la órbita —el ángulo lo barre entero—, luego la lectura no descende al cociente y su radio funcional es nulo, sin construcción local alguna. Es el paso de la advertencia a la imposibilidad, y cada mitad del formalismo se gana el sueldo en un sitio distinto: en el lado negativo, el radio reformula la proposición. En el positivo —la firma— entrega un número explícito.

El matiz que la hace no trivial: el espacio fila *sí* es invariante de gauge. Se mueve la dirección dentro del subespacio, no el subespacio. El resultado negativo tiene por eso grano fino —el subespacio informa (apéndice B.1); la dirección dominante dentro de él, no—. Leer $\mathbf{v}_1$ es leer una elección de gauge, no una propiedad de la función. La sección 7.1 lo mide sobre los pesos reales: la separación entre las $\mathbf{v}_1(\mathbf{W}_O)$ se desplaza con $\mathbf{R}$ mientras la salida y el circuito OV permanecen fijos, y la órbita alcanzable se certifica par a par (apéndice A).

La proposición admite una lectura más general, que nombra qué información de $\mathbf{W}_O$ sola es identificable:

Corolario 1 (Cociente de $\mathbf{W}_O$ por el gauge). *Sea $\mathbf{W}_O \in \mathbb{R}^{d_h \times d}$ de rango fila completo y $\mathcal{S}_h$ su espacio fila. La órbita $\{\mathbf{R}^{-1}\mathbf{W}_O : \mathbf{R} \in GL(d_h)\}$ es exactamente el conjunto de matrices de rango d_h con espacio fila $\mathcal{S}_h$, de modo que el cociente es la grassmanniana (Grassmannian), $\{\mathbf{W} \in \mathbb{R}^{d_h \times d} : \text{rango } \mathbf{W} = d_h\} / GL(d_h) \simeq \text{Gr}(d_h, d)$, y toda lectura de $\mathbf{W}_O$ sola invariante bajo el gauge factoriza por $\mathcal{S}_h$. Para el par $(\mathbf{W}_v, \mathbf{W}_O)$ de rangos completos, el invariante completo es el circuito $\mathbf{C} = \mathbf{W}_v \mathbf{W}_O$.*

Demostración. Si $\mathbf{W}'$ tiene rango d_h y espacio fila $\mathcal{S}_h$, sus filas son combinaciones invertibles de las de $\mathbf{W}_O$: $\mathbf{W}' = \mathbf{T} \mathbf{W}_O$ con $\mathbf{T} = \mathbf{W}' \mathbf{W}_O^+$ única e invertible, luego $\mathbf{W}' = \mathbf{R}^{-1} \mathbf{W}_O$ con $\mathbf{R} = \mathbf{T}^{-1}$. El recíproco es inmediato porque $\mathbf{R}^{-1}$ es invertible. Una función invariante es constante sobre cada órbita, es decir, sobre cada fibra de $\mathbf{W}_O \mapsto \mathcal{S}_h$, y por tanto factoriza por ella. Para el par: si $\mathbf{W}_v \mathbf{W}_O = \mathbf{W}'_v \mathbf{W}'_O$ con rangos completos, los espacios columna de $\mathbf{W}_v$ y $\mathbf{W}'_v$ coinciden con el de $\mathbf{C}$, luego $\mathbf{W}'_v = \mathbf{W}_v \mathbf{R}$ con $\mathbf{R} = \mathbf{W}_v^+ \mathbf{W}'_v$ invertible, y $\mathbf{W}_v(\mathbf{R} \mathbf{W}'_O - \mathbf{W}_O) = \mathbf{0}$ con $\mathbf{W}_v$ de rango columna completo da $\mathbf{W}'_O = \mathbf{R}^{-1} \mathbf{W}_O$. $\square$

El corolario sitúa las lecturas de la tabla 1: el espacio fila y el kernel de proyección entre subespacios (Yamagiwa et al., 2026) factorizan por $\text{Gr}(d_h, d)$ y son invariantes por construcción. La dirección dominante y el subespacio dominante de $\mathbf{W}_O$ no factorizan y no lo son. La Proposición 1 es el caso extremo: la lectura no solo no factoriza: su órbita agota la esfera de la fibra.

Queda por nombrar el punto de la órbita que el propio entrenamiento podría preferir, porque la sección 7.3 lo mide sobre los pesos reales. El sesgo de valor no entra en la penalización y no altera el lema:

Lema 1 (Punto balanceado). *Sea $\mathbf{C} = \mathbf{W}_v^{(h)} \mathbf{W}_O^{(h)}$ de rango completo d_h . Sobre $GL(d_h)$, el mínimo de $\|\mathbf{W}_v \mathbf{R}\|_F^2 + \|\mathbf{R}^{-1} \mathbf{W}_O\|_F^2$ a circuito fijo vale $2\|\mathbf{C}\|_*$ —la norma nuclear— y se alcanza exactamente en las factorizaciones balanceadas (balanced factorizations), $(\mathbf{W}_v \mathbf{R})^\top (\mathbf{W}_v \mathbf{R}) =$*

$(\mathbf{R}^{-1}\mathbf{W}_O)(\mathbf{R}^{-1}\mathbf{W}_O)^\top$, únicas salvo el subgrupo ortogonal $O(d_h)$. Si además $\sigma_1(\mathbf{C}) > \sigma_2(\mathbf{C})$, en todo punto balanceado (balanced point) $\mathbf{v}_1(\mathbf{W}_O) = \pm \mathbf{v}_1(\mathbf{C})$: la lectura por pesos coincide con el invariante. Con espectro degenerado la coincidencia es del subespacio dominante, la misma cláusula que la proposición 1 lleva para $\mathbf{W}_O$.

Demostración. Para toda factorización $\mathbf{C} = \mathbf{A}\mathbf{B}$ con $\mathbf{A} = \mathbf{W}_v\mathbf{R}$, $\mathbf{B} = \mathbf{R}^{-1}\mathbf{W}_O$: $2\|\mathbf{C}\|_* \leq 2\|\mathbf{A}\|_F\|\mathbf{B}\|_F \leq \|\mathbf{A}\|_F^2 + \|\mathbf{B}\|_F^2$ —la primera desigualdad es Hölder para las normas de Schatten con $p=q=2$ (Bhatia, 1997), la segunda es AM–GM; juntas son la forma variacional de la norma nuclear (Srebro and Shraibman, 2005)—. Con $\mathbf{C} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ reducida, el par $\mathbf{A}_0 = \mathbf{U}\mathbf{\Sigma}^{1/2}$, $\mathbf{B}_0 = \mathbf{\Sigma}^{1/2}\mathbf{V}^\top$ alcanza el valor y es balanceado. Es además alcanzable dentro de la órbita: $\mathbf{R} = \mathbf{W}_v^+\mathbf{A}_0$ cumple $\mathbf{W}_v\mathbf{R} = \mathbf{A}_0$ —las columnas de $\mathbf{A}_0$ viven en el espacio columna de $\mathbf{C}$, contenido en el de $\mathbf{W}_v$ — y es invertible porque $\mathbf{A}_0$ tiene rango d_h . La identidad $\mathbf{W}_v(\mathbf{R}\mathbf{B}_0 - \mathbf{W}_O) = \mathbf{0}$ con $\mathbf{W}_v$ de rango columna completo da $\mathbf{R}^{-1}\mathbf{W}_O = \mathbf{B}_0$. Que no haya otros minimizadores se ve por estacionariedad. La función $\varphi(\mathbf{R}) = \|\mathbf{W}_v\mathbf{R}\|_F^2 + \|\mathbf{R}^{-1}\mathbf{W}_O\|_F^2$ es suave en el abierto $GL(d_h)$ y coerciva en él — $\|\mathbf{W}_v\mathbf{R}\|_F \geq \sigma_{\min}(\mathbf{W}_v)\|\mathbf{R}\|_F$ y $\|\mathbf{R}^{-1}\mathbf{W}_O\|_F \geq \sigma_{\min}(\mathbf{W}_O)\|\mathbf{R}^{-1}\|_F$, con ambos $\sigma_{\min}$ positivos por el rango completo—, de modo que todo minimizador es un punto estacionario. Su gradiente es $2\mathbf{W}_v^\top\mathbf{W}_v\mathbf{R} - 2\mathbf{R}^{-\top}\mathbf{B}\mathbf{B}^\top$; anularlo y multiplicar por $\mathbf{R}^\top$ a la izquierda da $\mathbf{A}^\top\mathbf{A} = \mathbf{B}\mathbf{B}^\top$: todo minimizador es balanceado. Del balance y de $\mathbf{C} = \mathbf{A}\mathbf{B}$ se sigue $\mathbf{C}^\top\mathbf{C} = \mathbf{B}^\top(\mathbf{A}^\top\mathbf{A})\mathbf{B} = (\mathbf{B}^\top\mathbf{B})^2$, luego $\mathbf{B}^\top\mathbf{B} = (\mathbf{C}^\top\mathbf{C})^{1/2} = \mathbf{V}\mathbf{\Sigma}\mathbf{V}^\top$ —raíz semidefinida única— y $\mathbf{B} = \mathbf{Q}^\top\mathbf{\Sigma}^{1/2}\mathbf{V}^\top$ con $\mathbf{Q} \in O(d_h)$; entonces $\mathbf{A} = \mathbf{C}\mathbf{B}^\top(\mathbf{B}\mathbf{B}^\top)^{-1} = \mathbf{U}\mathbf{\Sigma}^{1/2}\mathbf{Q}$. Toda esa familia alcanza $2\|\mathbf{C}\|_*$ y no hay minimizadores fuera de ella. En ella, los vectores singulares derechos de $\mathbf{B}$ son los de $\mathbf{C}$, y con $\sigma_1 > \sigma_2$ el primero es $\mathbf{v}_1(\mathbf{C})$ salvo signo. $\square$

Verificación numérica, sin forwards: sobre cincuenta instancias aleatorias la construcción por SVD reconstruye el circuito, satisface el balance y ninguna perturbación de $\mathbf{R}$ la mejora. Sobre el ancla, el ángulo α entre la lectura por pesos y el invariante, evaluado en el punto balanceado construido, es cero numérico exacto en las 144 cabezas. El punto que el lema nombra es la referencia contra la que la sección 7.3 lee los 18–35° del gauge que el entrenamiento deja.

El punto balanceado no es la única forma canónica de la órbita. Wang and Wang (2026) fijan el gauge valor-salida por factorización QR de $\mathbf{W}_v$ —columnas ortonormales, residuo $O(d_h)$ por cabeza— y nombran el balance de Gram como alternativa en el sector consulta-clave. Sobre la forma QR también $\mathbf{v}_1(\mathbf{W}_O) = \pm \mathbf{v}_1(\mathbf{C})$: con $\mathbf{W}_v = \mathbf{U}\mathbf{Q}$ se tiene $\mathbf{W}_O = \mathbf{W}_v^+\mathbf{C} = \mathbf{Q}^\top\mathbf{\Sigma}\mathbf{V}^\top$, y los vectores singulares derechos son los de $\mathbf{C}$. Más en general, todo gauge con $\mathbf{W}_v = \mathbf{U}\mathbf{D}\mathbf{Q}$ — $\mathbf{D}$ diagonal positiva en la base singular izquierda de $\mathbf{C}$, con σ_1/d_1 máximo— da $\mathbf{W}_O = \mathbf{Q}^\top\mathbf{D}^{-1}\mathbf{\Sigma}\mathbf{V}^\top$ y alinea la lectura con el invariante. El residuo $O(d_h)$ del gauge-fixing es la parte ortogonal de la clase inocua $\{c\mathbf{Q}\}$, bajo la que la lectura no se mueve. El lema añade qué representante de esa familia favorece el entrenamiento: el de norma de Frobenius mínima, hacia el que empuja el *weight decay*, y ese es la referencia de la sección 7.3. El ángulo α que allí se mide es nulo sobre toda la familia alineada, de modo que la lectura no depende de cuál de sus formas canónicas se nombre.

4. La firma de respuesta gauge-invariante

Si la dirección dominante no es una representación funcionalmente identificable de la cabeza, una medida de diversidad de cabezas ha de anclarse a un objeto identificable. La contribución por parche de la cabeza al flujo residual,

$$\mathbf{C}_h^P = \mathbf{A}_h\mathbf{V}_h\mathbf{W}_O^{(h)} \in \mathbb{R}^{P \times d}, \quad (3)$$

—producto del mapa de atención $\mathbf{A}_h$, la proyección de valor $\mathbf{V}_h$ y la de salida $\mathbf{W}_O^{(h)}$ — es la respuesta que la cabeza *computa* y escribe en el residuo, e invariante de gauge: $\mathbf{A}_h\mathbf{V}_h\mathbf{R}\mathbf{R}^{-1}\mathbf{W}_O^{(h)} = \mathbf{C}_h^P$. Su primer vector singular derecho,

$$\mathbf{r}_h = \mathbf{v}_1(\mathbf{C}_h^P) \in \mathbb{S}^{d-1}, \quad (4)$$

—la *firma de respuesta* condicionada a la sonda (*probe-conditioned response signature*), $\mathbf{r}_h = \mathbf{r}_h(P)$, la dirección del residuo en que la cabeza deposita más energía sobre los parches— está bien definida entre cabezas y vive en el residuo compartido $\mathbb{R}^{768}$, el mismo espacio que $\mathbf{v}_1(\mathbf{W}_O)$, y eso hace comparables la lectura de pesos y la de función.¹ La invariancia exacta es frente al gauge continuo del sector; bajo una permutación de cabezas la colección $\{\mathbf{r}_h\}$ es equivariante, no invariante. La firma depende de la sonda —de su tamaño y de su composición por clases (lemma 2)—. El gauge cambia la parametrización sin cambiar la función, la sonda elige qué distribución funcional se resume, y las dos elecciones no son del mismo tipo. Esta firma es el instrumento de medida del trabajo: con ella se cuantifica la diversidad funcional de las cabezas sin la ambigüedad de gauge que invalida la lectura por $\mathbf{v}_1(\mathbf{W}_O)$. El apéndice B.3 la contrasta con la lectura estática, y el apéndice B.2 comprueba que es específica de cada cabeza por emparejamiento entre mitades de la sonda.

Frente al gauge, la firma no necesita radio: es exactamente invariante. Frente a la perturbación del estimador sí lo admite, y con hueco observable:

Lema 2 (Radio de la firma frente al estimador). *Sea $\hat{\mathbf{C}}_h \in \mathbb{R}^{P \times d}$ con $\sigma_1 > \sigma_2$ y $\mathbf{E} \in \mathbb{R}^{P \times d}$ con $\|\mathbf{E}\|_2 < \sigma_1 - \sigma_2$. Entonces*

$$\sin \theta(\mathbf{v}_1(\hat{\mathbf{C}}_h), \mathbf{v}_1(\hat{\mathbf{C}}_h + \mathbf{E})) \leq \frac{\sqrt{2} \|\mathbf{E}\|_2}{\sigma_1 - \sigma_2 - \|\mathbf{E}\|_2},$$

y si la decisión por firma de una capa tiene margen m —la diferencia de $|\cos|$ entre el par ganador y el subcampeón— y g es el mínimo del hueco sobre las cabezas de la capa —cualquier cabeza puede entrar en un par competidor, y un par lejano con huecos pequeños escaparía a un mínimo restringido al ganador y al subcampeón—, la decisión es invariante bajo toda perturbación por cabeza con $\|\mathbf{E}\|_2 < g m / (8 + m)$. El radio es positivo para todo hueco $g > 0$ y todo margen $m > 0$; con empate ($m = 0$) es nulo.

Demostración. Por Weyl (Stewart and Sun, 1990), la separación perturbada es al menos $\sigma_1 - \sigma_2 - \|\mathbf{E}\|_2$, y el teorema de Wedin (1972) con esa separación, en la forma conjunta sobre los dos subespacios singulares —de ahí el factor $\sqrt{2}$ (Chen et al., 2021, Teorema 2.9)—, da la cota del seno. La cuerda acota el desplazamiento del vector, $\|\Delta \mathbf{v}\| = 2 \sin(\theta/2) \leq \sqrt{2} \sin \theta$ para $\theta \leq 90^\circ$, luego por cabeza $\|\Delta \mathbf{v}\| \leq 2 \|\mathbf{E}\|_2 / (g - \|\mathbf{E}\|_2)$; cada $|\cos|$ por pares se mueve a lo sumo la suma de sus dos cabezas, porque con vectores unitarios $\langle \mathbf{u}, \mathbf{w} \rangle - \langle \mathbf{u}', \mathbf{w}' \rangle = \langle \mathbf{u} - \mathbf{u}', \mathbf{w} \rangle + \langle \mathbf{u}', \mathbf{w} - \mathbf{w}' \rangle$. Todo par distinto del ganador tiene déficit al menos m —el subcampeón realiza el máximo—, y su subida, como la caída del ganador, queda acotada por los huecos de sus propias cabezas; con g el mínimo de la capa, la erosión conjunta de cualquier competidor frente al ganador queda bajo m mientras: $8 \|\mathbf{E}\|_2 / (g - \|\mathbf{E}\|_2) < m$, que despeja al radio del enunciado. $\square$

El prerregistro de la verificación —fijado antes de leer dato alguno, con su enmienda de derivación fechada— declaraba el radio no vacío solo si supera la fluctuación real del estimador, medida como el recambio de media sonda. A $P=1000$ no la supera: la mediana de $r_h / \|\mathbf{E}\|$ sobre las 144 cabezas del ancla es 0,001, y en 134 la fluctuación excede el propio hueco, vaciando el certificado por construcción. El radio es positivo y computable, pero de peor caso: no cubre el recambio de media sonda, la perturbación más gruesa de su clase. Un diagnóstico fuera del prerregistro completa la lectura con la perturbación real, no la adversaria: recomputando la firma sobre cada mitad de la sonda por separado, el par más redundante coincide entre mitades en 8 de las 12 capas del ancla (ídem el conjunto de poda top-3). La estabilidad exacta de la firma es frente al gauge. Frente al estimador es materia de muestra finita, y a este P la decisión por firma conserva sensibilidad de muestreo en un tercio de las capas.

Ese 8 de 12 es un punto de una curva, medida sobre sondas anidadas —cada tamaño prefijo del siguiente, en orden rotado por clases— con $P \in \{250, 500, 1000, 2000, 5000\}$ y las cinco semillas

¹El vector singular está definido salvo signo. Las comparaciones entre firmas singulares emplean por ello el valor absoluto del producto escalar.

del ancla. La coincidencia del par entre mitades sube de $10,4 \pm 0,9$ a $11,4 \pm 0,5$ sobre las 12 capas (media y desviación entre semillas) al pasar de 250 a 5000 imágenes, sin alcanzar el 12 de 12 en ninguna semilla sostenida —dos de cinco lo alcanzan a $P=5000$ y ninguna baja de 11—, y el conjunto top-3 sube de 7,8 a 10,4. La mediana de $r_h/\|\mathbf{E}\|$, en cambio, no se mueve con el tamaño: queda entre 0,0014 y 0,0017 en toda la rejilla, con el 89-90 % de las cabezas fuera de dominio a todo P . Agrandar la sonda mejora la estabilidad empírica de la decisión y no acerca el certificado de peor caso a la fluctuación: denotan cosas distintas y la curva las separa. El propio 8 de 12 admite además una precisión de composición: las mitades de la sonda publicada son bloques de clases disjuntas, y rehecho el mismo $P=1000$ con mitades balanceadas por clase —las mismas mil imágenes— la coincidencia sube a 10 de 12. Dos de las cuatro capas discrepantes lo eran por composición de clases, no por tamaño de muestra.

5. Tres regímenes de intervención sobre el sector valor-salida

El trabajo interviene sobre el sector valor-salida a tres regímenes (*intervention regimes*): el gauge libre de la sección 3, que no toca la función por construcción; una sonda angular que entrena separando las direcciones dominantes hasta un umbral con garantía; y una variante dura que impone la configuración objetivo en cada paso. Esta sección fija el objetivo angular —el simplex del régimen holgado— y define la sonda y su variante.

5.1. Códigos esféricos y regímenes de separación angular

Definición 1 (Código esférico). *Un código esférico de tamaño K en dimensión d es un conjunto $\mathcal{C} = \{\mathbf{u}_1, \dots, \mathbf{u}_K\} \subset \mathbb{S}^{d-1}$ de direcciones unitarias. Su separación angular mínima es*

$$\theta_{\min}(\mathcal{C}) = \min_{i \neq j} \arccos(\langle \mathbf{u}_i, \mathbf{u}_j \rangle). \quad (5)$$

El objetivo es hallar $\mathcal{C}^*$ que maximice $\theta_{\min}$. En el régimen holgado ($K \leq d+1$), el único que este trabajo visita ($K=12$ o 16 frente a $d=768$ o 1024), el óptimo con signo es el simplex regular y tiene forma cerrada: se factoriza su matriz de Gram —unos en la diagonal, $-1/(K-1)$ fuera— y se embebe en $\mathbb{R}^d$ por rotación. El código objetivo de la variante dura (sección 5.2) es esa configuración. Su construcción es determinista y reproducible sin descenso alguno.

La separación angular alcanzable por un código de K direcciones en $\mathbb{S}^{d-1}$ depende de la relación entre K y d , y de si las direcciones portan signo. Para direcciones con signo, sumando las K direcciones unitarias y observando que la norma al cuadrado es no negativa,

$$0 \leq \left\| \sum_h \mathbf{u}_h \right\|^2 = K + \sum_{h \neq h'} \langle \mathbf{u}_h, \mathbf{u}_{h'} \rangle, \quad (6)$$

el coseno medio entre pares es al menos $-1/(K-1)$, y el coseno máximo no puede quedar por debajo de su media: $\theta_{\min} \leq \arccos(-1/(K-1))$ para *cualquier* configuración, no solo las equiangulares. En el *régimen holgado* ($K \leq d+1$) la cota se alcanza —con igualdad exactamente cuando la suma se anula y la configuración es equiangular— por el simplex regular, que es por tanto óptimo (Rankin, 1955). Para direcciones definidas *salvo signo* —vectores singulares, elementos del espacio proyectivo— la similitud pertinente es $|\cos|$ y el ángulo sin signo vive en $[0^\circ, 90^\circ]$: si $K \leq d$, el máximo lo alcanza el marco ortogonal (90°), y el simplex leído sin signo ($\arccos(1/(K-1))$) queda por debajo. El papel de cada valor en el regularizador —óptimo con signo, umbral sin signo— se precisa en la sección 5.2. El $84,78^\circ$ no es, por tanto, el óptimo del problema que la sonda regulariza —ese es el marco ortogonal—, sino un umbral operativo heredado del simplex. Que la sonda blanda lo rebase y siga hacia el marco ortogonal (sección 7.4) es lo esperable. El régimen saturado ($K > d+1$) no se visita en este trabajo.

5.2. El regularizador sobre W_O como sonda de inercia

Para contrastar si intervenir sobre la geometría de pesos mueve la función, el trabajo emplea como *sonda* —no como método propuesto— un regularizador angular natural construido sobre ese proxy: separar las direcciones representativas $\{\mathbf{v}_1(\mathbf{W}_O^{(h)})\}_{h=1}^H$ hacia el umbral del simplex. El conjunto es un código esférico de H direcciones definidas salvo signo, y el término empuja sus cosenos absolutos por debajo del umbral,

$$\mathcal{R}_{ov} = \sum_{h \neq h'} \max(0, |\langle \mathbf{v}_1(\mathbf{W}_O^{(h)}), \mathbf{v}_1(\mathbf{W}_O^{(h')}) \rangle| - \cos \theta^*), \quad (7)$$

con $\theta^* = \arccos(1/(H-1)) \approx 84,78^\circ$ el umbral heredado del simplex de H vectores (sección 5.1). El valor absoluto es necesario: dos cabezas con direcciones casi antiparalelas son equivalentes salvo signo, y el producto con signo las leería como bien separadas. La penalización se anula en todo el intervalo $|\cos| \leq 1/(H-1)$, de modo que exige separación suficiente, no una configuración concreta. La sonda se suma a la entropía cruzada con peso λ ,

$$\mathcal{L} = \mathcal{L}_{\text{tarea}} + \lambda \mathcal{R}_{ov}, \quad (8)$$

y la pregunta empírica es si, al separar esas direcciones, la similitud funcional entre cabezas se mueve. La sección 7.4 no detecta desplazamiento de la similitud funcional por encima de la variabilidad entre semillas a la intensidad fijada ($\lambda = 10^{-3}$).

6. Configuración experimental

Conjunto de datos. Se emplea ImageNet-100, el subconjunto de 100 clases de ImageNet definido por la lista de CMC (Tian et al., 2020). Cien clases aportan riqueza angular suficiente para que la diversidad entre cabezas sea medible, y el fenómeno estudiado depende de la relación entre el número de cabezas y la dimensión, no del número de clases. ImageNet-100 es, así, representativo sin la escala completa.

Arquitecturas y entorno. El aparato —gauge $GL(d_h)$ del sector valor-salida, circuito OV, interacción $Q \cdot K$ y firma $\mathbf{C}_h^P$ — se define igual en toda atención global, de modo que se contrasta sobre tres columnas que varían los dos ejes pertinentes sin reinterpretar una sola métrica (tabla 2). ViT-B/16 y ViT-L/16 (Dosovitskiy et al., 2021) cambian la escala y la profundidad del backbone a anchura por cabeza constante (H de 12 a 16, d de 768 a 1024, L de 12 a 24, con $d_h = 64$ y por tanto $H/d = 1/64$ fijos); DINOv2 (Oquab et al., 2024) —ViT-L/14, misma anchura y profundidad— cambia el régimen de entrenamiento —autosupervisado frente a supervisado— sobre esa misma escala. Las tres parten de pesos preentrenados (timm 1.0.22; Wightman, 2019). ViT-B y ViT-L se afinan sobre ImageNet-100, y DINOv2 se analiza congelado, sin afinado alguno, de modo que sus mapas de atención son los del preentrenamiento autosupervisado puro. La arquitectura ancla (ViT-B) se entrena con **cinco semillas** ($\{42, \dots, 46\}$) y ViT-L con tres. La columna congelada es una sola realización (un único checkpoint preentrenado; no se estima variabilidad entre semillas) y sus celdas van sin banda. Se reporta el n por fila. El contraste prueba transferencia entre dos escalas y profundidades a d_h constante y, en la columna ViT-L, entre regímenes de preentrenamiento; no varía de forma independiente el cociente cabezas/dimensión. La variabilidad entre semillas es el suelo de ruido contra el que se contrastan los efectos. El entorno es una GPU NVIDIA RTX 5090 de 32 GB. La atención por ventana —Swin y, en general, la no-global— queda fuera: la no-identificabilidad sí transferiría (el gauge valor-salida es estructural a cualquier factorización valor-salida), pero la inercia y la reubicación se miden sobre objetos que su topología jerárquica y local redefine —el mapa deja de ser global, la profundidad deja de ser uniforme—, y entran como extensión, no como columna de estas tablas.

Tabla 2: Arquitecturas del contraste y desenlace por apoyo. ViT-B→ViT-L varía escala y profundidad a d_h y H/d constantes; ViT-L→DINOv2 varía el régimen a escala constante. n : semillas; la columna congelada es una realización, sin dispersión entre semillas. Gauge: invariancia de salida (fp64) con deriva de $\mathbf{v}_1(\mathbf{W}_O)$; residuo: capas con emparejado $<$ nulo; cruce: capa del cruce sostenido $r_{Q \cdot K} > r_{\mathbf{W}_O}$ contra los listones de 24 capas fijados antes del dato; inercia (H1): solo columnas afinadas. El cruce de ViT-L supera dos de los tres listones (salto +0,403, margen +0,366) y falla el predominio profundo (+0,375 frente al listón $\geq 0,40$) por su capa final; el desenlace conjuntivo es ambiguo y se reporta como tal (apéndice B.1).

Arquitectura	(H, d)	n	Régimen	Gauge	Residuo	Cruce	Inercia
ViT-B/16 (ancla)	(12, 768)	5	sup., afinado	sí	12/12	capa 5 (5/5)	cota
ViT-L/16	(16, 1024)	3	sup., afinado	sí	24/24	capas 8–11 (3/3)	cota
DINOv2 (ViT-L/14)	(16, 1024)	1	SSL, congelado	sí	24/24	no transfiere	no aplica

Métricas. Separación angular mínima sin signo entre las direcciones representativas $\mathbf{v}_1(\mathbf{W}_O)$, $\theta_{\min}$, medida por capa —el mínimo entre pares de esa capa— y reportada como media entre las capas; redundancia angular entre cabezas — $|\cos|$ medio entre pares de esas direcciones—; similitud funcional s_{func} —coseno entre mapas de atención promedio—; exactitud top-1. Todas se reportan con media y *banda* entre semillas —en todo el trabajo, «banda» denota la desviación estándar entre semillas (*band*), y la de la variante base es el suelo de ruido contra el que se contrasta cualquier efecto—, y los valores finales de cada corrida se extraen como promedio de las últimas cinco épocas convergidas —la misma ventana para todas las variantes y métricas—, de modo que cada celda es trazable a su `run.csv`.

Tabla 3: Protocolo de afinado, común a base, blanda y dura salvo el término de la sonda. Fuente: `configs/` del repositorio y el bucle de entrenamiento.

Optimizador	AdamW ($\beta_1 = 0,9$, $\beta_2 = 0,999$)
Tasa de aprendizaje base y planificador	10^{-4} ; coseno a 30 épocas, sin calentamiento
<i>Weight decay</i>	0,05, desacoplado
Tamaño de lote	128 (ViT-B, DINOv2); 64 (ViT-L)
Pérdida	entropía cruzada con suavizado de etiquetas 0,1
Épocas y ventana de lectura	30; promedio de las últimas 5 con $ce > 0$
Aumentos	recorte aleatorio reescalado a 224 y volteo horizontal; validación: reescalado a 256 y recorte central
Precisión	fp32 en el entrenamiento; fp64 en el gauge-flip
Checkpoint de partida (timm 1.0.22)	<code>vit_base_patch16_224</code> <code>vit_large_patch16_224</code> <code>vit_large_patch14_dinov2.lvd142m</code>
Columna congelada	backbone fijo; cabeza lineal a 10^{-3}
Sonda: λ y umbral	10^{-3} ; $\arccos(1/(H-1))$
Variante dura	reproyección al simplex tras cada paso
Semillas	ViT-B {42, ..., 46}; ViT-L {42, 43, 44}

Conjunto de probing congelado. Las medidas funcionales comparten un único subconjunto de validación, muestreado una vez con semilla fija (10 imágenes por clase, 1000 en total, estratificado), de modo que el ruido de muestreo no contamina las comparaciones por capa.

6.1. Hipótesis y tests, fijados antes del dato

El trabajo sostiene una afirmación —la dirección dominante de la proyección de salida no es una representación funcionalmente identificable de la cabeza— y reparte la disciplina confirmatoria entre sus apoyos medidos. La pieza de no-identificabilidad (sección 3) es de forma cerrada y no entra en esta disciplina. Se preespecifican los tres contrastes empíricos, con sus métricas y direcciones fijadas aquí.

H1 (inercia). La sonda sobre $\mathbf{v}_1(\mathbf{W}_O)$ (ecuación (7)) eleva la separación angular hasta el umbral del simplex, $\theta_{\min} \rightarrow \theta^*$, pero la similitud funcional agregada no desciende del nivel base:

$$\Delta s_{\text{func}} = s_{\text{func}}^{\lambda} - s_{\text{func}}^{\text{base}} \approx 0, \quad (9)$$

a la intensidad fijada ($\lambda = 10^{-3}$). La predicción es la *ausencia* de efecto, no su presencia, y se juzga contra el suelo de ruido entre semillas: hay inercia si $|\Delta s_{\text{func}}|$ no excede la banda base mientras $\theta_{\min}$ satura. El criterio es un criterio de equivalencia práctica (*practical equivalence criterion*) preespecificado, no un test de equivalencia estadística. H1 requiere entrenar con la sonda y se contrasta en las dos columnas afinadas (ViT-B y ViT-L). La columna congelada no participa por construcción.

H2 (no-identificabilidad operativa). Bajo el gauge-flip del sector valor-salida (ecuación (1)) aplicado sin reentrenar, la deriva de $\mathbf{v}_1(\mathbf{W}_O)$ crece con la magnitud del gauge $\delta_{\mathbf{R}}$ hasta saturar, mientras la salida y la firma del circuito OV permanecen en el suelo numérico. El test es la monotonía de la deriva de pesos frente a su constancia en el circuito, sobre la malla de fuerzas.

H3 (reubicación). La correlación por capa entre s_{func} y la interacción $Q \cdot K$ supera a la del subespacio de $\mathbf{W}_O$ en una capa interior, con $Q \cdot K$ pasando de cerca de cero a claramente positivo en esa capa —el salto brusco, no un cruce por margen— y creciendo de forma monótona hacia las profundas. El cruce es reproducible *a través de las arquitecturas*, por semilla dentro de cada una y entre las tres escalas y regímenes, y es indiferente a la sonda. En la ancla el cruce cae en la capa 5. Para las columnas nuevas se preespecifica solo su *existencia y unicidad* —un salto brusco en una capa interior, con crecimiento monótono hacia las profundas—, no su índice: una columna de 24 capas no tiene por qué cruzar «en la 5». La firma de respuesta, además, se comprueba específica de cada cabeza contra un **nulo de permutación** (apéndice B.3).

Los tres se leen con su banda y con el n propio de cada arquitectura. La disciplina confirmatoria descansa en la *reproducibilidad del signo y del cruce*, no en tests inferenciales de potencia: H1 —ausencia de movimiento de s_{func} — se exige reproducible en las dos columnas afinadas, y H3 —cruce hacia $Q \cdot K$ — en las tres, de modo que el “cinco de cinco en una sola” se eleva a su reproducción a través de dos escalas y dos regímenes, criterio más firme que la potencia que dos semillas menos sacrifican en las arquitecturas nuevas. El smoke exploratorio previo fijó la banda de ruido. Los valores se confirman aquí sobre ImageNet-100 limpio con el conjunto congelado.

Desenlace de la disciplina confirmatoria. H2 y el nulo de permutación se reproducen en las tres columnas. H1 se reproduce en las dos afinadas, con el signo del desplazamiento invertido entre ellas. H3 no se reproduce en los términos preespecificados: se sostiene en la ancla, queda ambigua en ViT-L por uno de los tres listones y no se sostiene en la columna congelada. El criterio se aplica tal como se fijó y el desenlace se reporta sin reajustarlo (apéndice B.1).

7. Verificación

La verificación se ordena del enunciado a su consecuencia: la órbita de la proposición 1, medida par a par sobre los pesos reales; la decisión de poda bajo el gauge, en visión y en lenguaje; el gauge que el propio entrenamiento elige, sin inyectar ninguno; y las dos regímenes que entrenan, la sonda hasta el umbral y la imposición dura. Los resultados se cierran sobre cinco semillas en un ViT-B/16 afinado en ImageNet-100 y se contrastan sobre ViT-L/16 y un DINOv2 congelado. La columna de lenguaje (Pythia-410M) entra sin entrenamiento, por la misma forma cerrada. Dos diagnósticos correlacionales —la reubicación hacia $Q \cdot K$ y el portador de residuo— se subordinan al apéndice B.

7.1. La órbita, medida par a par

La contribución de una cabeza al residuo es invariante bajo una libertad de gauge del espacio de valor: para cualquier $\mathbf{R} \in GL(d_h)$, la sustitución $\mathbf{W}_v \rightarrow \mathbf{W}_v \mathbf{R}$, $\mathbf{b}_v \rightarrow \mathbf{b}_v \mathbf{R}$, $\mathbf{W}_O \rightarrow \mathbf{R}^{-1} \mathbf{W}_O$ deja la función intacta, porque $\mathbf{W}_v \mathbf{W}_O$ —el circuito OV, invariante de gauge del sector— no cambia. La dirección dominante $\mathbf{v}_1(\mathbf{W}_O)$ —su primer vector singular derecho, la dirección de escritura en el residuo—, en cambio, se desplaza con $\mathbf{R}$: el subgrupo ortogonal del gauge la conserva, y es la parte no ortogonal de $\mathbf{R}$, presente en toda transformación genérica, la que la mueve. Aplicando ese gauge sobre el modelo base afinado, sin reentrenar, se mide qué lee cada método (forward y firmas en fp64): la salida no cambia —error relativo $\leq 2 \times 10^{-13}$ en las 420 combinaciones de capa $\times$ semilla $\times$ fuerza—, pero la separación entre las $\mathbf{v}_1(\mathbf{W}_O)$ —la cantidad que la poda por redundancia compara— se desplaza, mientras la firma del circuito OV —su primer vector singular, por SVD exacta— permanece doce órdenes de magnitud por debajo ($\leq 4,2 \times 10^{-13}$), en el suelo de la doble precisión.

El desplazamiento de $\mathbf{v}_1(\mathbf{W}_O)$ no es el accidente de una transformación concreta: crece con la magnitud del gauge $\delta_{\mathbf{R}}$ y satura hacia la ortogonalización —de 0,05 con una $\mathbf{R}$ apenas distinta de un múltiplo de la identidad, sube por 0,35 y 0,66, y se asienta en $\sim 0,83$ (por debajo del 0,90 del azar uniforme en su espacio fila: la saturación conserva estructura residual) desde $\delta_{\mathbf{R}} \approx 1$ —, mientras la del circuito OV se queda en $\sim 3 \times 10^{-13}$ sea cual sea la fuerza (tabla 4). No es “un gauge la mueve”, sino “todo gauge genérico —fuera de una subvariedad de medida nula que contiene a $\{c\mathbf{Q}\}$ y al estabilizador puntual de cada $\mathbf{W}_O$ — la mueve, y ninguno mueve el circuito”. Es la demostración de forma cerrada de que leer o reorganizar $\mathbf{v}_1(\mathbf{W}_O)$ —poda por redundancia, interpretación por dirección dominante, routing por vector representativo— opera sobre ruido de gauge. Y hace plausible la inercia del regularizador de sección 7.4 —que optimiza ese mismo objeto no identificable—, sin demostrarla: que una intervención sobre él no mueva la similitud funcional por ninguna vía indirecta es un hecho empírico, medido aparte, no una consecuencia del gauge.

Tabla 4: Premisa, gauge-flip valor-salida sobre el modelo base, sin reentrenar y en fp64 (media $\pm$ desviación entre las 60 combinaciones de 5 semillas $\times$ 12 capas por fuerza). La deriva es $1 - |\cos|$ medio entre la firma antes y después del gauge. La primera columna, $\delta_{\mathbf{R}}$, no es una norma: mide la desviación media de $\mathbf{R}$ respecto a su mejor múltiplo escalar de la identidad, y es el mando de fuerza del gauge (crece al alejarse de la familia escalar); la segunda columna es la distancia de la ecuación (2) a la clase inocua, que es la que la teoría nombra. La única clase que deja $\mathbf{v}_1$ invariante para toda $\mathbf{W}_O$ es la conforme ortogonal $\{c\mathbf{Q}\}$, de medida nula en $GL(d_h)$ y nunca alcanzada por el muestreo. La deriva de $\mathbf{v}_1(\mathbf{W}_O)$ crece con la fuerza del gauge. La del circuito OV no: permanece en el suelo de la doble precisión, doce órdenes de magnitud por debajo, constante e independiente de la fuerza. Las dos últimas columnas materializan a cada fuerza la decisión de poda por $\mathbf{v}_1(\mathbf{W}_O)$ —par más redundante y conjunto top-3— sobre esas mismas 60 combinaciones: fracción en que el par cambia respecto a la decisión sin gauge y solape medio del top-3. El protocolo es el de esta tabla —una $\mathbf{R}$ por capa y fuerza—, distinto del de la tabla 5, que agrega cinco réplicas por capa a $\delta_{\mathbf{R}} \approx 1$ y reporta allí 92,7 %. Aquí esa fuerza satura en 1,00, las 60 de 60.

$\delta_{\mathbf{R}}$	$d(\mathbf{R})$ (ec. 2)	Error salida	Deriva $\mathbf{v}_1(\mathbf{W}_O)$	Deriva circuito OV	Cambia el par	Solape top-3
0,06	$0,044 \pm 0,000$	$1,1 \times 10^{-15}$	$0,05 \pm 0,04$	$2,9 \times 10^{-13}$	$0,03 \pm 0,08$	$0,91 \pm 0,04$
0,13	$0,088 \pm 0,000$	$1,1 \times 10^{-15}$	$0,15 \pm 0,09$	$2,9 \times 10^{-13}$	$0,13 \pm 0,05$	$0,91 \pm 0,03$
0,25	$0,172 \pm 0,001$	$1,1 \times 10^{-15}$	$0,35 \pm 0,16$	$2,9 \times 10^{-13}$	$0,42 \pm 0,00$	$0,76 \pm 0,03$
0,50	$0,313 \pm 0,001$	$1,1 \times 10^{-15}$	$0,66 \pm 0,15$	$2,9 \times 10^{-13}$	$0,58 \pm 0,06$	$0,49 \pm 0,06$
1,00	$0,471 \pm 0,002$	$8,0 \times 10^{-15}$	$0,83 \pm 0,04$	$2,9 \times 10^{-13}$	$1,00 \pm 0,00$	$0,33 \pm 0,06$
2,00	$0,525 \pm 0,002$	$8,5 \times 10^{-15}$	$0,83 \pm 0,05$	$2,9 \times 10^{-13}$	$0,93 \pm 0,04$	$0,28 \pm 0,07$
4,05	$0,531 \pm 0,002$	$2,9 \times 10^{-14}$	$0,82 \pm 0,07$	$2,9 \times 10^{-13}$	$0,95 \pm 0,05$	$0,28 \pm 0,05$

La misma rejilla responde con qué gauge se rompe la decisión, y no solo cuánto deriva la dirección. Materializada a cada fuerza la poda que la práctica ejecuta, el par más redundante

cambia en el 3,3 % de las 60 combinaciones a $\delta_{\mathbf{R}} = 0,06$ y ya en el 13,3 % a $\delta_{\mathbf{R}} = 0,13$. El prerregistro de esta curva esperaba estabilidad —par cambiado en menos del 5 %— hasta esa fuerza; el 13,3 % la rebasa y la expectativa no se cumple. Se reporta como tal. El 40 % se cruza en $\delta_{\mathbf{R}} = 0,25$ (41,7 %) y la saturación llega a $\delta_{\mathbf{R}} = 1$, donde ninguna de las 60 conserva su par. La lectura no es que toda perturbación del gauge rompa la decisión: la clase conforme ortogonal, que deja $\mathbf{v}_1$ exactamente invariante, tiene entorno, y en el extremo débil de la rejilla la decisión sobrevive —continuidad de los vectores singulares con hueco positivo—, aunque el radio certificado sobre la órbita sea nulo (proposición 1). Es que ese entorno es estrecho: por debajo de $\delta_{\mathbf{R}} \approx 0,1$, con $\mathbf{R}$ a menos de una décima de su desviación de la familia escalar, y a fuerza plena la decisión no conserva nada. En las dos fuerzas mayores la fracción afloja a 0,93 y 0,95 sin volver a 1. Con 66 pares por capa, el suelo de coincidencia por azar deja del orden de una combinación estable de 60, y lo observado queda por encima de ese suelo, cerca. Se reporta sin corregir.

La proposición 1 se certifica además par a par sobre los pesos reales (apéndice A): en las cinco semillas, el suelo de la órbita —el primer ángulo principal entre espacios fila— baja hasta $14,7^\circ$ según el par, el umbral del simplex $\theta^* = 84,78^\circ$ cae dentro del rango alcanzable de los 3960 pares medidos (66 pares $\times$ 12 capas $\times$ 5 semillas), y un descenso restringido a los espacios fila encuentra, en las 60 combinaciones capa $\times$ semilla, una configuración conjunta de las doce direcciones con $\theta_{\min} \geq \theta^*$ (peor caso $84,79^\circ$). El cumplimiento *total* del regularizador está, por tanto, en la órbita de gauge: existe un camino de coste funcional exactamente cero hacia él. Todo ángulo observado entre direcciones dominantes es un punto de un rango de decenas de grados que el gauge recorre con la función fija. El valor concreto es elección de gauge, no función. Cuánto de esa elección la fija el entrenamiento por su cuenta, y si basta, lo mide la sección 7.3.

7.2. La decisión de poda bajo gauge: visión y lenguaje

La deriva no es abstracta: la decisión que la práctica tomaría cambia bajo el gauge. Materializando las dos decisiones típicas —el par de cabezas más redundante y el conjunto de poda top-3 por redundancia media— sobre cada capa y semilla, y aplicando cinco gauges por capa a la fuerza saturada ($\delta_{\mathbf{R}} \approx 1$), la decisión por $\mathbf{v}_1(\mathbf{W}_O)$ cambia de par, bajo reparametrización genérica, en el 92,7 % de los casos y conserva de media 0,38 del top-3 (por capa, entre 0,24 y 0,69). La misma decisión tomada con la firma de respuesta gauge-invariante no cambia de par en ningún caso y conserva el top-3 completo (tabla 5). Dos modelos funcionalmente idénticos podan, con el criterio de pesos, conjuntos distintos de cabezas.

La inestabilidad no es propiedad de la visión ni del afinado: se reproduce, por la misma forma cerrada y sin entrenar nada, sobre un transformer de lenguaje preentrenado. Sobre Pythia-410M (Biderman et al., 2023) (GPT-NeoX, 24 capas, 16 cabezas, atención multi-cabeza pura) el mismo gauge valor-salida, a presupuesto de poda equivalente ($k=4$ de 16, el mismo 25 % relativo que el top-3 de 12 del ancla), cambia el par más redundante en el 90,0 % de los casos y conserva 0,379 del conjunto de poda (tabla 5) —un solape comparable al 0,378 del ancla: la misma forma cerrada rompe la decisión en grado comparable en dos modalidades y dos arquitecturas—. La firma de respuesta exige forwards con probe y no se porta a esta columna. La comparación se limita al criterio de pesos.

7.3. El gauge que el entrenamiento elige, y hasta dónde llega

Las dos medidas de esta subsección no estaban en el diseño original (sección 6). Se prerregistraron durante la revisión de este trabajo, con estadístico, agregación y umbrales fijados por escrito antes de ejecutar nada, para responder por anticipado a la objeción más fuerte contra la proposición 1. La objeción es esta. El *weight decay* —desacoplado en el optimizador que se usa (tabla 3)— ejerce presión hacia factores de menor norma de Frobenius, y el mínimo de esa norma sobre la órbita a circuito fijo es la factorización balanceada (lemma 1), única salvo el subgrupo ortogonal —bajo el cual, por sección 3, $\mathbf{v}_1(\mathbf{W}_O)$ es invariante—. Bajo balance exacto se tiene además $\mathbf{v}_1(\mathbf{W}_O) = \mathbf{v}_1(\mathbf{W}_v \mathbf{W}_O)$: el proxy leería el objeto identificable y la no-identificabilidad, cierta como

Tabla 5: Decisión bajo gauge, sin reentrenar. ViT-B: 5 semillas $\times$ 12 capas $\times$ 5 gauges a $\delta_{\mathbf{R}} \approx 1$ ($d(\mathbf{R})$ de la ecuación (2) entre 0,468 y 0,476), top-3 de 12 (25 %). Pythia-410M: 24 capas $\times$ 5 gauges a la misma fuerza saturada, top-4 de 16 (mismo 25 % relativo; columna congelada, un único checkpoint). La firma de respuesta no se mide en la columna de lenguaje (exige forwards con probe, fuera de alcance). Fracción de casos en que cambia el par más redundante y solape medio del conjunto de poda con la decisión sin gauge, por criterio. Umbrales fijados antes del dato: pesos inestable si el par cambia en ≥ 40 % o el solape medio $< 0,67$; firma estable si el solape $\geq 0,95$ y el par cambia < 5 %. La estabilidad declarada de la firma es frente al gauge. Su sensibilidad frente al muestreo del probe se acota y mide en el lemma 2.

Arquitectura	Criterio	Par cambia (%)	Solape top- k
ViT-B/16 (ancla, $k=3$)	$\mathbf{v}_1(\mathbf{W}_O)$ (pesos)	92,7	0,378
ViT-B/16 (ancla, $k=3$)	Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	0,0	1,000
Pythia-410M (lenguaje, $k=4$)	$\mathbf{v}_1(\mathbf{W}_O)$ (pesos)	90,0	0,379
Pythia-410M (lenguaje, $k=4$)	Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	no medido	no medido

imposibilidad de peor caso, sería inocua en la práctica. Si el entrenamiento elige un gauge casi canónico, la proposición 1 no mordería donde importa. Es una hipótesis medible, y se mide.

Antes se fija un objeto que hasta aquí no hacía falta. El *invariante estático* (*static invariant*) $\mathbf{v}_1(\mathbf{W}_v^{(h)} \mathbf{W}_O^{(h)})$ es la dirección dominante del circuito OV, calculada sobre los pesos y sin dato alguno. No es la firma de respuesta $\mathbf{v}_1(\mathbf{C}_h^P)$, que es el instrumento del trabajo y sí requiere el paso de los parches. Ambas son invariantes de gauge, pero solo la segunda mide cuanto la cabeza computa. Esta subsección compara la lectura por pesos contra el invariante estático, porque es el término exacto de la objeción: si el gauge fuera canónico, esos dos coincidirían.

El entrenamiento canoniza: el alineamiento mejora de forma monótona entre los tres estados observados. La canonización (*canonicalization*) de la que se habla aquí es acercarse al punto donde el proxy coincidiría con el invariante. Por cabeza, capa y semilla se mide $\alpha_h = \angle(\mathbf{v}_1(\mathbf{W}_O^{(h)}), \mathbf{v}_1(\mathbf{W}_v^{(h)} \mathbf{W}_O^{(h)}))$, que vale 0° bajo balance exacto y sobre toda la familia alineada que sigue al lemma 1, forma canónica QR incluida. En los checkpoints afinados la mediana es $35,20 \pm 2,11^\circ$ en ViT-B y $18,14 \pm 0,24^\circ$ en ViT-L, muy lejos del suelo de dos direcciones al azar, que depende de la dimensión del residuo ($88,5^\circ$ de mediana y $85,9^\circ$ de percentil 5 en $\mathbb{R}^{768}$; $88,8^\circ$ y $86,4^\circ$ en $\mathbb{R}^{1024}$). La objeción tiene, por tanto, base empírica: el gauge del entrenamiento no es adversario, se acerca al punto canónico. Un diagnóstico fuera del prerregistro lo sitúa en su trayectoria (tabla 6): α decrece entre los tres estados medidos, de $\sim 65^\circ$ en la inicialización a $\sim 40^\circ$ tras el preentrenamiento y a 35° o 18° tras el afinado. A escala ViT-L los dos regímenes de preentrenamiento canonizan a menos de un grado de distancia — $38,25^\circ$ el supervisado y $39,00^\circ$ el autosupervisado de DINOv2, que al estar congelado se queda ahí—, y es el afinado quien recorre el resto hasta 18° : la canonización del preentrenamiento denota propiedad del descenso más que del régimen. La del afinado queda medida solo en el régimen supervisado. La lectura de robustez, prerregistrada, descarta el artefacto numérico. Restringsida a las cabezas con hueco espectral (*spectral gap*) franco ($\sigma_1/\sigma_2 \geq 1,05$, algo más de la mitad), la mediana *baja* a $30,07 \pm 1,70^\circ$ y $13,94 \pm 0,65^\circ$: donde $\mathbf{v}_1$ está mejor definida, se alinea más.

Pero la canonización no alcanza a la decisión. La pregunta que importa es si esos grados cambian lo decidido, no cuántos quedan. Sobre el mismo checkpoint y sin inyectar ningún gauge, se materializan las dos decisiones de tabla 5 —par más redundante y conjunto de poda del 25 % por redundancia media— con dos criterios: la lectura por pesos $\mathbf{v}_1(\mathbf{W}_O)$ y el invariante estático. El acuerdo resultante (tabla 7) está muy por encima del azar: el solape del top- k es 0,61 y 0,64 frente al 0,25 de elegir a ciegas, y el par coincide en el 63 % y el 56 % de las capas frente al 1,5 % y el 0,8 % del azar. Leer $\mathbf{v}_1(\mathbf{W}_O)$ en el gauge natural no es leer ruido. Y aun así el acuerdo queda por debajo del listón que este mismo trabajo fijó para llamar estable a una decisión —solape

Tabla 6: Alineamiento entre la lectura por pesos y el invariante estático, $\alpha = \angle(\mathbf{v}_1(\mathbf{W}_O), \mathbf{v}_1(\mathbf{W}_v \mathbf{W}_O))$, mediana sobre cabezas×capas (media $\pm$ desviación entre semillas; init y preentrenado son una sola realización y van sin banda). La quinta columna restringe la mediana a las cabezas con hueco espectral franco, sobre el estado medido de cada fila —afinado en las dos supervisadas, congelado en DINOv2—. Dos direcciones al azar dan $88,5^\circ$ en $\mathbb{R}^{768}$ y $88,8^\circ$ en $\mathbb{R}^{1024}$. El afinado acerca la lectura al objeto identificable sin llevarla a él. El estadístico primario es α y no el desbalance espectral δ por una razón que el propio control expone: en la inicialización δ_{forma} es *menor* (0,006) que tras entrenar (0,019) mientras α es *mayor* (65° frente a 40°). Dos matrices gaussianas independientes tienen espectros casi idénticos y bases sin relación alguna: δ mide el balance de los espectros, pero el balance que hace coincidir el proxy con el invariante exige además que las bases encajen, y eso solo lo ve α . Diagnóstico, fuera del prerregistro.

Columna	Init	Preentr.	Afinado	$\sigma_1/\sigma_2 \geq 1,05$	δ_{forma}
ViT-B/16 ($n=5$)	64,61	42,91	$35,20 \pm 2,11$	$30,07 \pm 1,70$	0,020
ViT-L/16 ($n=3$)	64,83	38,25	$18,14 \pm 0,24$	$13,94 \pm 0,65$	0,017
DINOv2 (ViT-L/14, $n=1$)	64,06	39,00	—	29,09	0,021

$\geq 0,67$ y par constante en al menos el 60 % de los casos—: en ViT-B falla por el solape (0,61), con el par en el límite (63 ± 13 %), y en ViT-L fallan los dos. El par más redundante difiere entre los dos criterios en el 37 % y el 44 % de las capas. El desalineamiento residual de 18 a 35° basta para corromper la decisión sin necesidad de tocar nada. El descriptor prerregistrado lo confirma en el sentido esperado: la correlación por capa entre α medio y solape es $-0,52$ y $-0,38$.

Tabla 7: Coincidencia entre la decisión por $\mathbf{v}_1(\mathbf{W}_O)$ y la decisión por el invariante estático, en el gauge que el entrenamiento dejó y sin inyectar ninguno (media $\pm$ desviación entre semillas sobre capas×semillas). Umbrales heredados de tabla 5, fijados antes de que esta medida existiera. Complementa a tabla 5: allí la decisión se rompe bajo reparametrización genérica. Aquí no coincide ni siquiera sin reparametrizar.

Columna	Solape top- k	Azar	Par coincide	Azar
ViT-B/16 ($k=3$ de 12)	$0,611 \pm 0,020$	0,25	$63,3 \pm 12,6$ %	1,5 %
ViT-L/16 ($k=4$ de 16)	$0,639 \pm 0,033$	0,25	$55,6 \pm 6,4$ %	0,8 %

Dos precisiones sobre el alcance de estas dos tablas. La primera: miden *acuerdo entre criterios*, no calidad de poda; qué cabezas podar es la pregunta de tabla 9, donde ninguna similitud —de pesos o de firma— bate al azar, y las dos preguntas no se mezclan. La segunda: que el acuerdo supere al azar no autoriza a leer $\mathbf{v}_1(\mathbf{W}_O)$ como aproximación utilizable del invariante. Un solape de 0,61 por debajo del listón propio no sostiene ninguna recomendación de uso. Sostiene lo contrario, que es una lectura cuya fiabilidad depende de un gauge que no se eligió a propósito. La contrapartida funcional de esa lectura —qué ocurre cuando se *interviene* sobre ese objeto en vez de leerlo— es el asunto de la sección 7.4, y allí la inercia se mide también sobre la salida del modelo.

7.4. El regularizador sobre $\mathbf{W}_O$ separa sin coste funcional detectable

El portador de pesos es la dirección representativa $\mathbf{v}_1(\mathbf{W}_O^{(h)})$, el primer vector singular derecho de la proyección de salida, y el regularizador es el de ecuación (7) sobre ese portador. El afinado por sí solo separa las cabezas solo parcialmente: $\theta_{\min}$ se estanca en $51,96^\circ$, muy por debajo del umbral del simplex ($\theta^* = 84,78^\circ$). El estancamiento no denota obstrucción de empaquetamiento: con $K=12 \leq d=768$ el óptimo sin signo es el marco ortogonal a 90° , con 756 dimensiones de holgura, y el intervalo admisible $|\cos| \leq 1/11$ es enorme. Es un certificado de no-obstrucción, y el $51,96^\circ$ pasa de dato bruto a evidencia dirigida. El regularizador blando conduce esa separación a $85,01^\circ$ —rebasa el umbral y sigue derivando hacia el marco ortogonal— y reduce la redundancia

angular de 0,172 a 0,034, con una caída de exactitud de 0,10 pp que queda *dentro* de la banda de top-1 entre semillas de la base (0,19 pp): eso, y no un cero nominal, es sin coste. La variante dura, que reprojeta tras cada paso sobre el simplex, queda anclada a él (84,77°) —por debajo de la blanda, que sin código alguno lo rebasa: la bisagra deriva libremente hacia el marco ortogonal mientras la reprojcción la fija a una configuración subóptima— y paga 4,40 pp —uniforme entre semillas (rango 0,86 pp), 23 veces la banda— y desestabiliza la exactitud dentro de cada corrida (desviación intra-corrida 0,0022 frente a 0,0013 de base). La blanda no solo iguala a la dura en separación, la supera en de-correlación. La tabla 8 recoge el estado final.

El patrón se repite en la columna profunda: la dura paga 5,6 pp —uniforme entre semillas— y desplaza $s_{\text{func}} +0,031$, 31,8 veces la banda base de ViT-L, mientras la blanda alcanza el mismo $\theta_{\text{mín}}$ sin coste medible. El desplazamiento de la dura conserva signo y orden de magnitud entre arquitecturas. El de la blanda los invierte y permanece en el ruido.

Sobre s_{func} , el corazón de H1: el desplazamiento entre variantes es del orden de la dispersión entre semillas ($\Delta = +0,0013$, IC del 95 % $[-0,0052, +0,0077]$, que incluye el cero; t de Student con 4 grados de libertad sobre las diferencias pareadas por semilla), sin separación detectable de cero en cinco réplicas, con un posible sesgo de signo menor que esa dispersión. El resultado es una *cota*, no una nulidad. Su análisis de sensibilidad: la banda completa de s_{func} base entre semillas es 0,0041, inflada por dos corridas atípicas (una alta, una baja, de signos opuestos). El núcleo sin ellas es 0,0017. El efecto (0,0013) queda dentro de ambas medidas, y la lectura pareada por semilla coincide con la lectura contra la media de las base salvo en las dos semillas atípicas —el doble pareo que las detecta—, de modo que efecto, ruido entre semillas y ruido de corrida son del mismo tamaño y ninguno se separa. La dura, en cambio, *no* deja s_{func} quieto: lo desplaza $+0,052$ al alza —12,8 veces la banda, uniforme en las cinco semillas—, es decir, los mapas de atención se vuelven *más* parecidos entre cabezas mientras la geometría de pesos queda máximamente separada. La asimetría es ella misma un resultado: dos mecanismos —gradiente sobre la penalización uno, reprojcción forzada sin retropropagación el otro— alcanzan una separación mínima comparable (0,23° de diferencia) con configuraciones globales distintas —redundancia 0,034 frente a 0,091—, y uno no produce coste detectable mientras el otro arrastra la función. La inercia que H1 establece es la de la *sonda de gradiente* a la intensidad fijada, no la de cualquier manipulación de esa geometría: forzar los pesos fuera de la trayectoria del optimizador paga en exactitud y mueve la similitud funcional. Detalle numérico de la sonda blanda: el gradiente de la SVD se degrada cerca de la convergencia. $\theta_{\text{mín}}$ satura hacia la época 6 pero s_{func} deriva hasta la época ~ 25 y se estabiliza después (desviación época a época 0,0007), y por eso las métricas se extraen de la ventana convergida (sección 6).

Tabla 8: Premisa, parte I: ablación del regularizador angular sobre la geometría de $\mathbf{W}_O$ (ImageNet-100 limpio, 30 épocas, media $\pm$ desviación entre 5 semillas; valores por corrida promediados sobre la ventana convergida). $\theta_{\text{mín}}$ es la separación angular mínima sin signo entre direcciones representativas, por capa y reportada como media entre capas (umbral 84,78°); la redundancia es angular ($|\cos|$ medio entre direcciones). La blanda separa con coste dentro de la banda entre semillas ($0,10 < 0,19$ pp) y desplazamiento de s_{func} acotado por esa misma dispersión. La dura clava el código pagando 4,40 pp y moviendo $s_{\text{func}} +0,052$ al alza: dos mecanismos, misma separación mínima, configuraciones globales distintas, y solo uno paga.

Configuración	$\theta_{\text{mín}} \uparrow$	Redundancia $\downarrow$	Top-1 $\uparrow$	s_{func}
Base ($\lambda_A = 0$)	$51,96^\circ \pm 0,26$	$0,1724 \pm 0,0030$	$0,9284 \pm 0,0019$	$0,6945 \pm 0,0041$
Blanda ($\lambda_A = 10^{-3}$)	$85,01^\circ \pm 0,08$	$0,0338 \pm 0,0009$	$0,9274 \pm 0,0017$	$0,6958 \pm 0,0028$
Dura (reprojec- ción)	$84,77^\circ \pm 0,00$	$0,0909 \pm 0,0000$	$0,8844 \pm 0,0021$	$0,7466 \pm 0,0049$

La inercia, medida en la salida. La similitud funcional s_{func} compara mapas de atención, y $\mathbf{A}_h = \text{softmax}(\mathbf{Q}\mathbf{K}^\top)$ no contiene a $\mathbf{W}_O$ por vía directa: una intervención sobre $\mathbf{W}_O$ podría quedar inerte ahí por construcción y no por sustancia. La objeción se cierra midiendo donde el modelo se juega la función. Sobre el conjunto sonda congelado se compara la divergencia de Kullback-Leibler entre las distribuciones de salida de la corrida base y la blanda de la *misma* semilla, contra el rango que produce cambiar de semilla en la propia base, y con la variante dura como control positivo. En ViT-B la divergencia pareada base-blanda es 0,118 nats de media por imagen, por debajo del mínimo del rango entre semillas ($[0,121, 0,157]$, $n=20$): la sonda blanda perturba la salida menos que cambiar la semilla de entrenamiento. En tres de las cinco semillas eso vale individualmente. En ViT-L la divergencia pareada es 0,185 frente a un rango de $[0,169, 0,201]$: dentro del ruido, en su centro, no por debajo. La variante dura sale de ese rango en ambas columnas (0,253 y 0,308), de modo que el instrumento sí distingue una intervención dañina cuando la hay. La divergencia tiene cola larga y por eso viajan las dos cifras: la mediana por imagen es 0,0025 frente a 0,0038 del rango y 0,0115 del control en ViT-B, un orden por debajo de la media en los tres casos. La deriva de la firma de respuesta base→blanda queda igualmente dentro de su rango entre semillas (0,194 frente a un techo de 0,223 en ViT-B; 0,359 frente a 0,394 en ViT-L). La inercia de la sonda blanda, por tanto, no es un artefacto de mirar solo los mapas de atención: se sostiene en los logits, con la asimetría blanda/dura reproducida en un canal que s_{func} no ve.

La inercia queda establecida más arriba, a la intensidad fijada $\lambda = 10^{-3}$: $\theta_{\text{mín}}$ satura sin que s_{func} descienda del nivel base. Caracterizar la dependencia con λ sobre un rango más amplio queda como extensión, y exigiría el mismo aparato de lectura —cinco semillas por intensidad, contra el suelo de ruido entre semillas— que el apoyo a $\lambda = 10^{-3}$ ya consume. La cautela pertinente: a intensidad mucho mayor la sonda podría dejar de ser una perturbación inerte y empezar a deformar la representación, de modo que la indiferencia no se afirma fuera de la intensidad medida.

8. Discusión y limitaciones

Los tres brazos, leídos juntos. Gauge, sonda y variante dura no son tres resultados sueltos: caracterizan, en tres regímenes de intervención distintos por mecanismo, sobre el sector valor-salida, el acoplamiento entre esa geometría y la función. La intervención más libre —el gauge, que no toca la función por construcción— mueve la geometría al máximo sin coste; la intervención intermedia —la sonda, que sí entrena— también la mueve sin coste detectable a la intensidad medida; solo la más agresiva —la variante dura, que impone el simplex en cada paso— paga en función. El mismo sector, leído sin intervenir en él, completa la escala por su extremo nulo (sección 7.3). Que el daño aparezca justo donde la intervención dejó de ser un gauge y empezó a ser una restricción activa sobre la trayectoria del optimizador es el propio dato distinguiendo “reparametrización” de “manipulación”, no una lectura a posteriori. La asimetría conecta con la reubicación: si la función no habita $\mathbf{v}_1(\mathbf{W}_O)$, y la organización de la atención sí correlaciona con $\mathbf{Q}\cdot\mathbf{K}$ en el régimen afinado, la pregunta constructiva —qué componente gobierna la función, si no esa dirección— queda planteada, no respondida. La atribución por componente sobre $\mathbf{Q}\cdot\mathbf{K}$ es la continuación natural (sección 7.4 y apéndice B.1).

Qué afirma el resultado y qué no. La afirmación es negativa y acotada: la geometría de la proyección de salida — $\mathbf{v}_1(\mathbf{W}_O)$, la dirección que la poda por redundancia y la interpretación por dirección dominante leen— no es una representación funcionalmente identificable de la cabeza. No es identificable bajo el gauge del sector valor-salida, separarla no produce cambio detectable en la similitud funcional, y la organización de la atención reside en otro sustrato. El trabajo no afirma lo contrario de eso: no sostiene que exista un portador de pesos accionable, ni que $\mathbf{Q}\cdot\mathbf{K}$ sea el único sustrato de la función —esa lectura es correlacional—, ni que la firma de respuesta agote la diversidad disponible. Intervenir de forma constructiva sobre $\mathbf{Q}\cdot\mathbf{K}$, o sobre la firma de respuesta, es la continuación natural, no un resultado de este trabajo.

Implicaciones para la poda y la interpretación. Una parte de la poda de cabezas decide la redundancia comparando direcciones representativas de $\mathbf{W}_O$, y una parte de la interpretación mecanicista lee el papel de una cabeza desde su dirección dominante de pesos. La sección 7.1 muestra que esas comparaciones operan sobre una cantidad no identificable: dos modelos funcionalmente idénticos exhiben separaciones distintas entre sus $\mathbf{v}_1(\mathbf{W}_O)$ según el gauge, de modo que la redundancia angular medida sobre pesos es, en parte, un artefacto de reparametrización, y la decisión que produce cambia de hecho bajo gauge (tabla 5). La firma de respuesta gauge-invariante (sección 4) ofrece la cantidad que esas tareas necesitan como *medida*: diversidad de cabezas anclada al circuito identificable, que no se mueve al reparametrizar y es específica de cada cabeza (apéndice B.2). Con una acotación medida: estabilidad no es criterio de selección —ninguna similitud, de gauge o funcional, bate al suelo aleatorio como regla de poda a presupuesto fijo (tabla 9). Decidir *qué* podar sigue pidiendo criterios de importancia como los de segundo orden (Yang et al., 2023; Uddin et al., 2025), sobre los que este análisis no se pronuncia—.

La especialización no la captura la dirección dominante aislada de $\mathbf{W}_O$. Si las cabezas se especializan funcionalmente (Michel et al., 2019; Voita et al., 2019), los resultados sugieren que esa especialización se lee en el comportamiento computado y no en la dirección dominante de los pesos de salida. Si otra lectura de los pesos —el circuito, el subespacio, $Q \cdot K$ — la porta es pregunta abierta. Un trabajo vecino que regulariza la diversidad sobre los gradientes de entrada —señal ligada al comportamiento— altera la función y mejora la generalización OOD (Nicolicioiu et al., 2023), mientras que intervenir sobre la geometría de pesos no la mueve de forma detectable: el contraste sitúa el efecto en la señal funcional, no en el resumen estático de los pesos.

Límites. La no-identificabilidad es de forma cerrada y no depende de la arquitectura. La inercia y la reubicación viven en ella, y se contrastan por eso sobre tres columnas (tabla 2): dos escalas y profundidades a anchura por cabeza constante —ViT-B y ViT-L— y dos regímenes de entrenamiento —supervisado y autosupervisado, este último con DINOv2 congelado—. La invariancia de gauge, la decisión rota y los diagnósticos estáticos se reproducen en la columna autosupervisada. H1 no es aplicable sin entrenamiento y H3 no transfiere. La evidencia sobre inercia queda restringida a las dos columnas afinadas, y la reubicación al régimen afinado supervisado. El gauge que el entrenamiento elige se interroga igual en la columna congelada, donde el preentrenamiento autosupervisado también fijó uno. El borde declarado es la atención no-global: en Swin y la atención por ventana la no-identificabilidad sí transferiría —el gauge valor-salida es estructural—, pero el mapa local por ventana desplazada, el sesgo de posición relativa en los logits y la profundidad jerárquica por etapas obligan a rederivar s_{func} y la noción misma de profundidad antes de medir inercia o reubicación. Queda como extensión, no como agujero de rigor. La estabilidad exacta de la firma es frente al gauge; frente al muestreo del probe es materia finita, y la coincidencia del par entre mitades crece con el tamaño de la sonda sin saturar en la rejilla medida —de 10,4 a 11,4 sobre 12 capas entre $P=250$ y $P=5000$ (lemma 2)—: quien use la firma a un tamaño dado hereda esa sensibilidad, y la curva dice cuánta le queda. La lectura de la reubicación hacia $Q \cdot K$ es correlacional —Spearman entre s_{func} y candidatas geométricas por capa—, no causal, y la elección del primer vector singular de $\mathbf{C}_h^P$ como firma, frente a otros resúmenes de la respuesta, es una decisión de diseño cuyo contraste con el centrado por parche acota su sensibilidad sin agotarla. El listón del predominio profundo heredó de la ancla la asunción de que el último tercio de capas es homogéneo. ViT-L la rompe en su capa final, y la asunción queda declarada como límite del criterio, no corregida a posteriori.

8.1. La similitud no es un criterio de poda; la estabilidad sí es del instrumento

Un benchmark mínimo acota qué compra el instrumento y qué no. Con el mismo presupuesto ($k=2$ cabezas por capa, 24 de 144) y el mismo mecanismo de poda —anular las columnas de la cabeza en la proyección de salida—, se poda el conjunto más redundante según cada criterio y se mide la

caída de top-1 sobre el val completo (tabla 9). Ningún criterio de similitud bate al suelo aleatorio: la selección por pesos cae dentro del nulo aleatorio de cien sorteos por semilla ($3,13 \pm 0,54$ pp frente a una media de 2,89 pp, con percentiles 5 y 95 en 1,94 y 3,96; percentil 62 del nulo conjunto y bajo su percentil 5 en ninguna semilla) —coherente con que elegir por $\mathbf{v}_1(\mathbf{W}_O)$ es elegir por ruido de gauge—, y la selección por firma daña *más* que el azar ($4,26 \pm 0,29$ pp, percentil 97 del nulo y por encima de su percentil 95 en cuatro de cinco semillas, el criterio prerregistrado). El diagnóstico explica por qué: ambos criterios seleccionan cabezas de contribución grande al residuo ($2,7\times$ la energía media de las restantes), y las que la firma agrupa son además individualmente más costosas (podando media pareja cada vez, en la semilla 42, la suma de mitades ya es 3,72 frente a 2,90 pp en pesos, con superaditividad similar en ambos, $+0,8/+0,9$ pp). La similitud —de gauge o funcional— no equivale a redundancia prescindible: cabezas con firmas parecidas son centrales, no sobrantes. El enunciado aplicado, para la práctica, junta los dos certificados: la decisión por $\mathbf{v}_1(\mathbf{W}_O)$ no admite radio certificado positivo para ningún umbral admisible —el gauge la fabrica a voluntad (proposición 1 y tabla 5)— y la decisión por firma es invariante. Ninguna de las dos similitudes, sin embargo, selecciona qué podar mejor que el azar a este presupuesto. La ventaja del instrumento es la *decisión estable* bajo reparametrización, no la selección; qué podar exige criterios de importancia, fuera del alcance de este análisis.

Tabla 9: Poda por criterio, sin reentrenar (5 semillas base; $k=2$ cabezas por capa, 24 de 144; media $\pm$ banda entre semillas). El nulo aleatorio son cien sorteos por semilla, 500 en total; la media de los tres sorteos originales, 3,25 pp, se reproduce en 3,26 (fila de regresión: el 3,25 original). El mecanismo de poda es idéntico para todos los criterios. Ninguna similitud bate al nulo —criterio prerregistrado: caída bajo su percentil 5 en al menos cuatro de cinco semillas—, y la firma daña más que el azar en cuatro de cinco. El papel del instrumento es la estabilidad de la decisión, no la selección.

Criterio	Top-1 podado	Caída (pp)	Percentil en el nulo
$\mathbf{v}_1(\mathbf{W}_O)$ (pesos)	0,898	$3,13 \pm 0,54$	62
Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	0,887	$4,26 \pm 0,29$	97
Nulo aleatorio (100 sorteos)	0,900	$2,89 \pm 0,18$	p5 1,94, p95 3,96
Aleatorio, 3 sorteos (regresión)	0,896	$3,25 \pm 0,19$	—

El efecto práctico de este análisis es protector: identifica una lectura del espacio de pesos cuyas conclusiones cambian bajo reparametrizaciones que no tocan la función y la sustituye por una invariante. No introduce capacidades nuevas y emplea solo datos de referencia públicos.

9. Conclusión

La dirección dominante $\mathbf{v}_1(\mathbf{W}_O)$ —la que la poda por redundancia y la interpretación por dirección dominante leen— no es identificable bajo el gauge valor-salida. Su órbita es la esfera completa del espacio fila, y el gauge la desplaza —hasta 0,83 de deriva media en la ancla y 0,91 en ViT-L— mientras la salida y el circuito OV $\mathbf{W}_v\mathbf{W}_O$ permanecen en el suelo numérico de la doble precisión, invariancia que se verifica idéntica en las tres columnas, incluida la autosupervisada congelada. Ningún umbral de similitud sobre $\mathbf{v}_1(\mathbf{W}_O)$, dentro del rango que los espacios fila permiten, admite radio certificado positivo, y toda lectura de $\mathbf{W}_O$ sola invariante bajo el gauge factoriza por su espacio fila (corolario 1).

La consecuencia no es cautela: dos modelos funcionalmente idénticos podan conjuntos distintos de cabezas —el par más redundante cambia en el 92,7 % de los casos, bajo reparametrización genérica, sobre el ViT afinado y en más del 90 % sobre un transformer de lenguaje sin entrenar nada, y el solape del conjunto de poda cae a 0,378 en el ancla—, mientras la misma decisión tomada sobre la firma de respuesta permanece intacta. El criterio no elige *mal* qué podar: no está

bien definido sobre clases de equivalencia funcional.

En el gauge que el entrenamiento deja, la lectura por pesos se acerca al objeto identificable sin que la decisión coincida (sección 7.3). La cantidad que se está leyendo es la elección de gauge que el entrenamiento fija de forma sistemática pero insuficiente.

Para quien poda, interpreta o enruta por la geometría de $\mathbf{W}_O$, la firma de respuesta $v_1(C_h^P)$ —condicionada a la sonda, invariante bajo el gauge y específica de cada cabeza (apéndice B.2)— es la que ocupa su lugar, con la sensibilidad de muestra finita que el lemma 2 acota y la curva de sonda mide.

Los tres regímenes de intervención sobre el sector completan el cuadro como evidencia secundaria del desacoplamiento. Separar angularmente esa dirección hasta el umbral del simplex no produce coste funcional detectable a la intensidad medida: la sonda eleva $\theta_{\min}$ de 52° a 85° en la ancla y de 63° a 86° en la columna profunda, y el desplazamiento de s_{func} permanece del orden de la dispersión entre semillas en ambas, con el signo invertido entre ellas $+0,0013$ y $-0,0019$. El mismo criterio distingue el caso contrario: la variante dura, que impone el simplex por construcción, desplaza s_{func} $+0,052$ y $+0,031$ —12,8 y 31,8 veces la banda, mismo signo en ambas— al precio de 4,4 y 5,6 puntos de exactitud. La inercia de la sonda blanda no es, por tanto, incapacidad de la medida. La reubicación de la organización de la atención hacia $Q \cdot K$ con la profundidad queda acotada al régimen afinado supervisado —limpia en la ancla, sostenida y matizada en ViT-L, ausente en el DINOv2 congelado—, de modo que H3, tal como se prerregistró para las tres columnas, no se sostiene.

Disponibilidad de código y datos

El código de la sonda angular y todas las medidas, junto con la certificación de la órbita de gauge (apéndice A), está disponible en el repositorio abierto <https://github.com/mmunozpl/angular-separation-vit>, archivado de forma citable en Zenodo en <https://doi.org/10.5281/zenodo.21630534>. Los prerregistros de cada experimento (`prereg_*.md`) están en el repositorio con su commit de creación, anterior a toda ejecución: B1 y B2 (`b2fe055`, 26-08-2026); E0, E1 y E2 (`c7773e4`, 21-09-2026). Los CSV que respaldan cada tabla y figura de sección 7 se publican en <https://huggingface.co/datasets/ManPla/angular-separation-vit-results> (<https://doi.org/10.57967/hf/9743>), y los puntos de control de reproducción —por semilla y arquitectura— en <https://huggingface.co/ManPla/angular-separation-vit-checkpoints> (<https://doi.org/10.57967/hf/9742>). La demo interactiva de la órbita de gauge —la deriva de la dirección y la decisión de poda rota, sobre los pesos reales— se sirve en <https://huggingface.co/spaces/ManPla/angular-separation-vit-demo>.

Declaración sobre el uso de herramientas de IA

Claude (Anthropic) se usó como asistente de escritura y revisión metodológica durante la preparación de este manuscrito, y Claude Code como asistente en la escritura y la ejecución del código experimental. Los enunciados matemáticos y sus demostraciones, los diseños experimentales y sus prerregistros, y las conclusiones son del autor. Toda referencia citada se verificó contra su fuente primaria, y todo resultado numérico que se reporta procede de código que el autor ejecutó e inspeccionó. El autor asume la responsabilidad por la integridad, la exactitud y la originalidad de todo el contenido de este envío.

Financiación y conflictos de interés

Este trabajo no ha recibido financiación externa; el cómputo se realizó en equipo propio del autor. El autor declara no tener actividades financieras relacionadas fuera del trabajo enviado ni intereses en conflicto.

A. La órbita de gauge de $v_1(W_O)$, medida

Este apéndice certifica numéricamente la proposición 1 sobre los pesos reales de las cinco base de ViT-B, sin reentrenar y en CPU.

Banda por par. Para cada capa y cada par de cabezas (h, h') se computan los ángulos principales entre los espacios fila $\mathcal{S}_h$ y $\mathcal{S}_{h'}$ (SVD de $\mathbf{B}_h^\top \mathbf{B}_{h'}$ con $\mathbf{B}$ las bases ortonormales de fila). El primer ángulo principal es el suelo de la órbita conjunta —ningún gauge puede acercar las direcciones dominantes por debajo de él— y el techo es 90° (basta $d_h \geq 2$: dos vectores principales de índice distinto son ortogonales). Sobre 66 pares $\times$ 12 capas $\times$ 5 semillas: suelo mínimo global $14,7^\circ$, y $\theta^* = 84,78^\circ$ dentro del rango de los 3960 pares.

Realización explícita. Para un par por semilla se construye el gauge que lleva cada v_1 a su objetivo (el par de direcciones de mínimo ángulo entre los dos subespacios): la deriva del circuito OV queda en $\sim 2 \times 10^{-15}$ —invariancia a precisión de máquina— con las direcciones dominantes desplazadas decenas de grados.

Certificado simultáneo. El certificado por par no basta para el regularizador, que impone 66 restricciones acopladas sobre 12 direcciones. Un descenso restringido a los espacios fila —coordenadas libres en la base de cada $\mathcal{S}_h$, penalización sobre $|\cos| > 1/(H-1)$ — encuentra en las 60 combinaciones capa $\times$ semilla una configuración conjunta con $\theta_{\min} \geq \theta^*$ (peor caso $84,79^\circ$). El cumplimiento total del regularizador está en la órbita de gauge conjunta: existe un camino de coste funcional exactamente cero hasta él, y la inercia de la sección 7.4 es “no hubo cambio pese a existir un camino libre”, no “no se observó cambio”.

B. Más allá del sector valor-salida: dos diagnósticos correlacionales

Los dos diagnósticos de este apéndice son correlacionales y no se reprodujeron en las tres columnas del trío (sección 6). Se subordinan por ello al cuerpo del trabajo, que no depende de ellos. Acotan dónde vive la organización de la atención cuando la dirección dominante no la porta.

B.1. El sustrato de la atención se reubica hacia $Q \cdot K$ con la profundidad

Más allá de la no-identificabilidad de v_1 (sección 7.1), una caracterización por capa del modelo afinado muestra dónde reside la organización de la atención y por qué la geometría de $\mathbf{W}_O$ es inerte. Por cada capa se correlaciona la similitud funcional s_{func} —coseno entre mapas de atención promedio— con dos candidatas geométricas: el subespacio columna de $\mathbf{W}_O$ (similitud entre los espacios 768×64 por cabeza vía ángulos principales) y la interacción $Q \cdot K^\top$ (coseno entre los logits pre-softmax). La tabla 10 recoge ambas y la sola dirección dominante v_1 . La figura 1 las traza por capa con su banda entre semillas.

El patrón es una inversión. En las capas tempranas el subespacio de $\mathbf{W}_O$ correlaciona con la función mientras $Q \cdot K$ no. A partir de la capa 5 el orden se invierte y $Q \cdot K$ pasa a dominar, creciendo hasta $\sim 0,9$ en las profundas. El cruce $r_{Q \cdot K} > r_{\mathbf{W}_O\text{-subesp.}}$ ocurre en la capa 5 en las cinco semillas, con $Q \cdot K$ encendiéndose de forma brusca entre la capa 4 y la 5 ($r_{Q \cdot K}$ de 0,026 a 0,51). La inversión es asimétrica — $Q \cdot K$ pasa de ≈ 0 a $\approx 0,9$ mientras $\mathbf{W}_O$ estaba apenas por encima del ruido— e independiente del regularizador: bajo la variante blanda el cruce permanece en la capa 5 y $r_{Q \cdot K}$ es indiferente a la regularización (máximo $|\Delta| = 0,043$). La dirección dominante v_1 que el regularizador de pesos toca no participa del cruce: es baja o negativa en diez de las doce capas, traza función solo en la transición de las capas 3–4. Esa traza es real en el gauge que el entrenamiento fijó, pero no identificable (sección 7.1): otro gauge la borraría sin tocar la función,

de modo que no contradice la no-identificabilidad de v_1 —la ilustra, es el punto mismo de que la lectura por v_1 depende del gauge—. Esta es la razón medida de la inercia: el regularizador de pesos optimiza un objeto que no gobierna la organización de la atención.

Sobre ViT-L ($n=3$, 24 capas) el cruce sostenido existe en las tres semillas —capas 8, 11 y 8, a profundidad relativa del 33 al 46 %, comparable al 42 % de la ancla— y supera dos de los tres listones: el salto en la capa del cruce es +0,403 (listón $\geq 0,30$) y el margen +0,366 (listón $\geq 0,15$). El predominio profundo queda en +0,375, por debajo del listón $\geq 0,40$, y el desenlace conjuntivo es en consecuencia ambiguo. El diagnóstico señala una causa localizada: la capa 23 arrastra el mínimo en las tres semillas —+0,43, +0,41 y +0,28— mientras las capas 16 a 22 lo superan en todas (+0,61 a +0,63). En la ancla el último tercio no presentaba esa caída. La capa final no se excluye del cómputo del listón, fijado antes del dato. Se reporta el listón como salió y su causa junto a él.

La reubicación *no* transfiere a la columna congelada. Sobre DINOv2 (24 capas, un único checkpoint), los listones fijados antes del dato fallan en tres de cuatro: el cruce sostenido solo aparece desde la capa 22, con un salto de +0,223 en ese punto, el margen es +0,009 (listón $\geq 0,15$, falla) y el predominio profundo no existe —mínimo $r_{Q \cdot K}$ del último tercio −0,059 frente al listón $\geq 0,4$, falla—: en el backbone autosupervisado puro, $r_{Q \cdot K}$ no despega en ningún tramo de profundidad. H3, tal como se prerregistró para las tres columnas, no se sostiene en el régimen congelado.

La reubicación queda así acotada al régimen afinado supervisado: limpia en la ancla, sostenida y matizada en la columna profunda, ausente en la congelada. H3, prerregistrada como reproducible en las tres columnas, no se sostiene en esos términos.

Tabla 10: Premisa, parte II: correlación de Spearman entre s_{func} y dos candidatas geométricas, por capa (variante base, media entre 5 semillas; $r_{Q \cdot K}$ no depende de k). El subespacio se mide a $k = 64$. v_1 es la sola dirección dominante. El baseline aleatorio del subespacio a $k = 64$ es $\approx 0,25$; el de $Q \cdot K$, ≈ 0 . El cruce hacia $Q \cdot K$ en la capa 5 marca dónde la organización deja la escritura residual y pasa a la comparación consulta-clave.

Capa	r_{W_O} (subesp.)	$r_{W_O} (v_1)$	$r_{Q \cdot K}$
0	+0,439	+0,185	−0,104
1	+0,456	+0,075	+0,189
2	+0,503	+0,094	+0,233
3	+0,470	+0,463	+0,212
4	+0,341	+0,223	+0,026
5	+0,150	−0,005	+0,510
6	+0,176	−0,096	+0,296
7	+0,069	+0,038	+0,720
8	+0,058	−0,168	+0,811
9	−0,198	−0,313	+0,907
10	−0,041	−0,340	+0,770
11	+0,089	−0,108	+0,832

B.2. Identidad de cabeza entre mitades de la sonda

La especificidad por cabeza de la firma se prueba aquí sin $v_1(W_O)$, con un estadístico gauge-invariante prerregistrado (prereg_E2_identidad.md): sobre las dos mitades de la sonda se re-computa la firma de cada cabeza con el mismo código del lemma 2, se forma por capa la matriz $M_{hh'} = |\langle \mathbf{r}_h^{(A)}, \mathbf{r}_{h'}^{(B)} \rangle|$ y se lee la tasa de identificación (*identification rate*): la fracción de cabezas cuya firma en la mitad A tiene por vecina más cercana su propia firma en la mitad B. El nulo son mil permutaciones de las etiquetas de la mitad B por capa, con esperanza $1/H$. El veredicto




Figura 1: Premisa, parte II (visual de tabla 10): correlación de Spearman entre s_{func} y las candidatas geométricas por capa, media entre 5 semillas; las barras son ± 1 desviación típica. El subespacio de $\mathbf{W}_O$ ($k=64$) correlaciona en las tempranas y se hunde con la profundidad. $Q \cdot K$ arranca en el ruido, se enciende de forma brusca en la *costura* de la capa 5 ($0,026 \rightarrow 0,51$) y domina hasta $\sim 0,9$. La $Q \cdot K$ de la variante blanda (punteada) cae sobre la base: el cruce no depende del regularizador de pesos. Las líneas de puntos marcan los baselines aleatorios ($\approx 0,25$ el subespacio, ≈ 0 para $Q \cdot K$).

prerregistrado exige que la tasa media sobre capas supere el percentil 99 del nulo en las cinco semillas.

Se cumple con holgura (tabla 11). A $P=1000$ con mitades balanceadas por clase la tasa media es $0,993 \pm 0,007$ frente a un percentil 99 del nulo de 0,333, en las cinco semillas y con las doce capas por encima de 10/12; con asignación óptima entre cabezas la tasa es 1,000 en toda capa y semilla. La curva secundaria en P va de 0,981 a $P=250$ a 0,999 a $P \geq 2000$. Con las mitades por bloques de clases de la sonda publicada —la partición más adversa, que separa clases enteras— la tasa baja a $0,957 \pm 0,006$ y el descenso se concentra en las capas 10 y 11 (0,77 y 0,80), donde la firma es la que más depende de la composición por clases. La segunda parte de la expectativa no se cumple: las capas en que la decisión de poda discrepa entre mitades en la curva de sonda —la 3, con dos de cinco semillas coincidentes, y la 2 y la 7— no son las de menor tasa, que son la 11, la 2 y la 8, y con la tasa en 1,000 en nueve de las doce capas el orden entre capas no es informativo. La prueba establece la parte que el cuerpo necesita: la firma de cada cabeza se reconoce a sí misma a través de la sonda, y que la decisión de poda cambie entre mitades en algunas capas es sensibilidad del *par más redundante* a un margen pequeño (lemma 2), no confusión entre cabezas.

Tabla 11: Identidad de cabeza entre mitades de la sonda (5 semillas del ancla; media $\pm$ banda). Tasa de identificación con mitades balanceadas por clase a $P=1000$, tasa con asignación óptima, percentil 99 del nulo de permutación (esperanza 1/12) y tasa con las mitades por bloques de clases de la sonda publicada.

Capa	Tasa (por clase)	Óptima	p99 nulo	Tasa (bloques)
0	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
1	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
2	$0,983 \pm 0,037$	1,000	0,333	$0,983 \pm 0,037$
3	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
4	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
5	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
6	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
7	$1,000 \pm 0,000$	1,000	0,333	$1,000 \pm 0,000$
8	$0,983 \pm 0,037$	1,000	0,333	$0,967 \pm 0,046$
9	$1,000 \pm 0,000$	1,000	0,333	$0,967 \pm 0,046$
10	$1,000 \pm 0,000$	1,000	0,333	$0,767 \pm 0,091$
11	$0,950 \pm 0,046$	1,000	0,333	$0,800 \pm 0,095$

B.3. El portador de residuo se inclina del inerte sin desligarse

La firma de respuesta gauge-invariante (sección 4) se define sobre la contribución al residuo, no sobre $\mathbf{v}_1(\mathbf{W}_O)$. Un diagnóstico previo, sin reentrenar, mide cuánto se separan. Por capa se compara la firma computada $\mathbf{v}_1(\mathbf{A}_h \mathbf{V}_h \mathbf{W}_O)$ de cada cabeza con su firma estática $\mathbf{v}_1(\mathbf{W}_O)$ —el ángulo *emparejado*—, contra el nulo de permutación —la firma computada de h frente a la estática de $h' \neq h$ —. Ambas viven en el espacio fila de $\mathbf{W}_O$, de 64 dimensiones, de modo que el azar es la permutación dentro de ese subespacio, no el de $\mathbb{R}^{768}$. Ambas firmas se calculan por SVD exacta.

El ángulo emparejado queda en todas las capas por debajo del nulo y nunca en cero (tabla 12): la firma computada se inclina de verdad respecto a la estática —el contenido valor/atención la mueve, el portador de residuo no colapsa sobre el inerte, que era la condición go/no-go— pero sigue siendo más parecida a su propia cabeza que a las demás, es decir, específica de cada cabeza. La brecha se modula con la profundidad —de 24° en la capa 1 a 39° en la 2— con dos irregularidades reproducibles entre semillas: en la capa 8 el nulo cae a 73,1° frente a los $\sim 86^\circ$ del resto —las direcciones estáticas $\mathbf{v}_1(\mathbf{W}_O)$ de cabezas distintas se parecen entre sí ahí— y en la capa 11 emparejado y nulo caen juntos (23,5° y 51,9°), con todo el patrón desplazado hacia abajo. Ambas son propiedades de la firma estática en el gauge que el entrenamiento fijó —no identificables, como toda lectura por $\mathbf{v}_1(\mathbf{W}_O)$ (sección 7.1)—, de modo que se nombran como rasgos del diagnóstico, no como redundancia ni convergencia funcional. Es un diagnóstico del portador, no la inversión de apéndice B.1, y se reporta como tal.

Tabla 12: Diagnóstico computado/estático del portador de residuo, sin reentrenar (media $\pm$ desviación entre 5 semillas, conjunto congelado de 1000 imágenes). Ángulo emparejado (firma computada de h vs estática de h) frente al nulo de permutación (vs estática de $h' \neq h$), en grados. El emparejado por debajo del nulo en toda capa, y nunca en cero, denota que el portador de residuo se inclina del inerte sin desligarse.

Capa	Emparejado	Nulo de permutación
0	43,0 $\pm$ 1,2	77,2 $\pm$ 0,2
1	60,4 $\pm$ 1,2	84,4 $\pm$ 0,1
2	46,6 $\pm$ 2,5	85,6 $\pm$ 0,1
3	50,8 $\pm$ 3,1	87,0 $\pm$ 0,1
4	50,8 $\pm$ 4,2	87,5 $\pm$ 0,1
5	59,5 $\pm$ 3,3	86,7 $\pm$ 0,2
6	52,3 $\pm$ 2,7	85,6 $\pm$ 0,2
7	64,4 $\pm$ 3,7	85,3 $\pm$ 0,2
8	44,2 $\pm$ 1,2	73,1 $\pm$ 0,7
9	49,6 $\pm$ 3,7	86,6 $\pm$ 0,2
10	52,3 $\pm$ 2,7	82,8 $\pm$ 0,5
11	23,5 $\pm$ 2,2	51,9 $\pm$ 1,6

Referencias

- A. Ahmad, A. Joshi, and A. Modi. Beyond components: singular vector-based interpretability of transformer circuits. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- S. Ashkboos, M. L. Croci, M. Gennari do Nascimento, T. Hoeffler, and J. Hensman. SliceGPT: compress large language models by deleting rows and columns. In *International Conference on Learning Representations (ICLR)*, 2024a.
- S. Ashkboos, A. Mohtashami, M. L. Croci, B. Li, P. Cameron, M. Jaggi, D. Alistarh, T. Hoeffler, and J. Hensman. QuaRot: outlier-free 4-bit inference in rotated LLMs. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024b.

- R. Bhatia. *Matrix Analysis*, volume 169 of *Graduate Texts in Mathematics*. Springer, 1997.
- S. Biderman, H. Schoelkopf, Q. G. Anthony, H. Bradley, K. O’Brien, E. Hallahan, M. A. Khan, S. Purohit, U. S. Prashanth, E. Raff, A. Skowron, L. Sutawika, and O. van der Wal. Pythia: a suite for analyzing large language models across training and scaling. In *International Conference on Machine Learning (ICML)*, 2023.
- Y. Chen, Y. Chi, J. Fan, and C. Ma. Spectral methods for data science: a statistical perspective. *Foundations and Trends in Machine Learning*, 14(5):566–806, 2021.
- G. Dar, M. Geva, A. Gupta, and J. Berant. Analyzing transformers in embedding space. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 16124–16170, 2023.
- J. Deng, J. Guo, N. Xue, and S. Zafeiriou. ArcFace: additive angular margin loss for deep face recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- N. Elhage, N. Nanda, C. Olsson, et al. A mathematical framework for transformer circuits. Transformer Circuits Thread, 2021. URL <https://transformer-circuits.pub/2021/framework/index.html>.
- G. Franco, C. Loughridge, and M. Crovella. Singular vectors of attention heads align with features, 2026. arXiv preprint arXiv:2602.13524.
- K. Hashimoto, Y. Hirono, and A. Sannai. Unification of symmetries inside neural networks: Transformer, feedforward and neural ODE. *Machine Learning: Science and Technology*, 5(2): 025079, 2024. doi: 10.1088/2632-2153/ad5927.
- W. Liu, Y. Wen, Z. Yu, M. Li, B. Raj, and L. Song. SphereFace: deep hypersphere embedding for face recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- Z. Liu, C. Zhao, I. Fedorov, B. Soran, D. Choudhary, R. Krishnamoorthi, V. Chandra, Y. Tian, and T. Blankevoort. SpinQuant: LLM quantization with learned rotations. In *International Conference on Learning Representations (ICLR)*, 2025.
- P. Michel, O. Levy, and G. Neubig. Are sixteen heads really better than one? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- B. Millidge and S. Black. The singular value decompositions of transformer weight matrices are highly interpretable. AI Alignment Forum, 2022. URL <https://www.alignmentforum.org/posts/mkbGjzx8d8XqKHZA>. 28 November 2022.
- A. M. Nicolicioiu, A. L. Nicolicioiu, B. Alexe, and D. Teney. Learning diverse features in vision transformers for improved generalization. In *ICML 2023 Workshop on Spurious Correlations, Invariance and Stability*, 2023.
- M. Oquab, T. Darcet, T. Moutakanni, et al. DINOv2: learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. arXiv:2304.07193.
- X. Pan, A. Philip, Z. Xie, and O. Schwartz. Dissecting query-key interaction in vision transformers. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2405.14880.

- V. Pappayan, X. Y. Han, and D. L. Donoho. Prevalence of neural collapse during the terminal phase of deep learning training. *Proceedings of the National Academy of Sciences*, 117(40):24652–24663, 2020.
- F. Pernici, M. Bruni, C. Baecchi, and A. Del Bimbo. Regular polytope networks. *IEEE Transactions on Neural Networks and Learning Systems*, 33(9):4373–4387, 2022. doi: 10.1109/TNNLS.2021.3056762.
- R. A. Rankin. The closest packing of spherical caps in n dimensions. *Proceedings of the Glasgow Mathematical Association*, 2(3):139–144, 1955.
- N. Srebro and A. Shraibman. Rank, trace-norm and max-norm. In *Conference on Learning Theory (COLT), LNAI 3559*, pages 545–560, 2005. doi: 10.1007/11503415_37.
- G. W. Stewart and J.-G. Sun. *Matrix Perturbation Theory*. Academic Press, 1990.
- Y. Tian, D. Krishnan, and P. Isola. Contrastive multiview coding. In *European Conference on Computer Vision (ECCV)*, pages 776–794, 2020.
- V.-H. Tran, V. K. Bui, V.-H. Trinh, T. L. Ngoc, and T. M. Nguyen. Functional equivalence in attention: a comprehensive study with applications to linear mode connectivity, 2026. arXiv preprint arXiv:2606.17830.
- M. H. Uddin, L. Seymour, and S. Baidya. HEART-ViT: Hessian-guided efficient dynamic attention and token pruning in vision transformer, 2025. arXiv preprint arXiv:2512.20120.
- L. van Nierop. Transformer models are gauge invariant: a mathematical connection between AI and particle physics, 2024. arXiv preprint arXiv:2412.14543.
- A. Vaswani, N. Shazeer, N. Parmar, et al. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- E. Voita, D. Talbot, F. Moiseev, R. Sennrich, and I. Titov. Analyzing multi-head self-attention: specialized heads do the heavy lifting, the rest can be pruned. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2019.
- H. Wang and K. Wang. Complete characterization of gauge symmetries in Transformer architectures. In *Proceedings of the 4th (2025) and 3rd (2024) NeurIPS Workshops on Symmetry and Geometry in Neural Representations (NeurReps)*, PMLR 282, pages 622–663, 2026.
- H. Wang, Y. Wang, Z. Zhou, X. Ji, D. Gong, J. Zhou, Z. Li, and W. Liu. CosFace: large margin cosine loss for deep face recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- P.-Å. Wedin. Perturbation bounds in connection with singular value decomposition. *BIT Numerical Mathematics*, 12:99–111, 1972. doi: 10.1007/BF01932678.
- R. Wightman. PyTorch image models. GitHub, 2019. DOI 10.5281/zenodo.4414861.
- H. Yamagiwa, Y. Takase, and H. Shimodaira. Measuring affinity between attention-head weight subspaces via the projection kernel, 2026. arXiv preprint arXiv:2601.10266.
- H. Yang, H. Yin, M. Shen, P. Molchanov, H. Li, and J. Kautz. Global vision transformer pruning with hessian-aware saliency. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- Z. Zhu, T. Ding, J. Zhou, X. Li, C. You, J. Sulam, and Q. Qu. A geometric analysis of neural collapse with unconstrained features. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.