

Dos modelos idénticos, dos podas distintas: la dirección dominante de W_O bajo intervención libre, suave y dura

Manuel Muñoz Plá

Investigador independiente — Sevilla, España

ORCID: 0009-0000-5714-912X | mmunozpl@uoc.edu

Junio de 2026

Resumen

Una práctica extendida en análisis de cabezas de atención lee la geometría de la proyección de salida W_O : el primer vector singular $v_1(W_O^{(h)})$ de cada cabeza se toma como su dirección representativa para poda, interpretación o routing, bajo la suposición de que esa geometría refleja su función. Este trabajo contrasta esa suposición a tres intensidades de intervención sobre el sector valor-salida: bajo un gauge libre la dirección deriva sin efecto funcional; bajo una sonda que la separa hasta el umbral del simplex, tampoco; solo la imposición dura paga en función. El acoplamiento es unidireccional, y tiene una explicación de forma cerrada: $v_1(W_O)$ no es identificable bajo una reparametrización del sector valor-salida que no toca la función, mientras el circuito OV $W_v W_O$ —único objeto identificable— permanece fijo. La consecuencia es una imposibilidad: ningún umbral de similitud sobre esa dirección admite radio certificado positivo, y la decisión de poda que produce cambia bajo gauge en más del 90 % de los casos, tanto en un ViT afinado en visión como, por la misma forma cerrada y sin entrenar nada, en un transformer de lenguaje preentrenado. Como instrumento, la firma de respuesta gauge-invariante $v_1(C_h^P)$ mide la diversidad funcional sin la ambigüedad de gauge, y resulta específica de cada cabeza. Los resultados se establecen sobre un ViT-B/16 afinado en ImageNet-100 con cinco semillas y se contrastan sobre ViT-L/16 y un DINOv2 congelado: la no-identificabilidad y la especificidad de la firma se reproducen en las tres columnas y la inercia en las dos afinadas, mientras la reubicación hacia $Q \cdot K$ —correlacional, con un cruce reproducible en la capa 5— se acota al régimen afinado supervisado.

Palabras clave: atención multi-cabeza, no-identificabilidad de gauge, imposibilidad certificada, circuito OV, diversidad funcional, poda de cabezas, Transformers de visión.

1. Introducción

El Transformer de visión ha desplazado a la red convolucional como arquitectura de referencia en clasificación de imagen, y su mecanismo de atención multi-cabeza se presenta como una vía para que el modelo atienda, en paralelo, a distintas relaciones espaciales. La evidencia empírica matiza esa lectura: una parte de las cabezas converge sobre patrones de atención casi indistinguibles, de modo que la capacidad nominal de la capa no se traduce en diversidad efectiva. Podar cabezas tras el entrenamiento apenas degrada la exactitud [8, 9], denotando que la redundancia no es marginal sino estructural.

Sobre esa observación se ha construido una práctica que conviene hacer explícita. Para decidir qué cabezas son redundantes —y podarlas o fusionarlas—, para interpretar el papel de una cabeza, o para enrutar información entre ellas, una familia de métodos lee la *geometría de la proyección de salida* W_O : el primer vector singular $v_1(W_O^{(h)})$ de cada cabeza se toma como su dirección representativa, bajo la suposición de que esa geometría refleja lo que la cabeza hace. La suposición

es contrastable, y este trabajo la contrasta. Su respuesta es negativa: la dirección dominante sobre la que esa práctica opera no porta la función de la cabeza.

El argumento se apoya en tres intensidades de intervención sobre esa geometría, leídas juntas. Bajo el *gauge libre* —reparametrizar $\mathbf{W}_v \rightarrow \mathbf{W}_v \mathbf{R}$, $\mathbf{W}_O \rightarrow \mathbf{R}^{-1} \mathbf{W}_O$ con $\mathbf{R}$ invertible deja la función intacta— $\mathbf{v}_1(\mathbf{W}_O)$ se desplaza a voluntad mientras el circuito OV $\mathbf{W}_v \mathbf{W}_O$, único objeto identificable del sector, permanece fijo: leer esa dirección es leer una elección de gauge. Bajo la *sonda blanda*, que separa angularmente las direcciones representativas hasta el umbral del simplex, la geometría se mueve decenas de grados sin que la similitud funcional entre cabezas se separe del ruido entre semillas. Bajo la *variante dura*, que impone ese mismo simplex por construcción, la función sí se resiente. El acoplamiento es unidireccional: la geometría de $\mathbf{W}_O$ no gobierna la función salvo cuando se la fuerza hasta romperla, y esa asimetría —no la no-identificabilidad por sí sola— es lo que el dato sostiene. Sobre ella, una caracterización por capa sitúa además la organización de la atención en la interacción $Q \cdot K$, hacia la que se reubica con la profundidad en el régimen afinado, ajena a la dirección dominante de $\mathbf{W}_O$.

Si la dirección dominante no porta la función, una medida de diversidad de cabezas ha de anclarse a un objeto identificable. Las cabezas pueden caracterizarse por una dirección representativa sobre una hiperesfera, y la intuición de separarlas se formaliza con los *códigos esféricos* (sección 3); pero el portador correcto no es la geometría de pesos, sino la *firma de la respuesta por parche* que la cabeza computa, el primer vector singular de $\mathbf{C}_h^P = \mathbf{A}_h \mathbf{V}_h \mathbf{W}_O^{(h)}$, invariante de gauge. Esa firma es el instrumento con que este trabajo mide la diversidad funcional, y resulta específica de cada cabeza.

Contribución. El trabajo es un análisis, no una propuesta de método. El aparato geométrico se reduce a lo que la tesis usa —la noción de separación angular y el simplex de forma cerrada (sección 3)—; el apéndice mide la órbita de gauge sobre los pesos reales (apéndice A).

1. Una **disociación en tres intensidades**: bajo el gauge libre la geometría deriva hasta 0,91 mientras la función queda intacta a precisión de máquina, invariancia verificada en las tres columnas; bajo la sonda blanda la geometría se mueve de 23 a 33 grados hacia el simplex sin que la similitud funcional se separe del ruido entre semillas, en las dos columnas afinadas, con el signo del desplazamiento invertido entre ellas; y bajo la variante dura, que impone el simplex por construcción, la geometría queda clavada y la función sí se resiente — s_{func} se desplaza +0,031 y +0,052, mismo signo en ambas arquitecturas, al precio de 4,4 y 5,6 puntos de exactitud—. El acoplamiento geometría-función es unidireccional (sección 6.2).
2. Una **imposibilidad de forma cerrada**, con su consecuencia de decisión: bajo el gauge del sector valor-salida, la órbita de $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ es la esfera unitaria completa de su espacio fila, y el ángulo entre dos cabezas recorre todo el intervalo permitido con la función fija, de modo que ningún criterio de similitud sobre $\mathbf{v}_1(\mathbf{W}_O)$ —poda por redundancia, interpretación por dirección dominante, routing— admite radio certificado positivo; el circuito OV es lo identificable. La consecuencia es medible: la decisión de poda que esa geometría produce cambia bajo gauge en más del 90 % de los casos, tanto sobre un ViT afinado en visión como, por la misma forma cerrada y sin entrenar nada, sobre un transformer de lenguaje preentrenado (sección 4 y tabla 3).
3. La **reubicación hacia $Q \cdot K$, acotada a régimen**: la organización de la atención que distingue una cabeza de otra se desplaza con la profundidad hacia la comparación consulta-clave, donde $\mathbf{v}_1(\mathbf{W}_O)$ no participa; el desplazamiento es limpio en la ancla, sostenido pero matizado en una segunda escala y ausente en un backbone autosupervisado congelado, de modo que es el afinado supervisado, no la atención global por sí misma, quien lo produce (sección 6.4).

4. Un **instrumento gauge-invariante**, el lado positivo de la misma moneda: la firma de respuesta $\mathbf{v}_1(\mathbf{C}_h^P)$ vive en el mismo $\mathbb{R}^d$, es invariante de gauge y específica de cada cabeza, y su decisión sobrevive a la reparametrización que rompe la del proxy de pesos —una imposibilidad certificada y una posibilidad certificada, distinguidas por un solo criterio (secciones 4.2 y 6.5 y tabla 3)—. Que sea la medida correcta de diversidad no implica que sea el mejor criterio para *seleccionar* qué podar: a este presupuesto, ningún criterio —de gauge o funcional— bate al suelo aleatorio (tabla 7).

Alcance del dato. Los resultados se establecen sobre un ViT-B/16 afinado en ImageNet-100 con cinco semillas —la columna ancla— y se contrastan sobre dos columnas más con tres semillas cada una: un ViT-L/16 afinado y un DINOv2 congelado con cabeza lineal (tabla 1). El contraste no resultó uniforme: gauge y residuo se reproducen en las tres columnas, la inercia en las dos afinadas, y la reubicación solo en ellas —limpia en la ancla, matizada en ViT-L, ausente en la congelada—. No todos los apoyos aplican a toda columna: la inercia requiere entrenar con la sonda y se mide en ViT-B y ViT-L; sobre la columna congelada corren solo los apoyos sin reentrenar (gauge, reubicación, residuo). La no-identificabilidad es de forma cerrada y no depende de la arquitectura; la lectura de la reubicación como desplazamiento por profundidad es correlacional e indiciaria, no causal. La generalización a otros ratios de cabezas y dimensión se discute como límite (sección 7), no como resultado.

2. Trabajo relacionado

El proxy geométrico de la proyección de salida. Leer el rol o la redundancia de una cabeza desde la dirección dominante de su proyección de salida es el proxy más barato y estático imaginable: no exige forwards ni gradientes, opera directamente sobre el checkpoint. Este trabajo cierra esa vía por anticipado más que corrige una práctica ya extendida en la literatura revisada. Los métodos de poda de vanguardia en este entorno no la usan: HEART-ViT [15] poda cabezas y tokens por sensibilidad Hessiana sobre ViT-B/16 en ImageNet-100, Yang et al. [14] podan con saliencia Hessiana global, y el análisis de redundancia de cabezas de mayor recorrido lee gradientes o activaciones, no geometría de pesos [8, 9]. La interpretabilidad mecanicista más reciente, cuando sí lee geometría de pesos por cabeza, converge además hacia el objeto invariante de gauge y no hacia la dirección dominante aislada: Ahmad et al. [17] descomponen por SVD el circuito OV compuesto $\mathbf{W}_v \mathbf{W}_O$ (y el circuito QK), no $\mathbf{W}_O$ por separado; Franco et al. [18] descomponen igualmente el circuito $\mathbf{W}_q^\top \mathbf{W}_k$; y Yamagiwa et al. [19] comparan subespacios de *rango completo* de la proyección de salida —precisamente el objeto que aquí se certifica invariante bajo el gauge del sector valor-salida (proposición 1)—, no su dirección dominante aislada. La corrección que este trabajo aporta es, en consecuencia, corolario de la disociación geometría-función medida (sección 6.2), no la tesis: protege el atajo más barato —leer $\mathbf{v}_1(\mathbf{W}_O)$ solo— del que la práctica más cuidadosa ya se aparta, sin reclamar haber corregido a nadie en particular.

La órbita de gauge como recurso, no solo como advertencia. La libertad de gauge que aquí se certifica como fuente de no-identificabilidad (proposición 1) es la misma que la cuantización por rotación explota activamente como recurso de diseño. QuaRot [20] y SpinQuant [21] insertan rotaciones ortogonales que dejan la salida del modelo intacta —“computational invariance” en su terminología— para eliminar outliers antes de cuantizar; la rotación R_2 de SpinQuant se aplica exactamente al par valor-salida ($\mathbf{W}_v^{(h)} \rightarrow \mathbf{W}_v^{(h)} R_2$, $\mathbf{W}_O^{(h)} \rightarrow R_2^{-1} \mathbf{W}_O^{(h)}$ para toda cabeza h de la capa, con R_2 ortogonal), el mismo gauge de la proposición 1 restringido al subgrupo ortogonal $O(d_h) \subset GL(d_h)$ y, a diferencia de la órbita aquí certificada, compartido entre las cabezas de la capa en vez de independiente por cabeza. Que esa restricción de la órbita tenga consecuencias operativas medibles en la literatura de compresión es evidencia independiente de que la elección de gauge no es solo ruido contra el que advertir, sino un espacio de diseño. Cuantizar el circuito

OV a lo largo de esa órbita, y medir cómo se mueve su error con el punto elegido, queda fuera de este trabajo pero es la continuación de diseño más directa; junto a la atribución por componente sobre $Q \cdot K$, fija el rumbo del trabajo futuro (sección 7).

Diversidad de cabezas por regularización: el baseline directo. La diversidad entre cabezas se ha promovido con penalizaciones de varios tipos. El antecedente más próximo interviene sobre una señal ligada al comportamiento: un regularizador de ortogonalidad sobre los gradientes de entrada de cada cabeza incrementa la diversidad de los rasgos aprendidos y mejora la generalización fuera de distribución [10]. Ese enfoque altera la función —y obtiene ganancia OOD por ello—, frente al cual este trabajo reclama una intervención más simple: separar angularmente la *firma de la respuesta por parche*, sin gradientes de entrada ni segundo orden, con la misma maquinaria del simplex que el regularizador de pesos descartado. El contraste con la intervención sobre W_O —que no altera la función— es coherente con que la organización que distingue una cabeza de otra resida en la respuesta computada, no en la geometría dominante de los pesos.

Estructura por profundidad en la atención. La estratificación funcional por profundidad en Transformers está documentada. Pan et al. [13] descomponen la interacción $Q \cdot K$ por SVD de $W_q^\top W_k$ y documentan una transición de agrupamiento perceptual (capas tempranas) a contextualización (profundas). Yang et al. [14], al podar, observan que la proyección de salida y $Q \cdot K$ tienen importancias distintas y una tendencia no monótona en la diversidad de atención por capa. Esta estructura por profundidad no es contribución de este trabajo, sino contexto: enmarca la costura de la capa 5, donde la organización de la atención deja la escritura residual y pasa a la comparación consulta-clave, y la inversión hacia $Q \cdot K$ que documentamos (sección 6) es vecina de esas observaciones.

Redundancia y roles de la atención multi-cabeza. El análisis de la atención multi-cabeza ha mostrado que muchas cabezas son prescindibles [8] y que cumplen funciones especializadas e identificables [9]; una cabeza puede ser importante para la tarea sin que la geometría de su proyección de salida trace ese rol. Si esa especialización es propiedad emergente del entrenamiento o propiedad estática recuperable de los pesos es la cuestión que los resultados de este trabajo abordan (secciones 6 y 7).

Neural collapse y clasificadores fijos. El fenómeno de *neural collapse* [2] describe cómo, en la fase final del entrenamiento, las medias de clase y los vectores del clasificador convergen a un marco equiangular ajustado; trabajos posteriores [3] lo analizan bajo el modelo de características no restringidas. Esa regularidad ha motivado clasificadores *fijos* con geometría predeterminada [4]. El presente trabajo hereda la idea —entregar la geometría en lugar de esperarla— pero la aplica a la respuesta por parche de las cabezas, no a sus pesos.

Márgenes angulares. SphereFace [5], CosFace [6] y ArcFace [7] introdujeron márgenes sobre el ángulo entre la característica y el prototipo de clase. Operan sobre una geometría angular, pero estiman los prototipos durante el entrenamiento; aquí el objetivo angular se fija con separación garantizada y se aplica a la firma de respuesta de cada cabeza.

3. Marco teórico

Esta sección retiene lo imprescindible para situar la intervención: la noción de separación angular sobre la hiperesfera y el régimen en que opera el modelo, que fija el objetivo θ^* del regularizador. En el régimen holgado en que vive toda columna de este trabajo, el código óptimo tiene forma cerrada y no requiere maquinaria de generación.




Figura 1: Esquema bidimensional de un código esférico sobre $\mathbb{S}^{d-1}$. Cada dirección unitaria $\mathbf{u}_i$ corresponde, en este trabajo, a la dirección representativa de una cabeza de atención — $\mathbf{v}_1(\mathbf{W}_O)$, el objeto que la sonda separa— o a su firma de respuesta gauge-invariante, el instrumento de medida. La calidad del código se mide por la separación angular mínima $\theta_{\min}$, el menor de los ángulos entre pares; un buen código la maximiza.

3.1. La hiperesfera: una intuición previa

Cuando varios elementos idénticos que se repelen quedan confinados sobre una superficie cerrada, no se distribuyen al azar: se acomodan hasta alcanzar el reposo en que la fuerza neta se anula. Los electrones sobre una esfera conductora —el problema que Thomson planteó en 1904— y las semillas en el capítulo del girasol obedecen al mismo principio: cada elemento ocupa la posición que maximiza su distancia angular a los demás. Ese reposo no es un acto de cómputo, sino el residuo de una repulsión que se ha dejado actuar hasta el final. De un proceso enteramente continuo emergen, sin embargo, cantidades enteras —los términos de Fibonacci de la espiral—; el número de elementos no se impone desde fuera, sino que queda inscrito en la geometría del acomodo. Una red neuronal, al separar sus clases en el espacio de representación, reproduce ese mismo reposo: las direcciones asociadas a cada clase se distancian entre sí hasta configurar una disposición de separación angular máxima, fenómeno que la literatura reciente denota con el término *neural collapse*. La diferencia con los sistemas físicos abre una oportunidad: donde la naturaleza requiere todo el proceso de relajación para alcanzar esa configuración, un modelo puede recibirla fijada de antemano. Las páginas siguientes formalizan esa configuración sobre la hiperesfera unitaria $\mathbb{S}^{d-1}$ y precisan la noción de separación angular mínima entre pares de direcciones.

3.2. Códigos esféricos y separación angular

Definición 1 (Código esférico). *Un código esférico de tamaño K en dimensión d es un conjunto $\mathcal{C} = \{\mathbf{u}_1, \dots, \mathbf{u}_K\} \subset \mathbb{S}^{d-1}$ de direcciones unitarias. Su separación angular mínima es*

$$\theta_{\min}(\mathcal{C}) = \min_{i \neq j} \arccos(\langle \mathbf{u}_i, \mathbf{u}_j \rangle). \quad (1)$$

El objetivo es hallar $\mathcal{C}^*$ que maximice $\theta_{\min}$. En el régimen holgado ($K \leq d + 1$), el único que este trabajo visita ($K=12$ o 16 frente a $d=768$ o 1024), el óptimo con signo es el simplex regular y tiene forma cerrada: se factoriza su matriz de Gram —unos en la diagonal, $-1/(K - 1)$ fuera— y se embebe en $\mathbb{R}^d$ por rotación. El código objetivo de la variante dura (sección 4.3) es esa configuración; su construcción es determinista y reproducible sin descenso alguno.

3.3. Dos regímenes y el objetivo del regularizador

La separación angular alcanzable por un código de K direcciones en $\mathbb{S}^{d-1}$ depende de la relación entre K y d , y de si las direcciones portan signo. Para direcciones con signo, sumando las K direcciones unitarias y observando que la norma al cuadrado es no negativa,

$$0 \leq \left\| \sum_h \mathbf{u}_h \right\|^2 = K + \sum_{h \neq h'} \langle \mathbf{u}_h, \mathbf{u}_{h'} \rangle, \quad (2)$$

el coseno medio entre pares es al menos $-1/(K-1)$, y el coseno máximo no puede quedar por debajo de su media: $\theta_{\min} \leq \arccos(-1/(K-1))$ para *cualquier* configuración, no solo las equiangulares. En el *régimen holgado* ($K \leq d+1$) la cota se alcanza —con igualdad exactamente cuando la suma se anula y la configuración es equiangular— por el simplex regular, que es por tanto óptimo [1]. Para direcciones definidas *salvo signo* —vectores singulares, elementos del espacio proyectivo— la similitud pertinente es $|\cos|$ y el ángulo sin signo vive en $[0^\circ, 90^\circ]$: si $K \leq d$, el máximo lo alcanza el marco ortogonal (90°), y el simplex leído sin signo ($\arccos(1/(K-1))$) queda por debajo. El papel de cada valor en el regularizador —óptimo con signo, umbral sin signo— se precisa en la sección 4.3. El régimen saturado ($K > d+1$) no se visita en este trabajo.

3.4. Conexión con neural collapse

El *neural collapse* [2] establece que, al final del entrenamiento, los vectores del clasificador convergen a un marco equiangular ajustado: una configuración de separación angular máxima para $K \leq d+1$ clases. La red tiende, por tanto, espontáneamente hacia el código esférico. La intervención de este trabajo no espera a que esa geometría emerja, sino que la regulariza desde el inicio sobre la respuesta por parche. En el régimen holgado en que opera el modelo, el marco equiangular del neural collapse y el simplex objetivo del regularizador son la misma configuración.

4. El gauge valor-salida y la firma identificable

La práctica que este trabajo examina lee una dirección de los pesos: el primer vector singular $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ de la proyección de salida de cada cabeza, tomado como su dirección representativa para poda por redundancia, interpretación por dirección dominante o routing. Esta sección fija qué de ese sector es identificable y qué no, y deriva la firma sobre la que se apoyan las medidas del trabajo.

4.1. El circuito OV y la no-identificabilidad de $\mathbf{v}_1(\mathbf{W}_O)$

El sector valor-salida de una cabeza factoriza su contribución al residuo en dos matrices, $\mathbf{W}_v^{(h)} \in \mathbb{R}^{d \times d_h}$ y $\mathbf{W}_O^{(h)} \in \mathbb{R}^{d_h \times d}$, pero esa factorización no es única. Para cualquier $\mathbf{R} \in GL(d_h)$ invertible, la sustitución

$$\mathbf{W}_v^{(h)} \rightarrow \mathbf{W}_v^{(h)} \mathbf{R}, \quad \mathbf{W}_O^{(h)} \rightarrow \mathbf{R}^{-1} \mathbf{W}_O^{(h)}, \quad (3)$$

deja la función intacta, porque el producto $\mathbf{W}_v^{(h)} \mathbf{W}_O^{(h)}$ —el *circuito OV*— no cambia. El circuito OV es el único objeto identificable del sector: toda propiedad de la cabeza que gobierne su función ha de ser función de él. La dirección dominante $\mathbf{v}_1(\mathbf{W}_O^{(h)})$ no lo es. Bajo ecuación (3) se desplaza —el subgrupo ortogonal de $\mathbf{R}$ la gira, y la parte no ortogonal, presente en todo gauge genérico, la saca de su recta—, de modo que dos modelos funcionalmente idénticos pueden exhibir cualquier separación angular entre sus $\mathbf{v}_1(\mathbf{W}_O)$. La afirmación admite forma cerrada y cota exacta:

Proposición 1 (Radio certificado nulo de la lectura por $\mathbf{v}_1$). *Sea $\mathbf{W}_O^{(h)} \in \mathbb{R}^{d_h \times d}$ de rango completo y $\mathcal{S}_h$ su espacio fila. Para toda dirección unitaria $\mathbf{w} \in \mathcal{S}_h$ existe $\mathbf{R} \in GL(d_h)$ con $\mathbf{v}_1(\mathbf{R}^{-1} \mathbf{W}_O^{(h)}) = \pm \mathbf{w}$, y la sustitución (3) deja el circuito OV intacto. En consecuencia, el ángulo entre las direcciones dominantes de dos cabezas recorre bajo gauge todo ángulo permitido por*

los espacios fila —desde el primer ángulo principal $\theta_1(\mathcal{S}_h, \mathcal{S}_{h'})$ hasta 90° — con la función fija, y ningún umbral de similitud sobre $\mathbf{v}_1(\mathbf{W}_O)$ admite radio certificado positivo.

Demostración. Con $\mathbf{W}_O = \mathbf{U}\Sigma\mathbf{V}^\top$ y $\mathbf{M} = \mathbf{R}^{-1}\mathbf{U}\Sigma$ se tiene $\mathbf{R}^{-1}\mathbf{W}_O = \mathbf{M}\mathbf{V}^\top$, cuyos vectores singulares derechos son $\mathbf{V}\mathbf{Q}$ con $\mathbf{Q}$ los derechos de $\mathbf{M}$. Al variar $\mathbf{R}$ sobre $GL(d_h)$, $\mathbf{M}$ recorre todo $GL(d_h)$ y $\mathbf{Q}$ toda base ortonormal de $\mathbb{R}^{d_h}$; la primera columna se coloca en cualquier coordenada deseada. La órbita de $\mathbf{v}_1$ es la esfera unitaria completa de $\mathcal{S}_h$. $\square$

El matiz que la hace no trivial: el espacio fila *sí* es invariante de gauge; se mueve la dirección dentro del subespacio, no el subespacio. El resultado negativo tiene por eso grano fino —el subespacio informa (sección 6.4); la dirección dominante dentro de él, no—. Leer $\mathbf{v}_1$ es leer una elección de gauge, no una propiedad de la función. La sección 6.1 lo mide sobre los pesos reales: la separación entre las $\mathbf{v}_1(\mathbf{W}_O)$ se desplaza con $\mathbf{R}$ mientras la salida y el circuito OV permanecen fijos, y la órbita alcanzable se certifica par a par (apéndice A).

4.2. La firma de respuesta gauge-invariante

Si la dirección dominante no porta la función, una medida de diversidad de cabezas ha de anclarse a un objeto identificable. La contribución por parche de la cabeza al flujo residual,

$$\mathbf{C}_h^P = \mathbf{A}_h \mathbf{V}_h \mathbf{W}_O^{(h)} \in \mathbb{R}^{P \times d}, \quad (4)$$

—producto del mapa de atención $\mathbf{A}_h$, la proyección de valor $\mathbf{V}_h$ y la de salida $\mathbf{W}_O^{(h)}$ — es la respuesta que la cabeza *computa* y escribe en el residuo, e invariante de gauge: $\mathbf{A}_h \mathbf{V}_h \mathbf{R} \mathbf{R}^{-1} \mathbf{W}_O^{(h)} = \mathbf{C}_h^P$. Su primer vector singular derecho,

$$\mathbf{r}_h = \mathbf{v}_1(\mathbf{C}_h^P) \in \mathbb{S}^{d-1}, \quad (5)$$

—la *firma de respuesta*, la dirección del residuo en que la cabeza deposita más energía sobre los parches— está bien definida entre cabezas y vive en el residuo compartido $\mathbb{R}^{768}$, el mismo espacio que $\mathbf{v}_1(\mathbf{W}_O)$, y eso hace comparables la lectura de pesos y la de función.¹ Esta firma es el instrumento de medida del trabajo: con ella se cuantifica la diversidad funcional de las cabezas sin la ambigüedad de gauge que invalida la lectura por $\mathbf{v}_1(\mathbf{W}_O)$. La sección 6.5 comprueba que es específica de cada cabeza.

4.3. El regularizador sobre $\mathbf{W}_O$ como sonda de inercia

Para contrastar si intervenir sobre la geometría de pesos mueve la función, el trabajo emplea como *sonda* —no como método propuesto— el regularizador angular que la práctica usaría: separar las direcciones representativas $\{\mathbf{v}_1(\mathbf{W}_O^{(h)})\}_{h=1}^H$ hacia el umbral del simplex. El conjunto es un código esférico de H direcciones definidas salvo signo, y el término empuja sus cosenos absolutos por debajo del umbral,

$$\mathcal{R}_{\text{ov}} = \sum_{h \neq h'} \max(0, |\langle \mathbf{v}_1(\mathbf{W}_O^{(h)}), \mathbf{v}_1(\mathbf{W}_O^{(h')}) \rangle| - \cos \theta^*), \quad (6)$$

con $\theta^* = \arccos(1/(H-1)) \approx 84,78^\circ$ el umbral heredado del simplex de H vectores (sección 3.3). El valor absoluto es necesario: dos cabezas con direcciones casi antiparalelas son equivalentes salvo signo, y el producto con signo las leería como bien separadas. La penalización se anula en toda la banda $|\cos| \leq 1/(H-1)$, de modo que exige separación suficiente, no una configuración concreta. La sonda se suma a la entropía cruzada con peso λ ,

$$\mathcal{L} = \mathcal{L}_{\text{tarea}} + \lambda \mathcal{R}_{\text{ov}}, \quad (7)$$

y la pregunta empírica es si, al separar esas direcciones, la similitud funcional entre cabezas se mueve. La sección 6.2 responde que no a la intensidad fijada ($\lambda = 10^{-3}$).

¹El vector singular está definido salvo signo; las comparaciones entre firmas singulares emplean por ello el valor absoluto del producto escalar.

5. Configuración experimental

Conjunto de datos. Se emplea ImageNet-100, el subconjunto de 100 clases de ImageNet. Cien clases aportan riqueza angular suficiente para que la diversidad entre cabezas sea medible, y el fenómeno estudiado depende de la relación entre el número de cabezas y la dimensión, no del número de clases; ImageNet-100 es, así, representativo sin la escala completa.

Arquitecturas y entorno. El aparato —gauge $GL(d_h)$ del sector valor-salida, circuito OV, interacción $Q \cdot K$ y firma C_h^P — se define igual en toda atención global, de modo que se contrasta sobre tres columnas que varían los dos ejes pertinentes sin reinterpretar una sola métrica (tabla 1). ViT-B/16 y ViT-L/16 cambian el ratio cabezas/dimensión (H de 12 a 16, d de 768 a 1024, con $d_h = 64$ constante); DINOv2 a escala ViT-L cambia el régimen de entrenamiento —autosupervisado frente a supervisado— sobre esa misma escala. Las tres parten de pesos preentrenados (**timm**); ViT-B y ViT-L se afinan sobre ImageNet-100, y DINOv2 se analiza congelado, sin afinado alguno, de modo que sus mapas de atención son los del preentrenamiento autosupervisado puro. La arquitectura ancla (ViT-B) se entrena con **cinco semillas** ($\{42, \dots, 46\}$) y ViT-L con tres; la columna congelada es una sola realización ($n=1$ de facto: sin afinado no hay semillas que muevan los pesos ni los mapas) y sus celdas van sin banda. Se reporta el n por fila. La variabilidad entre semillas es el suelo de ruido contra el que se contrastan los efectos. El entorno es una GPU NVIDIA RTX 5090 de 32 GB. La atención por ventana —Swin y, en general, la no-global— queda fuera: la no-identificabilidad sí transferiría (el gauge valor-salida es estructural a cualquier factorización valor-salida), pero la inercia y la reubicación se miden sobre objetos que su topología jerárquica y local redefine —el mapa deja de ser global, la profundidad deja de ser uniforme—, y entran como extensión, no como columna de estas tablas.

Tabla 1: Arquitecturas del contraste y desenlace por apoyo. ViT-B→ViT-L varía el ratio H/d a d_h constante (el “otro ratio”); ViT-L→DINOv2 varía el régimen a escala constante. n : semillas; la columna congelada es una realización, sin dispersión entre semillas. Gauge: invariancia de salida (fp64) con deriva de $v_1(W_O)$; residuo: capas con emparejado $<$ nulo; cruce: capa del cruce sostenido $r_{Q \cdot K} > r_{W_O}$ contra los listones de 24 capas fijados antes del dato; inercia (H1): solo columnas afinadas. El cruce de ViT-L supera dos de los tres listones (salto +0,403, margen +0,366) y falla el predominio profundo (+0,375 frente al listón $\geq 0,40$) por su capa final; el desenlace conjuntivo es ambiguo y se reporta como tal (sección 6.4).

Arquitectura	H/d	n	Régimen	Gauge	Residuo	Cruce	Inercia
ViT-B/16 (ancla)	12/768	5	sup., afinado	sí	12/12	capa 5 (5/5)	cota
ViT-L/16	16/1024	3	sup., afinado	sí	24/24	capas 8–11 (3/3)	cota
DINOv2 (ViT-L)	16/1024	1	SSL, congelado	sí	24/24	no trans- fiere	no apli- ca

Métricas. Separación angular mínima sin signo entre las direcciones representativas $v_1(W_O)$, $\theta_{\min}$, medida por capa —el mínimo entre pares de esa capa— y reportada como media entre las capas; redundancia angular entre cabezas — $|\cos|$ medio entre pares de esas direcciones—; similitud funcional s_{func} —coseno entre mapas de atención promedio—; exactitud top-1. Todas se reportan con media y banda entre semillas, y los valores finales de cada corrida se extraen como promedio de las últimas cinco épocas convergidas —la misma ventana para todas las variantes y métricas—, de modo que cada celda es trazable a su **run.csv**.

Conjunto de probing congelado. Las medidas funcionales comparten un único subconjunto de validación, muestreado una vez con semilla fija (10 imágenes por clase, 1000 en total, estratificado),

de modo que el ruido de muestreo no contamina las comparaciones por capa.

5.1. Hipótesis y tests, fijados antes del dato

El trabajo sostiene una afirmación —la dirección dominante de la proyección de salida no porta la función— y reparte la disciplina confirmatoria entre sus apoyos medidos. La pieza de no-identificabilidad (sección 4.1) es de forma cerrada y no entra en esta disciplina; se preespecifican los tres contrastes empíricos, con sus métricas y direcciones fijadas aquí.

H1 (inercia). La sonda sobre $\mathbf{v}_1(\mathbf{W}_O)$ (ecuación (6)) eleva la separación angular hasta el umbral del simplex, $\theta_{\min} \rightarrow \theta^*$, pero la similitud funcional agregada no desciende del nivel base:

$$\Delta s_{\text{func}} = s_{\text{func}}^{\lambda} - s_{\text{func}}^{\text{base}} \approx 0, \quad (8)$$

a la intensidad fijada ($\lambda = 10^{-3}$). La predicción es la *ausencia* de efecto, no su presencia, y se juzga contra el suelo de ruido entre semillas: hay inercia si $|\Delta s_{\text{func}}|$ no excede la banda base mientras $\theta_{\min}$ satura. H1 requiere entrenar con la sonda y se contrasta en las dos columnas afinadas (ViT-B y ViT-L); la columna congelada no participa por construcción.

H2 (no-identificabilidad operativa). Bajo el gauge-flip del sector valor-salida (ecuación (3)) aplicado sin reentrenar, la deriva de $\mathbf{v}_1(\mathbf{W}_O)$ crece con la magnitud del gauge $\|\mathbf{R}\|$ hasta saturar, mientras la salida y la firma del circuito OV permanecen en el suelo numérico. El test es la monotonía de la deriva de pesos frente a su constancia en el circuito, sobre la malla de fuerzas.

H3 (reubicación). La correlación por capa entre s_{func} y la interacción $Q \cdot K$ supera a la del subespacio de $\mathbf{W}_O$ en una capa interior, con $Q \cdot K$ pasando de cerca de cero a claramente positivo en esa capa —el salto brusco, no un cruce por margen— y creciendo de forma monótona hacia las profundas. El cruce es reproducible *a través de las arquitecturas*, por semilla dentro de cada una y entre las tres escalas y regímenes, y es indiferente a la sonda. En la ancla el cruce cae en la capa 5; para las columnas nuevas se preespecifica solo su *existencia y unicidad* —un salto brusco en una capa interior, con crecimiento monótono hacia las profundas—, no su índice: una columna de 24 capas no tiene por qué cruzar «en la 5». La firma de respuesta, además, se comprueba específica de cada cabeza contra un **nulo de permutación** (sección 6.5).

Los tres se leen con su banda y con el n propio de cada arquitectura. La disciplina confirmatoria descansa en la *reproducibilidad del signo y del cruce*, no en tests inferenciales de potencia: H1 —ausencia de movimiento de s_{func} — se exige reproducible en las dos columnas afinadas, y H3 —cruce hacia $Q \cdot K$ — en las tres, de modo que el “cinco de cinco en una sola” se eleva a su reproducción a través de dos escalas y dos regímenes, criterio más firme que la potencia que dos semillas menos sacrifican en las arquitecturas nuevas. El smoke exploratorio previo fijó la banda de ruido; los valores se confirman aquí sobre ImageNet-100 limpio con el conjunto congelado.

Desenlace de la disciplina confirmatoria. H2 y el nulo de permutación se reproducen en las tres columnas; H1 en las dos afinadas, con el signo del desplazamiento invertido entre ellas. H3 no se reproduce en los términos preespecificados: se sostiene en la ancla, queda ambigua en ViT-L por uno de los tres listones y no se sostiene en la columna congelada. El criterio se aplica tal como se fijó y el desenlace se reporta sin reajustarlo (sección 6.4).

6. Resultados: la dirección dominante no porta la función

Los resultados se cierran sobre cinco semillas en un ViT-B/16 afinado en ImageNet-100, y sostienen una sola afirmación con cuatro apoyos: la dirección dominante de la proyección de salida no porta la función de las cabezas. Su pieza de partida es de forma cerrada y no requiere reentrenar: la

dirección $\mathbf{v}_1(\mathbf{W}_O)$ —la que la poda por redundancia y la interpretación por dirección dominante leen— no es identificable, porque una transformación de gauge del sector valor-salida la mueve a voluntad sin tocar la función (sección 6.1). Sobre esa base, la sonda angular que opera sobre esa geometría alcanza la separación sin coste de exactitud pero no mueve la similitud funcional (sección 6.2), y la organización de la atención que distingue una cabeza de otra se reubica con la profundidad hacia la interacción $Q \cdot K$, donde esa dirección no participa (sección 6.4). Un último diagnóstico, también sin reentrenar, comprueba que la firma de respuesta gauge-invariante (sección 4.2) es específica de cada cabeza (sección 6.5).

6.1. El gauge valor-salida: $\mathbf{v}_1(\mathbf{W}_O)$ no es identificable

La contribución de una cabeza al residuo es invariante bajo una libertad de gauge del espacio de valor: para cualquier $\mathbf{R} \in GL(d_h)$, la sustitución $\mathbf{W}_v \rightarrow \mathbf{W}_v \mathbf{R}$, $\mathbf{b}_v \rightarrow \mathbf{b}_v \mathbf{R}$, $\mathbf{W}_O \rightarrow \mathbf{R}^{-1} \mathbf{W}_O$ deja la función intacta, porque $\mathbf{W}_v \mathbf{W}_O$ —el circuito OV, el único objeto identificable del sector— no cambia. La dirección dominante $\mathbf{v}_1(\mathbf{W}_O)$ —su primer vector singular derecho, la dirección de escritura en el residuo—, en cambio, se desplaza con $\mathbf{R}$: el subgrupo ortogonal del gauge la conserva, y es la parte no ortogonal de $\mathbf{R}$, presente en toda transformación genérica, la que la mueve. Aplicando ese gauge sobre el modelo base afinado, sin reentrenar, se mide qué lee cada método (forward y firmas en fp64): la salida no cambia —error relativo $\leq 2 \times 10^{-13}$ en las 420 combinaciones de capa $\times$ semilla $\times$ fuerza—, pero la separación entre las $\mathbf{v}_1(\mathbf{W}_O)$ —la cantidad que la poda por redundancia compara— se desplaza, mientras la firma del circuito OV —su primer vector singular, por SVD exacta— permanece doce órdenes de magnitud por debajo ($\leq 4,2 \times 10^{-13}$), en el suelo de la doble precisión.

El desplazamiento de $\mathbf{v}_1(\mathbf{W}_O)$ no es el accidente de una transformación concreta: crece con la magnitud del gauge $\|\mathbf{R}\|$ y satura hacia la ortogonalización —de 0,05 con una $\mathbf{R}$ apenas distinta de un múltiplo de la identidad, sube por 0,35 y 0,66, y se asienta en $\sim 0,83$ (el techo de $1 - |\cos|$) desde $\|\mathbf{R}\| \approx 1$ —, mientras la del circuito OV se queda en $\sim 3 \times 10^{-13}$ sea cual sea la fuerza (tabla 2). No es “un gauge la mueve”, sino “todo gauge genérico la mueve, dentro del techo del $|\cos|$, y ninguno mueve el circuito”. Es la demostración de forma cerrada de que leer o reorganizar $\mathbf{v}_1(\mathbf{W}_O)$ —poda por redundancia, interpretación por dirección dominante, routing por vector representativo— opera sobre ruido de gauge. Y hace plausible la inercia del regularizador de sección 6.2 —que optimiza ese mismo objeto no identificable—, sin demostrarla: que una intervención sobre él no mueva la similitud funcional por ninguna vía indirecta es un hecho empírico, medido aparte, no una consecuencia del gauge.

Tabla 2: Premisa, gauge-flip valor-salida sobre el modelo base, sin reentrenar y en fp64 (media $\pm$ desviación entre las 60 combinaciones de 5 semillas $\times$ 12 capas por fuerza). La deriva es $1 - |\cos|$ medio entre la firma antes y después del gauge; $\|\mathbf{R}\|$ mide la desviación de $\mathbf{R}$ respecto a un múltiplo escalar de la identidad. La deriva de $\mathbf{v}_1(\mathbf{W}_O)$ crece con la fuerza del gauge; la del circuito OV no: permanece en el suelo de la doble precisión, doce órdenes de magnitud por debajo, constante e independiente de la fuerza.

$\ \mathbf{R}\ $	Error salida	Deriva $\mathbf{v}_1(\mathbf{W}_O)$	Deriva circuito OV
0,06	$1,1 \times 10^{-15}$	$0,05 \pm 0,04$	$2,9 \times 10^{-13}$
0,13	$1,1 \times 10^{-15}$	$0,15 \pm 0,09$	$2,9 \times 10^{-13}$
0,25	$1,1 \times 10^{-15}$	$0,35 \pm 0,16$	$2,9 \times 10^{-13}$
0,50	$1,1 \times 10^{-15}$	$0,66 \pm 0,15$	$2,9 \times 10^{-13}$
1,00	$8,0 \times 10^{-15}$	$0,83 \pm 0,04$	$2,9 \times 10^{-13}$
2,00	$8,5 \times 10^{-15}$	$0,83 \pm 0,05$	$2,9 \times 10^{-13}$
4,05	$2,9 \times 10^{-14}$	$0,82 \pm 0,07$	$2,9 \times 10^{-13}$

La deriva no es abstracta: la decisión que la práctica tomaría cambia bajo el gauge. Materializando las dos decisiones típicas —el par de cabezas más redundante y el conjunto de poda top-3 por redundancia media— sobre cada capa y semilla, y aplicando cinco gauges por capa a

la fuerza saturada ($\|\mathbf{R}\| \approx 1$), la decisión por $\mathbf{v}_1(\mathbf{W}_O)$ cambia de par en el 92,7 % de los casos y conserva de media 0,38 del top-3 (por capa, entre 0,24 y 0,69); la misma decisión tomada con la firma de respuesta gauge-invariante no cambia de par en ningún caso y conserva el top-3 completo (tabla 3). Dos modelos funcionalmente idénticos podan, con el criterio de pesos, conjuntos distintos de cabezas.

La inestabilidad no es propiedad de la visión ni del afinado: se reproduce, por la misma forma cerrada y sin entrenar nada, sobre un transformer de lenguaje preentrenado. Sobre Pythia-410M [16] (GPT-NeoX, 24 capas, 16 cabezas, atención multi-cabeza pura) el mismo gauge valor-salida, a presupuesto de poda equivalente ($k=4$ de 16, el mismo 25 % relativo que el top-3 de 12 del ancla), cambia el par más redundante en el 90,0 % de los casos y conserva solo 0,229 del conjunto de poda (tabla 3). La firma de respuesta exige forwards con probe y no se porta a esta columna; la comparación se limita al criterio de pesos.

Tabla 3: Decisión bajo gauge, sin reentrenar. ViT-B: 5 semillas $\times$ 12 capas $\times$ 5 gauges a $\|\mathbf{R}\| \approx 1$, top-3 de 12 (25 %). Pythia-410M: 24 capas $\times$ 5 gauges a la misma fuerza saturada, top-4 de 16 (mismo 25 % relativo; columna congelada, $n=1$ de facto); la firma de respuesta no se mide en la columna de lenguaje (exige forwards con probe, fuera de alcance). Fracción de casos en que cambia el par más redundante y solape medio del conjunto de poda con la decisión sin gauge, por criterio. Umbrales fijados antes del dato: pesos inestable si el par cambia en ≥ 40 % o el solape medio $< 0,67$; firma estable si el solape $\geq 0,95$ y el par cambia < 5 %.

Arquitectura	Criterio	Par cambia (%)	Solape top- k
ViT-B/16 (ancla, $k=3$)	$\mathbf{v}_1(\mathbf{W}_O)$ (pesos)	92,7	0,378
ViT-B/16 (ancla, $k=3$)	Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	0,0	1,000
Pythia-410M (lenguaje, $k=4$)	$\mathbf{v}_1(\mathbf{W}_O)$ (pesos)	90,0	0,229
Pythia-410M (lenguaje, $k=4$)	Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	no medido	no medido

La proposición 1 se certifica además par a par sobre los pesos reales (apéndice A): en las cinco semillas, el suelo de la órbita —el primer ángulo principal entre espacios fila— baja hasta 14,7° según el par, el umbral del simplex $\theta^* = 84,78^\circ$ cae dentro de la banda alcanzable de los 3960 pares medidos (66 pares $\times$ 12 capas $\times$ 5 semillas), y un descenso restringido a los espacios fila encuentra, en las 60 combinaciones capa $\times$ semilla, una configuración conjunta de las doce direcciones con $\theta_{\min} \geq \theta^*$ (peor caso 84,79°). El cumplimiento *total* del regularizador está, por tanto, en la órbita de gauge: existe un camino de coste funcional exactamente cero hacia él. Todo ángulo observado entre direcciones dominantes es un punto de una banda de decenas de grados que el gauge recorre con la función fija; el valor concreto es elección de gauge, no función.

6.2. El regularizador sobre $\mathbf{W}_O$ separa sin coste, pero no mueve la función

El portador de pesos es la dirección representativa $\mathbf{r}_h = \mathbf{v}_1(\mathbf{W}_O^{(h)})$, el primer vector singular derecho de la proyección de salida, y el regularizador es el de ecuación (6) sobre ese portador. El afinado por sí solo separa las cabezas solo parcialmente: $\theta_{\min}$ se estanca en 51,96°, muy por debajo del umbral del simplex ($\theta^* = 84,78^\circ$). El estancamiento no denota obstrucción de empaquetamiento: con $K=12 \leq d=768$ el óptimo sin signo es el marco ortogonal a 90°, con 756 dimensiones de holgura, y la banda admisible $|\cos| \leq 1/11$ es enorme; es un certificado de no-obstrucción, y el 51,96° pasa de dato bruto a evidencia dirigida. El regularizador blando conduce esa separación a 85,01° —rebasa el umbral y sigue derivando hacia el marco ortogonal— y reduce la redundancia angular de 0,172 a 0,034, con una caída de exactitud de 0,10 pp que queda *dentro* de la banda de top-1 entre semillas de la base (0,19 pp): eso, y no un cero nominal, es sin coste. La variante dura, que re proyecta tras cada paso sobre el simplex, queda anclada a él (84,77°) —por debajo de la blanda, que sin código alguno lo rebasa: la bisagra deriva libremente hacia el marco ortogonal mientras la re proyección la fija a una configuración subóptima— y paga 4,40 pp —uniforme entre semillas (rango 0,86 pp), 23 veces la banda— y desestabiliza la exactitud dentro de cada corrida

(desviación intra-corrida 0,0022 frente a 0,0013 de base); la blanda no solo iguala a la dura en separación, la supera en de-correlación. La tabla 4 recoge el estado final.

El patrón se repite en la columna profunda: la dura paga 5,6 pp —uniforme entre semillas— y desplaza $s_{\text{func}} +0,031$, treinta y una veces la banda base de ViT-L, mientras la blanda alcanza el mismo $\theta_{\text{mín}}$ sin coste medible. El desplazamiento de la dura conserva signo y orden de magnitud entre arquitecturas; el de la blanda los invierte y permanece en el ruido.

Sobre s_{func} , el corazón de H1: el desplazamiento entre variantes es del orden de la dispersión entre semillas ($\Delta = +0,0013$, IC del 95 % $[-0,0011, +0,0037]$, que incluye el cero), sin separación detectable de cero en cinco réplicas, con un posible sesgo de signo menor que esa dispersión. El resultado es una *cota*, no una nulidad. Su análisis de sensibilidad: la banda completa de s_{func} base entre semillas es 0,0041, inflada por dos corridas atípicas (una alta, una baja, de signos opuestos); el núcleo sin ellas es 0,0017. El efecto (0,0013) queda dentro de ambas medidas, y la lectura pareada por semilla coincide con la lectura contra la media de las base salvo en las dos semillas atípicas —el doble pareo que las detecta—, de modo que efecto, ruido entre semillas y ruido de corrida son del mismo tamaño y ninguno se separa. La dura, en cambio, NO deja s_{func} quieto: lo desplaza $+0,052$ al alza —12,8 veces la banda, uniforme en las cinco semillas—, es decir, los mapas de atención se vuelven *más* parecidos entre cabezas mientras la geometría de pesos queda máximamente separada. La asimetría es ella misma un resultado: dos intervenciones sobre la misma geometría llegan casi al mismo $\theta_{\text{mín}}$ —gradiente sobre la penalización una, reproyección forzada sin retropropagación la otra— y una es inerte mientras la otra arrastra la función, según el mecanismo. La inercia que H1 establece es la de la *sonda de gradiente* a la intensidad fijada, no la de cualquier manipulación de esa geometría: forzar los pesos fuera de la trayectoria del optimizador paga en exactitud y mueve la similitud funcional. Detalle numérico de la sonda blanda: el gradiente de la SVD se degrada cerca de la convergencia; $\theta_{\text{mín}}$ satura hacia la época 6 pero s_{func} deriva hasta ~ 25 y se estabiliza después (desviación época a época 0,0007), y por eso las métricas se extraen de la ventana convergida (sección 5).

Tabla 4: Premisa, parte I: ablación del regularizador angular sobre la geometría de $\mathbf{W}_O$ (ImageNet-100 limpio, 30 épocas, media $\pm$ desviación entre 5 semillas; valores por corrida promediados sobre la ventana convergida). $\theta_{\text{mín}}$ es la separación angular mínima sin signo entre direcciones representativas, por capa y reportada como media entre capas (umbral $84,78^\circ$); la redundancia es angular ($|\cos|$ medio entre direcciones). La blanda separa con coste dentro de la banda entre semillas ($0,10 < 0,19$ pp) y desplazamiento de s_{func} acotado por esa misma dispersión; la dura clava el código pagando 4,40 pp y moviendo $s_{\text{func}} +0,052$ al alza: dos caminos al mismo $\theta_{\text{mín}}$, uno inerte y otro no, según el mecanismo.

Configuración	$\theta_{\text{mín}} \uparrow$	Redundancia $\downarrow$	Top-1 $\uparrow$	s_{func}
Base ($\lambda_A = 0$)	$51,96^\circ \pm 0,26$	$0,1724 \pm 0,0030$	$0,9284 \pm 0,0019$	$0,6945 \pm 0,0041$
Blanda ($\lambda_A = 10^{-3}$)	$85,01^\circ \pm 0,08$	$0,0338 \pm 0,0009$	$0,9274 \pm 0,0017$	$0,6958 \pm 0,0028$
Dura (reproyección)	$84,77^\circ \pm 0,00$	$0,0909 \pm 0,0000$	$0,8844 \pm 0,0021$	$0,7466 \pm 0,0049$

6.3. La intensidad fijada y la dependencia con λ

La inercia se establece a la intensidad fijada $\lambda = 10^{-3}$ (sección 6.2): $\theta_{\text{mín}}$ satura sin que s_{func} descienda del nivel base. Caracterizar la dependencia con λ sobre un rango más amplio queda como extensión, y exigiría el mismo aparato de lectura —cinco semillas por intensidad, contra el suelo de ruido entre semillas— que el apoyo a $\lambda = 10^{-3}$ ya consume. La cautela pertinente: a intensidad mucho mayor la sonda podría dejar de ser una perturbación inerte y empezar a deformar la representación, de modo que la indiferencia no se afirma fuera de la intensidad medida.

6.4. El sustrato de la atención se reubica hacia $Q \cdot K$ con la profundidad

Más allá de la no-identificabilidad de v_1 (sección 6.1), una caracterización por capa del modelo afinado muestra dónde reside la organización de la atención y por qué la geometría de $\mathbf{W}_O$ es inerte. Por cada capa se correlaciona la similitud funcional s_{func} —coseno entre mapas de atención promedio— con dos candidatas geométricas: el subespacio columna de $\mathbf{W}_O$ (similitud entre los espacios 768×64 por cabeza vía ángulos principales) y la interacción $Q \cdot K^\top$ (coseno entre los logits pre-softmax). La tabla 5 recoge ambas y la sola dirección dominante v_1 ; la figura 2 las traza por capa con su banda entre semillas.

El patrón es una inversión. En las capas tempranas el subespacio de $\mathbf{W}_O$ correlaciona con la función mientras $Q \cdot K$ no; a partir de la capa 5 el orden se invierte y $Q \cdot K$ pasa a dominar, creciendo hasta $\sim 0,9$ en las profundas. El cruce $r_{Q \cdot K} > r_{\mathbf{W}_O\text{-subesp.}}$ ocurre en la capa 5 en las cinco semillas, con $Q \cdot K$ encendiéndose de forma brusca entre la capa 4 y la 5 ($r_{Q \cdot K}$ de 0,026 a 0,51). La inversión es asimétrica — $Q \cdot K$ pasa de ≈ 0 a $\approx 0,9$ mientras $\mathbf{W}_O$ estaba apenas por encima del ruido— e independiente del regularizador: bajo la variante blanda el cruce permanece en la capa 5 y $r_{Q \cdot K}$ es indiferente a la regularización (máximo $|\Delta| = 0,043$). La dirección dominante v_1 que el regularizador de pesos toca no participa del cruce: es baja o negativa en casi toda la profundidad, traza función solo en la transición de las capas 3–4. Esa traza es real en el gauge que el entrenamiento fijó, pero no identificable (sección 6.1): otro gauge la borraría sin tocar la función, de modo que no contradice la no-identificabilidad de v_1 —la ilustra, es el punto mismo de que la lectura por v_1 depende del gauge—. Esta es la razón medida de la inercia: el regularizador de pesos optimiza un objeto que no gobierna la organización de la atención.

Sobre ViT-L ($n=3$, 24 capas) el cruce sostenido existe en las tres semillas —capas 8, 11 y 8, a profundidad relativa del 33 al 46 %, comparable al 42 % de la ancla— y supera dos de los tres listones: el salto en la capa del cruce es +0,403 (listón $\geq 0,30$) y el margen +0,366 (listón $\geq 0,15$). El predominio profundo queda en +0,375, por debajo de la banda $\geq 0,40$, y el desenlace conjuntivo es en consecuencia ambiguo. El diagnóstico denota una causa localizada: la capa 23 arrastra el mínimo en las tres semillas —+0,43, +0,41 y +0,28— mientras las capas 16 a 22 lo superan en todas (+0,61 a +0,63); en la ancla el último tercio no presentaba esa caída. La capa final no se excluye del cómputo del listón, fijado antes del dato; se reporta el listón como salió y su causa junto a él.

La reubicación NO transfiere a la columna congelada. Sobre DINOv2 (24 capas, $n=1$ declarado), los listones fijados antes del dato fallan en tres de cuatro: el cruce sostenido solo aparece desde la capa 22, con un salto de +0,223 en ese punto (banda), el margen es +0,009 (listón $\geq 0,15$, falla) y el predominio profundo no existe —mínimo $r_{Q \cdot K}$ del último tercio $-0,059$ frente al listón $\geq 0,4$, falla—: en el backbone autosupervisado puro, $r_{Q \cdot K}$ no despega en ninguna banda de profundidad. H3, tal como se preregistró para las tres columnas, no se sostiene en el régimen congelado.

La reubicación queda así acotada al régimen afinado supervisado: limpia en la ancla, sostenida y matizada en la columna profunda, ausente en la congelada. H3, preregistrada como reproducible en las tres columnas, no se sostiene en esos términos.

6.5. El portador de residuo se inclina del inerte sin desligarse

La firma de respuesta gauge-invariante (sección 4.2) se define sobre la contribución al residuo, no sobre $v_1(\mathbf{W}_O)$; un diagnóstico previo, sin reentrenar, mide cuánto se separan. Por capa se compara la firma computada $v_1(\mathbf{A}_h \mathbf{V}_h \mathbf{W}_O)$ de cada cabeza con su firma estática $v_1(\mathbf{W}_O)$ —el ángulo *emparejado*—, contra el nulo de permutación —la firma computada de h frente a la estática de $h' \neq h$ —. Ambas viven en el espacio fila de $\mathbf{W}_O$, de 64 dimensiones, de modo que el azar es la permutación dentro de ese subespacio, no el de $\mathbb{R}^{768}$; ambas firmas se calculan por SVD exacta.

El ángulo emparejado queda en todas las capas por debajo del nulo y nunca en cero (tabla 6): la firma computada se inclina de verdad respecto a la estática —el contenido valor/atención la mueve, el portador de residuo no colapsa sobre el inerte, que era la condición go/no-go— pero sigue siendo más parecida a su propia cabeza que a las demás, es decir, específica de cada

Tabla 5: Premisa, parte II: correlación de Spearman entre s_{func} y dos candidatas geométricas, por capa (variante base, media entre 5 semillas; $r_{Q \cdot K}$ no depende de k). El subespacio se mide a $k = 64$; v_1 es la sola dirección dominante. El baseline aleatorio del subespacio a $k = 64$ es $\approx 0,25$; el de $Q \cdot K$, ≈ 0 . El cruce hacia $Q \cdot K$ en la capa 5 marca dónde la organización deja la escritura residual y pasa a la comparación consulta-clave.

Capa	r_{W_O} (subesp.)	$r_{W_O} (v_1)$	$r_{Q \cdot K}$
0	+0,439	+0,185	-0,104
1	+0,456	+0,075	+0,189
2	+0,503	+0,094	+0,233
3	+0,470	+0,463	+0,212
4	+0,341	+0,223	+0,026
5	+0,150	-0,005	+0,510
6	+0,176	-0,096	+0,296
7	+0,069	+0,038	+0,720
8	+0,058	-0,168	+0,811
9	-0,198	-0,313	+0,907
10	-0,041	-0,340	+0,770
11	+0,089	-0,108	+0,832

cabeza. La brecha se modula con la profundidad —de 24° en la capa 1 a 39° en la 2— con dos irregularidades reproducibles entre semillas: en la capa 8 el nulo cae a $73,1^\circ$ frente a los $\sim 86^\circ$ del resto —las direcciones estáticas $v_1(W_O)$ de cabezas distintas se parecen entre sí ahí— y en la capa 11 emparejado y nulo caen juntos ($23,5^\circ$ y $51,9^\circ$), con todo el patrón desplazado hacia abajo. Ambas son propiedades de la firma estática en el gauge que el entrenamiento fijó —no identificables, como toda lectura por $v_1(W_O)$ (sección 6.1)—, de modo que se nombran como rasgos del diagnóstico, no como redundancia ni convergencia funcional. Es un diagnóstico del portador, no la inversión de sección 6.4, y se reporta como tal.

Tabla 6: Diagnóstico computado/estático del portador de residuo, sin reentrenar (media $\pm$ desviación entre 5 semillas, conjunto congelado de 1000 imágenes). Ángulo emparejado (firma computada de h vs estática de h) frente al nulo de permutación (vs estática de $h' \neq h$), en grados. El emparejado por debajo del nulo en toda capa, y nunca en cero, denota que el portador de residuo se inclina del inerte sin desligarse.

Capa	Emparejado	Nulo de permutación
0	$43,0 \pm 1,2$	$77,2 \pm 0,2$
1	$60,4 \pm 1,2$	$84,4 \pm 0,1$
2	$46,6 \pm 2,5$	$85,6 \pm 0,1$
3	$50,8 \pm 3,1$	$87,0 \pm 0,1$
4	$50,8 \pm 4,2$	$87,5 \pm 0,1$
5	$59,5 \pm 3,3$	$86,7 \pm 0,2$
6	$52,3 \pm 2,7$	$85,6 \pm 0,2$
7	$64,4 \pm 3,7$	$85,3 \pm 0,2$
8	$44,2 \pm 1,2$	$73,1 \pm 0,7$
9	$49,6 \pm 3,7$	$86,6 \pm 0,2$
10	$52,3 \pm 2,7$	$82,8 \pm 0,5$
11	$23,5 \pm 2,2$	$51,9 \pm 1,6$




Figura 2: Premisa, parte II (visual de tabla 5): correlación de Spearman entre s_{func} y las candidatas geométricas por capa, media entre 5 semillas; las barras son ± 1 desviación típica. El subespacio de $\mathbf{W}_O$ ($k=64$) correlaciona en las tempranas y se hunde con la profundidad; $Q \cdot K$ arranca en el ruido, se enciende de forma brusca en la *costura* de la capa 5 ($0,026 \rightarrow 0,51$) y domina hasta $\sim 0,9$. La $Q \cdot K$ de la variante blanda (punteada) cae sobre la base: el cruce no depende del regularizador de pesos. Las líneas de puntos marcan los baselines aleatorios ($\approx 0,25$ el subespacio, ≈ 0 para $Q \cdot K$).

6.6. La similitud no es un criterio de poda; la estabilidad sí es del instrumento

Un benchmark mínimo acota qué compra el instrumento y qué no. Con el mismo presupuesto ($k=2$ cabezas por capa, 24 de 144) y el mismo mecanismo de poda —anular las columnas de la cabeza en la proyección de salida—, se poda el conjunto más redundante según cada criterio y se mide la caída de top-1 sobre el val completo (tabla 7). Ningún criterio de similitud bate al suelo aleatorio: la selección por pesos cae dentro de su banda ($3,13 \pm 0,54$ frente a $3,25 \pm 0,19$) —coherente con que elegir por $\mathbf{v}_1(\mathbf{W}_O)$ es elegir por ruido de gauge—, y la selección por firma daña *más* que el azar ($4,26 \pm 0,29$). El diagnóstico explica por qué: ambos criterios seleccionan cabezas de contribución grande al residuo ($2,7 \times$ la energía media de las restantes), y las que la firma agrupa son además individualmente más costosas (podando media pareja cada vez, la suma de mitades ya es 3,72 frente a 2,90 pp en pesos, con superaditividad similar en ambos, $+0,8/+0,9$ pp). La similitud —de gauge o funcional— no equivale a redundancia prescindible: cabezas con firmas parecidas son centrales, no sobrantes. El enunciado aplicado, para la práctica, junta los dos certificados: la decisión por $\mathbf{v}_1(\mathbf{W}_O)$ no admite radio certificado positivo —el gauge la fabrica a voluntad (proposición 1 y tabla 3)— y la decisión por firma es invariante; pero ninguna de las dos similitudes selecciona qué podar mejor que el azar a este presupuesto. La ventaja del instrumento es la *decisión estable* bajo reparametrización, no la selección; qué podar exige criterios de importancia, fuera del alcance de este análisis.

Tabla 7: Poda por criterio, sin reentrenar (5 semillas base; $k=2$ cabezas por capa, 24 de 144; media $\pm$ banda entre semillas; el criterio aleatorio promedia tres sorteos fijados por semilla). El mecanismo de poda es idéntico para los tres criterios. Ninguna similitud bate al suelo aleatorio; el papel del instrumento es la estabilidad de la decisión, no la selección.

Criterio	Top-1 podado	Caída (pp)
$\mathbf{v}_1(\mathbf{W}_O)$ (pesos)	0,898	$3,13 \pm 0,54$
Firma $\mathbf{v}_1(\mathbf{C}_h^P)$	0,887	$4,26 \pm 0,29$
Aleatorio (suelo)	0,896	$3,25 \pm 0,19$

7. Discusión y limitaciones

Los tres brazos, leídos juntos. Gauge, sonda y variante dura no son tres resultados sueltos: caracterizan, a tres intensidades crecientes de intervención sobre el sector valor-salida, el acoplamiento entre esa geometría y la función. La intervención más libre —el gauge, que no toca la función por construcción— mueve la geometría al máximo sin coste; la intervención intermedia —la sonda, que sí entrena— también la mueve sin coste; solo la más agresiva —la variante dura, que impone el simplex en cada paso— paga en función. Que el daño aparezca justo donde la intervención dejó de ser un gauge y empezó a ser una restricción activa sobre la trayectoria del optimizador es el propio dato distinguiendo “reparametrización” de “manipulación”, no una lectura a posteriori. La asimetría conecta con la reubicación: si la función no habita $\mathbf{v}_1(\mathbf{W}_O)$, y la organización de la atención sí correlaciona con $Q \cdot K$ en el régimen afinado, la pregunta constructiva —qué componente gobierna la función, si no esa dirección— queda planteada, no respondida; la atribución por componente sobre $Q \cdot K$ es la continuación natural (secciones 6.2 y 6.4).

Qué afirma el resultado y qué no. La afirmación es negativa y acotada: la geometría de la proyección de salida — $\mathbf{v}_1(\mathbf{W}_O)$, la dirección que la poda por redundancia y la interpretación por dirección dominante leen— no porta la función de la cabeza. No es identificable bajo el gauge del sector valor-salida, separarla no mueve la similitud funcional, y la organización de la atención reside en otro sustrato. El trabajo no afirma lo contrario de eso: no sostiene que exista un portador de pesos accionable, ni que $Q \cdot K$ sea el único sustrato de la función —esa lectura es correlacional—, ni que la firma de respuesta agote la diversidad disponible. Intervenir de forma constructiva sobre $Q \cdot K$, o sobre la firma de respuesta, es la continuación natural, no un resultado de este trabajo.

Implicaciones para la poda y la interpretación. Una parte de la poda de cabezas decide la redundancia comparando direcciones representativas de $\mathbf{W}_O$, y una parte de la interpretación mecanicista lee el papel de una cabeza desde su dirección dominante de pesos. La sección 6.1 muestra que esas comparaciones operan sobre una cantidad no identificable: dos modelos funcionalmente idénticos exhiben separaciones distintas entre sus $\mathbf{v}_1(\mathbf{W}_O)$ según el gauge, de modo que la redundancia angular medida sobre pesos es, en parte, un artefacto de reparametrización, y la decisión que produce cambia de hecho bajo gauge (tabla 3). La firma de respuesta gauge-invariante (sección 4.2) ofrece la cantidad que esas tareas necesitan como *medida*: diversidad de cabezas anclada al circuito identificable, que no se mueve al reparametrizar y es específica de cada cabeza (sección 6.5). Con una acotación medida: estabilidad no es criterio de selección —ninguna similitud, de gauge o funcional, bate al suelo aleatorio como regla de poda a presupuesto fijo (tabla 7); decidir *qué* podar sigue pidiendo criterios de importancia como los de segundo orden [14, 15], sobre los que este análisis no se pronuncia—.

Especialización emergente, no estructural. Si las cabezas se especializan funcionalmente [8, 9], los resultados sugieren que esa especialización es *emergente* —propiedad del comportamiento computado— más que *estructural* —recuperable de la geometría dominante de los pesos de salida—. Un trabajo vecino que regulariza la diversidad sobre los gradientes de entrada —señal ligada al comportamiento— altera la función y mejora la generalización OOD [10], mientras que intervenir sobre la geometría de pesos no la mueve: el contraste sitúa el efecto en la señal funcional, no en el resumen estático de los pesos.

Límites. La no-identificabilidad es de forma cerrada y no depende de la arquitectura; la inercia y la reubicación viven en ella, y se contrastan por eso sobre tres columnas (tabla 1): dos escalas del ratio cabezas/dimensión —ViT-B y ViT-L— y dos regímenes de entrenamiento —supervisado y autosupervisado, este último con DINOv2 congelado—. Que los cuatro apoyos aparezcan también a otra escala y bajo autosupervisión separa “propiedad de la atención global” de “artefacto del afinado supervisado de una sola columna”, una pregunta que una arquitectura sola no podía

responder. El borde declarado es la atención no-global: en Swin y la atención por ventana la no-identificabilidad sí transferiría —el gauge valor-salida es estructural—, pero el mapa local por ventana desplazada, el sesgo de posición relativa en los logits y la profundidad jerárquica por etapas obligan a rederivar s_{func} y la noción misma de profundidad antes de medir inercia o reubicación; queda como extensión, no como agujero de rigor. La lectura de la reubicación hacia $Q \cdot K$ es correlacional —Spearman entre s_{func} y candidatas geométricas por capa—, no causal, y la elección del primer vector singular de $\mathbf{C}_h^P$ como firma, frente a otros resúmenes de la respuesta, es una decisión de diseño cuyo contraste con el centrado por parche acota su sensibilidad sin agotarla. El listón del predominio profundo heredó de la ancla la asunción de que el último tercio de capas es homogéneo; ViT-L la rompe en su capa final, y la asunción queda declarada como límite del criterio, no corregida a posteriori.

8. Conclusión

Tres intensidades de intervención sobre el sector valor-salida caracterizan el acoplamiento entre su geometría y la función de una cabeza de atención, y el acoplamiento es unidireccional. Bajo el gauge libre, la dirección dominante $\mathbf{v}_1(\mathbf{W}_O)$ —la que la poda por redundancia y la interpretación por dirección dominante leen— se desplaza a voluntad sin tocar la función; bajo la sonda que la separa angularmente hasta el símplex, tampoco; solo al imponer ese símplex por construcción la función se resiente. La explicación del extremo inerte es de forma cerrada: $\mathbf{v}_1(\mathbf{W}_O)$ no es identificable bajo ese gauge, que la desplaza —hasta 0,91 de deriva— mientras la salida y el circuito $OV \mathbf{W}_v \mathbf{W}_O$ permanecen en el suelo numérico de la doble precisión, invariancia que se verifica idéntica en las tres columnas, incluida la autosupervisada congelada. La consecuencia no es cautela: ningún umbral de similitud sobre $\mathbf{v}_1(\mathbf{W}_O)$ admite radio certificado positivo, y dos modelos funcionalmente idénticos podan conjuntos distintos de cabezas —el par más redundante cambia en el 92,7 % de los casos sobre el ViT afinado y en más del 90 % sobre un transformer de lenguaje sin entrenar nada, y el solape del conjunto de poda cae a 0,378 en el ancla—, mientras la misma decisión tomada sobre la firma de respuesta permanece intacta.

Separar angularmente esa dirección hasta el umbral del símplex no mueve la similitud funcional. La sonda eleva $\theta_{\min}$ de 52° a 85° en la ancla y de 63° a 86° en la columna profunda, y el desplazamiento de s_{func} permanece del orden de la dispersión entre semillas en ambas, con el signo invertido entre ellas —+0,0013 y −0,0019—. El mismo criterio distingue el caso contrario: la variante dura, que impone el símplex por construcción, desplaza s_{func} +0,052 y +0,031 —doce y treinta y una veces la banda, mismo signo en ambas— al precio de 4,4 y 5,6 puntos de exactitud. La inercia de la sonda blanda no es, por tanto, incapacidad de la medida.

La reubicación de la organización de la atención hacia $Q \cdot K$ con la profundidad se acota a su régimen. Es limpia en la ancla —cruce en la capa 5, cinco de cinco semillas, los tres listones superados—, sostenida pero matizada en ViT-L —cruce en las capas 8 a 11 de 24, a profundidad relativa comparable, con salto y margen limpios y el predominio profundo en fallo por la capa final— y ausente en el DINOv2 congelado, donde $r_{Q \cdot K}$ no despegas en ninguna banda de profundidad. H3, tal como se preregistró para las tres columnas, no se sostiene: la lectura que el dato admite es que el afinado supervisado, y no la atención global por sí misma, produce la reubicación.

Queda, por tanto, un resultado de dos velocidades, y conviene leerlo como tal. La no-identificabilidad y la inercia son de forma cerrada la primera y reproducidas en dos escalas la segunda; la reubicación es correlacional y de régimen. Para quien poda, interpreta o enruta por la geometría de $\mathbf{W}_O$, la implicación no depende de cuál de las dos velocidades se mire: la cantidad que se está leyendo es la elección de gauge que el entrenamiento fijó por accidente, y la firma de respuesta $\mathbf{v}_1(\mathbf{C}_h^P)$ —invariante y específica de cada cabeza en las tres columnas— es la que ocupa su lugar.

A. La órbita de gauge de $v_1(W_O)$, medida

Este apéndice certifica numéricamente la proposición 1 sobre los pesos reales de las cinco base de ViT-B, sin reentrenar y en CPU.

Banda por par. Para cada capa y cada par de cabezas (h, h') se computan los ángulos principales entre los espacios fila $\mathcal{S}_h$ y $\mathcal{S}_{h'}$ (SVD de $\mathbf{B}_h^\top \mathbf{B}_{h'}$ con $\mathbf{B}$ las bases ortonormales de fila). El primer ángulo principal es el suelo de la órbita conjunta —ningún gauge puede acercar las direcciones dominantes por debajo de él— y el techo es 90° (con $d_h + d_{h'} \ll d$ siempre existen pares ortogonales). Sobre $66 \text{ pares} \times 12 \text{ capas} \times 5 \text{ semillas}$: suelo mínimo global $14,7^\circ$, y $\theta^* = 84,78^\circ$ dentro de la banda de los 3960 pares.

Realización explícita. Para un par por semilla se construye el gauge que lleva cada v_1 a su objetivo (el par de direcciones de mínimo ángulo entre los dos subespacios): la deriva del circuito OV queda en $\sim 2 \times 10^{-15}$ —invariancia a precisión de máquina— con las direcciones dominantes desplazadas decenas de grados.

Certificado simultáneo. La banda por par no basta para el regularizador, que impone 66 restricciones acopladas sobre 12 direcciones. Un descenso restringido a los espacios fila —coordenadas libres en la base de cada $\mathcal{S}_h$, penalización sobre $|\cos| > 1/(H-1)$ — encuentra en las 60 combinaciones capa $\times$ semilla una configuración conjunta con $\theta_{\min} \geq \theta^*$ (peor caso $84,79^\circ$). El cumplimiento total del regularizador está en la órbita de gauge conjunta: existe un camino de coste funcional exactamente cero hasta él, y la inercia de la sección 6.2 es “no hubo cambio pese a existir un camino libre”, no “no se observó cambio”.

Referencias

- [1] R. A. Rankin. The closest packing of spherical caps in n dimensions. *Proceedings of the Glasgow Mathematical Association*, 2(3):139–144, 1955.
- [2] V. Pappas, X. Y. Han y D. L. Donoho. Prevalence of neural collapse during the terminal phase of deep learning training. *Proceedings of the National Academy of Sciences*, 117(40):24652–24663, 2020.
- [3] Z. Zhu, T. Ding, J. Zhou, X. Li, C. You, J. Sulam y Q. Qu. A geometric analysis of neural collapse with unconstrained features. *Advances in Neural Information Processing Systems* (NeurIPS), 2021.
- [4] F. Pernici, M. Bruni, C. Baecchi y A. Del Bimbo. Regular polytope networks. *IEEE Transactions on Neural Networks and Learning Systems*, 2021.
- [5] W. Liu, Y. Wen, Z. Yu, M. Li, B. Raj y L. Song. SphereFace: deep hypersphere embedding for face recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [6] H. Wang, Y. Wang, Z. Zhou, X. Ji, D. Gong, J. Zhou, Z. Li y W. Liu. CosFace: large margin cosine loss for deep face recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [7] J. Deng, J. Guo, N. Xue y S. Zafeiriou. ArcFace: additive angular margin loss for deep face recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [8] P. Michel, O. Levy y G. Neubig. Are sixteen heads really better than one? *Advances in Neural Information Processing Systems* (NeurIPS), 2019.

- [9] E. Voita, D. Talbot, F. Moiseev, R. Sennrich y I. Titov. Analyzing multi-head self-attention: specialized heads do the heavy lifting, the rest can be pruned. *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2019.
- [10] A. M. Nicolicioiu, A. L. Nicolicioiu, B. Alexe y D. Teney. Learning diverse features in vision transformers for improved generalization. *ICML 2023 Workshop on Spurious Correlations, Invariance and Stability*, 2023.
- [11] A. Dosovitskiy, L. Beyer, A. Kolesnikov *et al.* An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR)*, 2021.
- [12] A. Vaswani, N. Shazeer, N. Parmar *et al.* Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [13] X. Pan, A. Philip, Z. Xie y O. Schwartz. Dissecting query-key interaction in vision transformers. *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2405.14880.
- [14] H. Yang, H. Yin, M. Shen, P. Molchanov, H. Li y J. Kautz. Global vision transformer pruning with Hessian-aware saliency. *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [15] M. H. Uddin, L. Seymour y S. Baidya. HEART-ViT: Hessian-guided efficient dynamic attention and token pruning in vision transformer. *arXiv preprint* arXiv:2512.20120, 2025.
- [16] S. Biderman, H. Schoelkopf, Q. G. Anthony, H. Bradley, K. O’Brien, E. Hallahan, M. A. Khan, S. Purohit, U. S. Prashanth, E. Raff, A. Skowron, L. Sutawika y O. van der Wal. Pythia: a suite for analyzing large language models across training and scaling. *International Conference on Machine Learning (ICML)*, 2023.
- [17] A. Ahmad, A. Joshi y A. Modi. Beyond components: singular vector-based interpretability of transformer circuits. *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [18] G. Franco, C. Loughridge y M. Crovella. Singular vectors of attention heads align with features. *arXiv preprint* arXiv:2602.13524, 2026.
- [19] H. Yamagiwa, Y. Takase y H. Shimodaira. Measuring affinity between attention-head weight subspaces via the projection kernel. *arXiv preprint* arXiv:2601.10266, 2026.
- [20] S. Ashkboos, A. Mohtashami, M. L. Croci, B. Li, P. Cameron, M. Jaggi, D. Alistarh, T. Hoefer y J. Hensman. QuaRot: outlier-free 4-bit inference in rotated LLMs. *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [21] Z. Liu, C. Zhao, I. Fedorov, B. Soran, D. Choudhary, R. Krishnamoorthi, V. Chandra, Y. Tian y T. Blankevoort. SpinQuant: LLM quantization with learned rotations. *International Conference on Learning Representations (ICLR)*, 2025.