

# Separación angular máxima en Transformers de visión: códigos esféricos para una atención diversa y una detección generalizable de medios sintéticos

Manuel Muñoz Plá

Investigador independiente — Mairena del Aljarafe, Sevilla, España

ORCID: 0009-0000-5714-912X | mmunozpl@uoc.edu

Borrador — 28 de mayo de 2026

## Resumen

La atención multi-cabeza de los Transformers de visión tiende a acomodar varias cabezas sobre patrones redundantes, y los detectores de medios sintéticos pierden exactitud frente a generadores no observados durante el entrenamiento. Ambos problemas comparten una raíz geométrica: la disposición de un conjunto de direcciones en el espacio de representación. Este trabajo propone gobernar esa disposición mediante *códigos esféricos* —conjuntos de direcciones unitarias sobre la hiperesfera con separación angular mínima maximizada— y deriva dos contribuciones. La primera regulariza las direcciones representativas de las cabezas de atención hacia una configuración de máxima separación, con el objetivo de reducir la redundancia entre cabezas sin alterar la arquitectura ni añadir parámetros. La segunda fija los prototipos de un clasificador por generador sobre un código esférico, de modo que el espacio angular no ocupado denota un margen explícito para el rechazo de generadores nuevos en régimen de conjunto abierto. El marco se ancla en el fenómeno de *neural collapse* y emplea el *kissing number* como caso exacto de validación geométrica. La evaluación, aún pendiente, contempla ImageNet para la diversidad de atención y el conjunto GenImage con protocolo *leave-one-generator-out* para la detección generalizable. **[PENDIENTE: cifras del resumen tras los experimentos]**

**Palabras clave:** códigos esféricos, separación angular, atención multi-cabeza, neural collapse, detección de medios sintéticos, conjunto abierto.

## 1. Introducción

El Transformer de visión ha desplazado a la red convolucional como arquitectura de referencia en clasificación de imagen, y su mecanismo de atención multi-cabeza se presenta habitualmente como una vía para que el modelo atienda, en paralelo, a distintas relaciones espaciales. La evidencia empírica matiza esa lectura: una parte de las cabezas converge sobre patrones de atención casi indistinguibles, de manera que la capacidad nominal de la capa no se traduce en diversidad efectiva. Podar cabezas tras el entrenamiento apenas degrada la exactitud, lo que denota que la redundancia no es marginal sino estructural.

En un dominio aparentemente alejado, la detección de medios sintéticos afronta un problema distinto pero igual de persistente. Un detector entrenado sobre las imágenes de un conjunto de generadores alcanza una exactitud elevada dentro de ese conjunto y la pierde al enfrentarse a un generador no observado. El problema abierto del campo no es la exactitud intradominio, ya saturada, sino la generalización a arquitecturas generativas nuevas, que aparecen a un ritmo que ningún conjunto de entrenamiento cerrado puede seguir.

Estos dos problemas, la redundancia de la atención y la fragilidad ante lo no observado, comparten una raíz que no es evidente a primera vista: en ambos casos lo que está en juego es *cómo se disponen un conjunto de direcciones* en un espacio de representación. Las cabezas de atención pueden caracterizarse por una dirección representativa; las clases o los generadores,

por la dirección del prototipo que el modelo les asigna. Cuando esas direcciones se amontonan, la capacidad se desaprovecha y las fronteras de decisión se vuelven frágiles. Cuando se separan al máximo, cada elemento ocupa una región propia y bien aislada, y el espacio sobrante queda disponible para lo que el entrenamiento no preveía.

La geometría que formaliza esa disposición ideal es la de los *códigos esféricos*: conjuntos de direcciones unitarias sobre la hiperesfera elegidos de modo que el menor de los ángulos entre pares sea lo mayor posible. Su caso límite —el número máximo de direcciones que admiten una separación angular dada— es el *kissing number*, un objeto clásico de la geometría de empaquetamientos. Y su contrapartida en redes neuronales es el fenómeno de *neural collapse*: las direcciones de clase, sin instrucción explícita, se separan al final del entrenamiento hasta configurar un marco equiangular. La idea de este trabajo es no esperar a que la red descubra esa configuración, sino entregársela fijada de antemano.

**Contribuciones.** El trabajo desarrolla dos intervenciones geométricas sobre el Transformer de visión y un protocolo de evaluación:


1. Un **regularizador de atención angularmente diversa** (sección 4.2) que conduce las direcciones representativas de las cabezas hacia una configuración de separación angular máxima, sin modificar la arquitectura ni incrementar el número de parámetros.
2. Una **cabeza de prototipos por generador** (sección 4.3) cuyas direcciones de clase se fijan sobre un código esférico, de modo que el espacio angular no asignado actúa como región de rechazo para generadores no observados, tratando la detección de medios sintéticos como un problema de conjunto abierto.
3. Un **protocolo de validación geométrica** (sección 4.1) que verifica el procedimiento de generación de códigos contra las configuraciones óptimas conocidas en las dimensiones 2, 3, 4, 8 y 24, y un **protocolo de evaluación** (sección 5) con separación *leave-one-generator-out* sobre el conjunto GenImage.

## 2. Trabajo relacionado

**Códigos esféricos y empaquetamientos.** La distribución de puntos sobre la esfera con separación máxima es un problema clásico, planteado en su forma física por Thomson y en su forma geométrica por Tammes. El *kissing number* —el mayor número de esferas unitarias que pueden tocar a una esfera central sin solaparse— se conoce de forma exacta solo en las dimensiones 1, 2, 3, 4, 8 y 24, estas dos últimas gracias a los retículos  $E_8$  y de Leech [1]. Para dimensiones y cardinalidades arbitrarias se recurre a códigos casi óptimos obtenidos por minimización de energías de repulsión [2].

**Neural collapse y clasificadores fijos.** El fenómeno de *neural collapse* [3] describe cómo, en la fase final del entrenamiento, las medias de clase y los vectores del clasificador convergen a un marco equiangular ajustado. Trabajos posteriores [4] lo analizan bajo el modelo de características no restringidas. Esta regularidad ha motivado el uso de clasificadores *fijos* con geometría predeterminada [5], que ahorran parámetros y estabilizan el entrenamiento. El presente trabajo se sitúa en esa línea, pero sustituye el marco equiangular por un código esférico general y lo extiende a las proyecciones de atención.

**Márgenes angulares.** SphereFace [6], CosFace [7] y ArcFace [8] introdujeron márgenes sobre el ángulo entre la característica y el prototipo de clase. Estos métodos operan sobre una geometría angular, pero estiman los prototipos durante el entrenamiento; aquí los prototipos se fijan con separación garantizada.



**Figura 1:** Esquema bidimensional de un código esférico sobre  $\mathbb{S}^{d-1}$ . Cada dirección unitaria  $u_i$  corresponde a una clase, una cabeza de atención o un generador. La calidad del código se mide por la separación angular mínima  $\theta_{\min}$ , el menor de los ángulos entre pares; un buen código la maximiza.

**Redundancia de la atención multi-cabeza.** El análisis de la atención multi-cabeza ha mostrado que muchas cabezas son prescindibles [9] y que cumplen funciones especializadas e identificables [10]. La diversidad entre cabezas se ha promovido habitualmente con penalizaciones *ad hoc*; este trabajo la encuadra como un problema de separación angular sobre la hiperesfera.

**Detección de imagen sintética.** La detección de imagen generada por modelos generativos [13] y, más recientemente, por modelos de difusión [14] se enfrenta a una caída de exactitud al cambiar de generador. El conjunto GenImage [15] reúne imágenes de múltiples generadores y habilita la evaluación de generalización a arquitecturas no observadas; estrategias como DRCT [16] abordan explícitamente esa transferencia. Ninguna de estas líneas trata la detección como un problema geométrico de conjunto abierto sobre un código esférico, que es la posición de este trabajo.

### 3. Marco teórico

#### 3.1. La hiperesfera: una intuición previa

Cuando varios elementos idénticos que se repelen quedan confinados sobre una superficie cerrada, no se distribuyen al azar: se acomodan hasta alcanzar el reposo en que la fuerza neta se anula. Los electrones sobre una esfera conductora —el problema que Thomson planteó en 1904— y las semillas en el capítulo del girasol obedecen al mismo principio: cada elemento ocupa la posición que maximiza su distancia angular a los demás. Ese reposo no es un acto de cómputo, sino el residuo de una repulsión que se ha dejado actuar hasta el final. De un proceso enteramente continuo emergen, sin embargo, cantidades enteras —los doce vecinos del empaquetamiento tridimensional, los términos de Fibonacci de la espiral—; el número de elementos no se impone desde fuera, sino que queda inscrito en la geometría del acomodo. Una red neuronal, al separar sus clases en el espacio de representación, reproduce ese mismo reposo: las direcciones asociadas a cada clase se distancian entre sí hasta configurar una disposición de separación angular máxima, fenómeno que la literatura reciente denota con el término *neural collapse*. La diferencia con los sistemas físicos abre una oportunidad: donde la naturaleza requiere todo el proceso de relajación para alcanzar esa configuración, un modelo puede recibirla fijada de antemano. Las páginas siguientes formalizan esa configuración sobre la hiperesfera unitaria  $\mathbb{S}^{d-1}$  y precisan la noción de separación angular mínima entre pares de direcciones.

### 3.2. Códigos esféricos y separación angular

**Definición 1** (Código esférico). *Un código esférico de tamaño  $K$  en dimensión  $d$  es un conjunto  $\mathcal{C} = \{\mathbf{u}_1, \dots, \mathbf{u}_K\} \subset \mathbb{S}^{d-1}$  de direcciones unitarias. Su separación angular mínima es*

$$\theta_{\min}(\mathcal{C}) = \min_{i \neq j} \arccos(\langle \mathbf{u}_i, \mathbf{u}_j \rangle). \quad (1)$$

El objetivo es hallar  $\mathcal{C}^*$  que maximice  $\theta_{\min}$ . El mínimo sobre pares no es diferenciable, por lo que en la práctica se optimiza una energía de repulsión equivalente. Para un exponente  $s > 0$ , la energía de Riesz

$$E_s(\mathcal{C}) = \sum_{i \neq j} \|\mathbf{u}_i - \mathbf{u}_j\|^{-s} \quad (2)$$

penaliza la proximidad entre direcciones; sus mínimos aproximan, al crecer  $s$ , las configuraciones de separación angular máxima [2]. La minimización de ecuación (2) sobre la hipersfera admite descenso de gradiente proyectado y constituye el procedimiento de generación de códigos de sección 4.1.

### 3.3. El kissing number como caso exacto

El *kissing number*  $\tau(d)$  es el mayor número de esferas unitarias que pueden tocar simultáneamente a una esfera unitaria central sin solaparse entre sí. Se conoce de forma exacta solo en dimensiones contadas:  $\tau(2) = 6$ ,  $\tau(3) = 12$ ,  $\tau(4) = 24$ ,  $\tau(8) = 240$  y  $\tau(24) = 196\,560$  [1]. La conexión con los códigos esféricos es directa.

**Proposición 1** (Cota de capacidad angular). *El número máximo de direcciones unitarias en  $\mathbb{R}^d$  con separación angular mínima mayor o igual que  $\pi/3$  es exactamente el kissing number  $\tau(d)$ .*

*Justificación.* Para dos direcciones unitarias,  $\|\mathbf{u}_i - \mathbf{u}_j\|^2 = 2 - 2\cos\theta_{ij}$ , de modo que  $\theta_{ij} \geq \pi/3$  equivale a  $\cos\theta_{ij} \leq \frac{1}{2}$  y a  $\|\mathbf{u}_i - \mathbf{u}_j\| \geq 1$ . Las bolas de radio  $\frac{1}{2}$  centradas en los extremos  $\mathbf{u}_i$  no se solapan y todas son tangentes a la esfera de radio  $\frac{1}{2}$  centrada en el origen; su número máximo es, por definición,  $\tau(d)$  [1].  $\square$

Proposición 1 delimita el papel del kissing number en este trabajo. No es la herramienta operativa —las dimensiones reales del modelo no son 8 ni 24, ni la cardinalidad de clases coincide con un  $\tau(d)$ —, sino el caso exacto que enmarca el objeto general. El código esférico es lo que la red emplea; el kissing number es la referencia contra la que se valida el procedimiento que lo genera y la cota que acota su capacidad.

### 3.4. Dos regímenes: holgado y saturado

La separación angular alcanzable por un código de  $K$  direcciones en  $\mathbb{S}^{d-1}$  depende de la relación entre  $K$  y  $d$ , y conviene distinguir dos regímenes porque el modelo opera en uno solo de ellos.


**Régimen holgado** ( $K \leq d + 1$ ). Cuando el número de direcciones no supera  $d + 1$ , existe el *símplex regular*: la configuración en que todos los pares forman el mismo ángulo, máximo posible. Sumando las  $K$  direcciones unitarias y observando que la norma al cuadrado es no negativa,

$$0 \leq \left\| \sum_h \mathbf{u}_h \right\|^2 = K + \sum_{h \neq h'} \langle \mathbf{u}_h, \mathbf{u}_{h'} \rangle, \quad (3)$$

se obtiene, para una configuración equiangular de ángulo  $\theta$ , la cota  $\cos\theta \geq -1/(K - 1)$ , alcanzada con igualdad por el símplex:

$$\theta_{\text{símplex}}(K) = \arccos\left(-\frac{1}{K-1}\right). \quad (4)$$

Esta separación óptima depende solo de  $K$ , no de  $d$ : una vez que la dimensión alcanza  $d = K - 1$ , añadir más dimensiones deja espacio sin usar pero no mejora el ángulo. La ecuación (4) es



**Figura 2:** Los dos regímenes en dimensión  $d=2$ , donde la configuración es exacta y representable. Con pocas direcciones para el espacio disponible (izquierda,  $K=3$ ) el simplex las separa al máximo, en ángulo obtuso. Al saturar el espacio (derecha,  $K=6$ , el kissing number de  $d=2$ ) la separación colapsa a  $60^\circ$ . El mismo contraste se da en  $d=3$  —tetraedro a  $109,5^\circ$  frente a cuboctaedro a  $60^\circ$ — y en toda dimensión.

decreciente en  $K$  y está acotada en  $(\pi/2, \pi]$  — $180^\circ$  para  $K=2$ ,  $120^\circ$  para  $K=3$ , y tendiendo a  $90^\circ$  por arriba al crecer  $K$ , sin alcanzarlo nunca—. El régimen holgado vive, por tanto, enteramente en ángulos obtusos.

**Régimen saturado ( $K > d + 1$ ).** Cuando las direcciones superan  $d + 1$ , el simplex regular deja de existir: no caben tantas direcciones equiangulares en el espacio disponible. La separación óptima cae por debajo de  $90^\circ$  y la dimensión pasa a ser la restricción activa. El kissing number es el punto señalado de este régimen — $K = \tau(d)$  direcciones a exactamente  $60^\circ$  (proposición 1)—; densidades mayores producen ángulos aún menores.


**El modelo opera en régimen holgado.** Las dos intervenciones de este trabajo se sitúan con holgura en el primer régimen. Las cabezas de atención de un ViT-B/16 son  $H = 12$  direcciones y los prototipos de generador son  $K = M + 1$  direcciones —del orden de la decena—, ambos embebidos en  $d = 768$ . Dado que  $12 \ll 768$  y  $M + 1 \ll 768$ , la dimensión no es restrictiva. Conviene, sin embargo, distinguir dos variantes del régimen holgado según la naturaleza de las direcciones.

Los prototipos de generador (sección 4.3) son direcciones con orientación definida, y su separación óptima es la del simplex con signo,  $\arccos(-1/(M)) \approx 97^\circ$ . Las direcciones representativas de las cabezas (sección 4.2), en cambio, se definen como el primer vector singular de  $\mathbf{W}_O^{(h)}$ , un objeto *definido salvo signo*:  $\mathbf{u}_1$  y  $-\mathbf{u}_1$  representan la misma dirección. Para tales objetos el ángulo con signo no es una magnitud bien definida, y la separación que sí lo es —invariante al signo— vive en  $[0^\circ, 90^\circ]$  y vale, para el simplex de  $K$  vectores singulares,  $\theta_u^*(K) = \arccos(1/(K-1))$ . Para las  $H = 12$  cabezas,  $\theta_u^* = \arccos(1/11) \approx 84,8^\circ$  —el complementario de los  $95,2^\circ$  del simplex con signo—. Este es el valor objetivo  $\theta^*$  del regularizador de sección 4.2. El simplex de 12 vectores no admite, en efecto, ninguna orientación de signos que deje todos los cosenos mutuos negativos, por lo que el régimen sin signo no es una elección sino la única descripción coherente de la separación entre cabezas.


Ninguno de los dos casos toca los  $60^\circ$  del kissing number, que corresponden al régimen saturado y solo intervienen en la validación geométrica de sección 4.1, donde los códigos esféricos, generados con orientación definida, sí se miden con signo.

### 3.5. Conexión con neural collapse

El fenómeno de *neural collapse* [3] establece que, al final del entrenamiento, los vectores del clasificador de un modelo bien entrenado convergen a un marco equiangular ajustado: una configuración de separación angular máxima para  $K \leq d + 1$  clases. La red, por tanto, tiende espontáneamente hacia el código esférico. Las dos contribuciones de este trabajo parten de esa



**Figura 3:** Separación angular óptima del simplex con signo  $\theta_{\text{simplex}}(K) = \arccos(-1/(K-1))$  en función del número de direcciones  $K$ , válida en régimen holgado ( $K \leq d+1$ ). La curva decrece de forma monótona desde  $180^\circ$  y se aproxima asintóticamente a  $90^\circ$  sin alcanzarlo: en este régimen la separación óptima con signo es siempre obtusa. El punto azul marca el caso  $K=12$  ( $\approx 95,2^\circ$ ), aplicable a los prototipos de generador y a la validación de códigos. Las direcciones representativas de las cabezas de atención, en cambio, son vectores singulares sin signo: su separación óptima es la reflexión respecto a  $90^\circ$  de la curva,  $\arccos(1/(K-1))$ , que para  $K=12$  vale  $\approx 84,8^\circ$ .



**Figura 4:** Visión general. El Transformer de visión recibe dos intervenciones geométricas independientes: la contribución A regulariza las direcciones de las cabezas de atención dentro del encoder; la contribución B fija los prototipos de la cabeza de clasificación sobre un código esférico y habilita el rechazo de generadores no observados.

observación y la anticipan: en lugar de esperar a que la geometría emerja del proceso de relajación, se fija o se regulariza desde el inicio. En el régimen holgado en que opera el modelo (sección 3.4) esa disposición óptima es la del simplex regular; el marco equiangular del *neural collapse* y el código esférico de Riesz coinciden ahí numéricamente, observación que la sección 5 retoma al describir las ablaciones.

## 4. Método

### 4.1. Generación y validación de códigos esféricos

Dado un par  $(d, K)$ , el código  $\mathcal{C}$  se obtiene minimizando la energía de Riesz de ecuación (2) mediante descenso de gradiente proyectado sobre  $\mathbb{S}^{d-1}$ : en cada paso el gradiente se proyecta al espacio tangente a la hipersfera, se aplica un paso del optimizador Adam y las direcciones se renormalizan a norma unidad.<sup>1</sup> El procedimiento se resume en algoritmo 1.

<sup>1</sup>El optimizador adaptativo y la proyección tangente mejoran la convergencia frente al descenso estocástico ingenuo en  $d \gg 1$ , donde la energía de Riesz presenta un paisaje altamente no convexo: los gradientes se disparan con pares próximos en la inicialización aleatoria y, sin proyección tangente, la dinámica deriva por la componente radial.

---

**Algoritmo 1** Generación de un código esférico por descenso proyectado

---

**Require:** dimensión  $d$ , tamaño  $K$ , exponente  $s$ , pasos  $T$ , tasa inicial  $\eta_0$

- 1: inicializar  $\mathbf{u}_1, \dots, \mathbf{u}_K$  aleatorias en  $\mathbb{S}^{d-1}$
  - 2: inicializar el optimizador Adam con tasa  $\eta_0$
  - 3: inicializar el planificador *cosine annealing*
  - 4: **for**  $t = 1$  **hasta**  $T$  **do**
  - 5:   calcular  $\mathbf{g}_i = \nabla_{\mathbf{u}_i} E_s$  ▷ energía de repulsión
  - 6:    $\mathbf{g}_i^{\text{tan}} \leftarrow \mathbf{g}_i - \langle \mathbf{g}_i, \mathbf{u}_i \rangle \mathbf{u}_i$  ▷ proyección tangente
  - 7:    $\mathbf{u}_i \leftarrow$  paso de Adam sobre  $\mathbf{u}_i$  con  $\mathbf{g}_i^{\text{tan}}$
  - 8:    $\mathbf{u}_i \leftarrow \mathbf{u}_i / \|\mathbf{u}_i\|$  ▷ reproyección a la hiperesfera
  - 9:   actualizar la tasa con el planificador
  - 10: **end for**
  - 11: **return**  $\mathcal{C} = \{\mathbf{u}_1, \dots, \mathbf{u}_K\}$
- 

**Validación geométrica.** Antes de su uso en la red, el procedimiento se verifica en las dimensiones de kissing number conocido. Para  $(d, K) \in \{(2, 6), (3, 12), (4, 24), (8, 240), (24, 196560)\}$  se comprueba que el código recuperado satisface la cota del kissing number,  $\theta_{\min} \geq \pi/3$ , dentro de una tolerancia numérica. Para las dimensiones reales del modelo, sin solución exacta, se reporta la brecha respecto a las cotas superiores conocidas. Este control de sanidad precede a todo experimento con redes y no consume cómputo de GPU.

El descenso desde inicialización aleatoria no recupera, sin embargo, todas las configuraciones óptimas. Para  $(d, K)=(4, 24)$  se estanca de forma reproducible —verificado sobre seis semillas, cinco valores del exponente  $s$ , ruido térmico recocido e inicialización ortogonal— en un mínimo local con  $\theta_{\min} \approx 55,23^\circ$  y energía a un 0,007 por ciento del óptimo de  $D_4$ : la configuración  $D_4$  existe, pero su cuenca de atracción desde inicialización aleatoria es demasiado estrecha. Para  $(d, K)=(3, 12)$  el descenso converge al icosaedro regular, con  $\theta_{\min} \approx 63,43^\circ$ , en lugar del cuboctaedro a  $60^\circ$ ; el icosaedro es más estable bajo la energía de Riesz y satisface igualmente la cota del kissing ( $63,43^\circ \geq 60^\circ$ ). Por ello, para los pares con configuración óptima cerrada conocida — $D_4$  en  $d=4$ ,  $E_8$  en  $d=8$ , raíces del retículo de Leech en  $d=24$ — el protocolo arranca desde la configuración canónica y verifica que el descenso la conserva; para las dimensiones reales del modelo — $d=768$ ,  $K \in \{9, 12\}$ — la inicialización es aleatoria y la separación recuperada se reporta en la tabla 2.

## 4.2. Contribución A: atención angularmente diversa

Una capa de atención multi-cabeza con  $H$  cabezas dispone, para cada cabeza  $h$ , de una proyección de salida  $\mathbf{W}_O^{(h)} \in \mathbb{R}^{d \times d_h}$ . Se define la *dirección representativa* de la cabeza  $h$  como el primer vector singular izquierdo de  $\mathbf{W}_O^{(h)}$ :

$$\mathbf{r}_h = \mathbf{u}_1(\mathbf{W}_O^{(h)}), \quad \mathbf{u}_1 \text{ primer vector singular izquierdo}, \quad (5)$$

es decir, la dirección del subespacio de salida en que la cabeza deposita más energía. Esta elección no es arbitraria. Un estudio preliminar sobre el modelo afinado contrasta dos resúmenes posibles de la cabeza —el primer vector singular y la media normalizada de las columnas de  $\mathbf{W}_O^{(h)}$ — frente a una medida directa de diversidad funcional: la similitud entre los mapas de atención de cada par de cabezas. El primer vector singular correla con esa similitud funcional de forma apreciable (coeficiente agregado  $\approx 0,35$  sobre las doce capas), mientras que la media de columnas resulta prácticamente ortogonal al comportamiento de la cabeza (coeficiente  $\approx 0,02$ ).<sup>2</sup> La media de

---

<sup>2</sup>El primer vector singular está definido salvo signo; la comparación funcional y el regularizador de ecuación (6) emplean por ello el valor absoluto del producto escalar. La correlación, aunque clara en agregado, es parcial: la similitud entre mapas de atención está dominada por estructura común —atención al token de clase y a los parches vecinos— y el resumen no captura la totalidad de la diversidad funcional.

columnas mide la rotación del centroide de  $\mathbf{W}_O^{(h)}$ , una cantidad que un modelo puede alterar sin modificar sus mapas de atención; el primer vector singular capta, en cambio, el subespacio dominante de la proyección.

El conjunto  $\{\mathbf{r}_1, \dots, \mathbf{r}_H\}$  es un código esférico en  $\mathbb{R}^d$ . Dado que cada  $\mathbf{r}_h$  es un vector singular, definido salvo signo, la intervención añade a la función de pérdida un término que empuja ese conjunto hacia la separación angular máxima usando el valor absoluto del producto escalar:

$$\mathcal{R}_{\text{div}} = \sum_{h \neq h'} \max(0, |\langle \mathbf{r}_h, \mathbf{r}_{h'} \rangle| - \cos \theta^*), \quad (6)$$

donde  $\theta^* = \arccos(1/(H-1)) \approx 84,8^\circ$  es la separación óptima sin signo del simplex de  $H$  vectores singulares —el régimen sin signo descrito en sección 3.4—. El valor absoluto es necesario, no opcional: dos cabezas con vectores singulares casi antiparalelos son funcionalmente equivalentes, y el producto escalar con signo las leería erróneamente como bien separadas. Nótese que  $\cos \theta^* = 1/(H-1) > 0$ , de modo que la penalización se anula exactamente cuando las cabezas alcanzan el simplex sin signo; no es un umbral estructural. El término penaliza únicamente los pares por debajo del objetivo, no impone ninguna arquitectura nueva y no añade parámetros entrenables. Se contempla además una variante *dura*, en la que la proyección  $\mathbf{W}_O^{(h)}$  se somete tras cada paso a una rotación ortogonal que alinea su primer vector singular con la dirección asignada del código; la comparación entre la variante blanda de ecuación (6) y la dura forma parte de la ablación de sección 5.

### 4.3. Contribución B: prototipos de generador en conjunto abierto

Para la detección de medios sintéticos, el espacio de etiquetas de entrenamiento es  $\{\text{real}\} \cup \{g_1, \dots, g_M\}$ , con  $M$  generadores observados. La cabeza de clasificación asigna a cada etiqueta un prototipo unitario, y el conjunto de los  $M+1$  prototipos se fija sobre un código esférico  $\mathcal{C}$  generado por algoritmo 1. Dado el embedding [CLS] normalizado  $\hat{\mathbf{z}} = \mathbf{z}/\|\mathbf{z}\|$ , la puntuación de la clase  $k$  es el coseno  $s_k = \langle \hat{\mathbf{z}}, \mathbf{p}_k \rangle$ , y el entrenamiento emplea una pérdida de margen angular que atrae cada embedding hacia el prototipo de su etiqueta.

**Régimen de conjunto abierto.** La separación angular máxima entre prototipos deja, entre las celdas de decisión, regiones angulares no asignadas a ninguna etiqueta. Una imagen procedente de un generador no observado tiende a proyectarse en esas regiones en lugar de invadir la celda de la clase *real*. Se definen dos decisiones:

- **Real frente a sintético:** se compara la puntuación del prototipo *real* con la mayor puntuación entre los prototipos de generador; un margen a favor de los segundos denota imagen sintética.
- **Generador novel:** si  $\max_k s_k < \tau$  para un umbral  $\tau$ , la imagen se marca como procedente de un generador no catalogado, sin perder la decisión binaria anterior.


### 4.4. Objetivo de entrenamiento

La función de pérdida combina la tarea, el regularizador de diversidad y la clasificación por prototipos:

$$\mathcal{L} = \mathcal{L}_{\text{tarea}} + \lambda_A \mathcal{R}_{\text{div}} + \lambda_B \mathcal{L}_{\text{proto}}, \quad (7)$$

con pesos  $\lambda_A, \lambda_B \geq 0$ . En los experimentos de diversidad de atención sobre clasificación de imagen,  $\lambda_B = 0$  y  $\mathcal{L}_{\text{tarea}}$  es la entropía cruzada habitual. En los experimentos de detección,  $\mathcal{L}_{\text{proto}}$  asume el papel de clasificador y  $\mathcal{R}_{\text{div}}$  se mantiene como término opcional cuya aportación se cuantifica por ablación.





**Figura 5:** Geometría del rechazo en conjunto abierto. Los prototipos de las clases conocidas —*real* y generadores  $g_1 \dots g_4$ — ocupan direcciones de separación angular máxima; cada uno define un cono de aceptación (sombreado). Una imagen de un generador no observado tiende a proyectarse en el espacio angular no asignado y queda fuera de todos los conos, lo que habilita su rechazo sin contaminar la celda *real*.

## 5. Configuración experimental


Esta sección fija el protocolo; los resultados se incorporarán una vez ejecutados los experimentos.

**Conjuntos de datos.** Para la contribución A se emplea ImageNet-100, el subconjunto de 100 clases de ImageNet. Cien clases aportan riqueza angular suficiente para que la diversidad entre cabezas sea medible —mientras que diez la dejarían trivial—, y el fenómeno que la contribución A estudia es geométrico: depende de la relación entre el número de cabezas y la dimensión del modelo, no del número de clases, por lo que ImageNet-100 es representativo sin necesidad de la escala completa. Para la contribución B se emplea GenImage [15], que reúne imágenes reales y sintéticas de múltiples generadores, con el protocolo *leave-one-generator-out* descrito más abajo; DRCT [16] se reserva como conjunto de prueba externo, solo en inferencia, para medir transferencia.

**Protocolo *leave-one-generator-out*.** Para cada generador  $g$  de GenImage se entrena un detector con las imágenes de todos los generadores excepto  $g$ , y se evalúa la detección sobre  $g$ . La media sobre los  $M$  generadores excluidos cuantifica la generalización a arquitecturas no observadas, que es el objeto central de la contribución B.

**Arquitectura y entorno.** La columna vertebral es un Transformer de visión ViT-B/16. La contribución A parte de pesos preentrenados de ViT-B/16 (`timm`) y se afina sobre ImageNet con la pérdida  $\mathcal{L}$  de la ecuación (7); el regularizador  $\mathcal{R}_{\text{div}}$  actúa así como un aditivo geométrico sobre una columna ya competente, lo que aísla su efecto mejor que un entrenamiento conjunto desde cero —que con el cómputo disponible no alcanzaría una exactitud competitiva sin la receta completa de entrenamiento prolongado—. La contribución B parte igualmente de pesos preentrenados y se afina sobre GenImage a una resolución de 256 px, suficiente para preservar los artefactos de alta frecuencia de los generadores de difusión. El entorno de cómputo es una GPU NVIDIA RTX 5090 de 32 GB, que admite el ViT-B en una sola tarjeta sin recurrir a *gradient checkpointing*.

**Métricas.** La diversidad de atención se mide por la redundancia entre cabezas —similitud media entre las direcciones representativas— y por la entropía de los mapas de atención, además de la exactitud top-1. La detección se evalúa por exactitud binaria, AUROC y, en régimen de conjunto abierto, por la curva de rechazo de clasificación abierta (OSCR) y el AUROC de separación entre



**Figura 6:** Evolución de la separación angular mínima sin signo entre cabezas a lo largo del afinado. La base, sin regularizador, se estanca en torno a  $52^\circ$  —el techo del *neural collapse* espontáneo—. La blanda alcanza el óptimo  $\theta^* \approx 84,8^\circ$  hacia la época 6 y lo mantiene. La dura lo impone desde la primera época por reproyección.

clases conocidas y generadores no observados. La validación geométrica reporta la separación angular alcanzada frente al óptimo conocido.

**Ablaciones previstas.** (i) Variante blanda (ecuación (6)) frente a variante dura del código de atención. (ii) Prototipos fijos frente a prototipos inicializados con el código y posteriormente afinados. (iii) Código esférico frente a inicialización aleatoria; en las dimensiones del modelo ( $K \ll d$ ) el código de Riesz coincide numéricamente con el marco equiangular ajustado —ambos con  $\theta_{\min} = \arccos(-1/(K-1))$ —, por lo que esa tercera configuración no se reporta como condición separada. (iv) Sensibilidad a los pesos  $\lambda_A, \lambda_B$  y al exponente  $s$  de la energía de Riesz.

## 6. Resultados

Se reportan a continuación los resultados de la contribución A sobre ImageNet-100. Los de la validación geométrica (tabla 2) y la contribución B (tabla 3) se incorporarán tras su ejecución.

### 6.1. Contribución A: diversidad de atención

Las tres configuraciones —base sin regularizador, blanda con  $\lambda_A = 10^{-3}$  y dura por reproyección— se afinan 30 épocas sobre ImageNet-100 desde pesos preentrenados de ViT-B/16. La tabla 1 resume el estado final y la figura 6 la evolución por época.

**Tabla 1:** Contribución A sobre ImageNet-100, estado final tras 30 épocas.  $\theta_{\min}$  es la separación angular mínima sin signo entre cabezas;  $\bar{s}$  es la similitud funcional media entre mapas de atención.

| Configuración                    | $\theta_{\min} \uparrow$ | Redundancia $\downarrow$ | $\bar{s}$ func. $\downarrow$ | Top-1 $\uparrow$ |
|----------------------------------|--------------------------|--------------------------|------------------------------|------------------|
| Base ( $\lambda_A = 0$ )         | $52,0^\circ$             | 0,175                    | 0,693                        | 0,925            |
| Blanda ( $\lambda_A = 10^{-3}$ ) | $85,0^\circ$             | 0,034                    | 0,688                        | <b>0,926</b>     |
| Dura (reproyección)              | $84,8^\circ$             | 0,091                    | —                            | 0,877            |

Tres observaciones se desprenden de los datos.

Primero, el afinado por sí solo separa las cabezas, pero solo parcialmente: la base alcanza  $\theta_{\min} \approx 52^\circ$  y se estanca, muy por debajo del óptimo de  $84,8^\circ$ . Es el *neural collapse* esperado, con un techo que deja redundancia angular sin eliminar. Esto justifica que la intervención de la contribución A no sea redundante con el fenómeno espontáneo: el *collapse* no llega al óptimo.

Segundo, el regularizador blando alcanza el óptimo del simplex sin signo y reduce la redundancia a la mitad —de 0,175 a 0,034— sin coste en exactitud: el *top-1* de validación (0,926) iguala al de la base (0,925). La separación angular máxima entre cabezas es, por tanto, alcanzable sin penalización de rendimiento. La variante dura llega a la misma geometría pero degrada la exactitud casi cinco puntos (0,877), lo que denota que incentivar la separación mediante un término suave es preferible a imponerla por reproyección: el camino hacia la configuración óptima importa tanto como la configuración.

Tercero, y con la cautela debida, el efecto sobre la diversidad *funcional* de la atención es marginal. La similitud media entre mapas de atención apenas desciende —de 0,693 a 0,688— y la reducción se concentra casi enteramente en las capas tardías ( $-0,035$  en la última capa), mientras varias capas intermedias no mejoran o empeoran levemente. La separación angular de las direcciones de salida  $\mathbf{W}_O$  y la diversidad de comportamiento de la atención resultan, así, en gran medida *desacopladas*: reorganizar la geometría de  $\mathbf{W}_O$  hacia la máxima separación apenas altera a qué atiende cada cabeza. Este desacople es en sí mismo un hallazgo, y orienta la continuación natural del trabajo (sección 7).

## 6.2. Validación geométrica y contribución B

**Tabla 2:** Validación geométrica: separación angular recuperada frente a la cota del kissing number.

| Dimensión $d$ | Tamaño $K$ | Cota kissing ( $\theta_{\min} \geq$ ) | $\theta_{\min}$ recuperado | Conforme      |
|---------------|------------|---------------------------------------|----------------------------|---------------|
| 2             | 6          | $60^\circ$                            | [PENDIENTE: ]              | [PENDIENTE: ] |
| 3             | 12         | $60^\circ$                            | [PENDIENTE: ]              | [PENDIENTE: ] |
| 4             | 24         | $60^\circ$                            | [PENDIENTE: ]              | [PENDIENTE: ] |
| 8             | 240        | $60^\circ$                            | [PENDIENTE: ]              | [PENDIENTE: ] |
| 24            | 196560     | $60^\circ$                            | [PENDIENTE: ]              | [PENDIENTE: ] |

**Tabla 3:** Contribución B. Detección *leave-one-generator-out* sobre GenImage y transferencia a DRCT.

| Configuración                   | AUROC GenImage<br>(LOGO) $\uparrow$ | OSCR $\uparrow$ | AUROC<br>transferencia DRCT<br>$\uparrow$ |
|---------------------------------|-------------------------------------|-----------------|-------------------------------------------|
| Cabeza lineal base              | [PENDIENTE: ]                       | [PENDIENTE: ]   | [PENDIENTE: ]                             |
| + prototipos en código esférico | [PENDIENTE: ]                       | [PENDIENTE: ]   | [PENDIENTE: ]                             |
| + rechazo de conjunto abierto   | [PENDIENTE: ]                       | [PENDIENTE: ]   | [PENDIENTE: ]                             |

[PENDIENTE: figura de la validación geométrica —separación alcanzada por dimensión— y figura de las curvas OSCR por generador excluido.]

## 7. Discusión y limitaciones

El marco descansa sobre una distinción que conviene no difuminar. Las configuraciones de separación angular máxima solo se conocen de forma exacta en dimensiones contadas; en las dimensiones reales del modelo se trabaja con códigos casi óptimos, y la brecha respecto al óptimo teórico —cuantificada en tabla 2— denota el margen de imprecisión que el método arrastra. El kissing number es el caso ideal de referencia, no la herramienta universal.

Una segunda cuestión abierta es si las direcciones del código deben fijarse e inmovilizarse o solo inicializar un ajuste posterior. La primera opción ofrece el argumento teórico más limpio y el ahorro de parámetros; la segunda suele rendir algo más en exactitud. El trabajo no prejuzga la respuesta y la traslada a la ablación de sección 5.

Por último, la dirección representativa de una cabeza de atención —definida en ecuación (5) como primer vector singular de  $\mathbf{W}_O^{(h)}$ — es un resumen entre varios posibles. La elección se apoya en el estudio preliminar de sección 4.2, que la prefiere sobre la media de columnas por su correlación apreciablemente mayor con la similitud entre mapas de atención. Esa correlación es, sin embargo, parcial: el resumen captura una fracción de la diversidad funcional, no su totalidad, y su ventaja sobre la media de columnas no es uniforme entre capas. La cuantía con que la regularización de un resumen así definido se traduce en diversidad efectiva de la atención es, por tanto, una cuestión que la evaluación debe medir, no un hecho que el marco garantice.

Los resultados de la sección 6.1 resuelven esa cuestión en sentido matizado: la regularización alcanza el óptimo geométrico sin coste de exactitud, pero su efecto sobre la diversidad funcional de la atención es marginal. La interpretación más plausible es que la función de una cabeza —a qué atiende— no reside en la proyección de salida  $\mathbf{W}_O$ , que solo proyecta de vuelta el resultado, sino en el mecanismo que decide la atención,  $\text{softmax}(\mathbf{Q}\mathbf{K}^\top)$ . Separar las direcciones de  $\mathbf{W}_O$  reorganiza la salida sin tocar ese mecanismo, de donde el desacople observado. Inducir separación sobre el subespacio  $\mathbf{Q} \cdot \mathbf{K}$  —y el estudio de atribución por componente que lo precede— es la continuación natural de este trabajo; a diferencia de  $\mathbf{W}_O$ , ese subespacio define una forma bilineal y no un conjunto de direcciones, por lo que exige extender el marco más allá de los códigos esféricos.

## 8. Conclusión

El trabajo encuadra dos problemas en apariencia distantes —la redundancia de la atención multi-cabeza y la fragilidad de los detectores de medios sintéticos frente a generadores no observados— como un único problema geométrico: la disposición de un conjunto de direcciones sobre la hiperesfera. Sobre esa base propone un regularizador de atención angularmente diversa y una cabeza de prototipos por generador anclada en un código esférico, ambos sin coste arquitectónico y con el espacio angular no asignado como margen explícito para lo no observado. La validación geométrica frente al kissing number y la evaluación con protocolo *leave-one-generator-out* quedan especificadas; su ejecución determinará el alcance empírico de la propuesta.

## Disponibilidad de código y datos

El código de generación de códigos esféricos, de las dos intervenciones y de los protocolos de evaluación se publicará en un repositorio abierto junto con la versión revisada de este preprint. **[PENDIENTE: enlace al repositorio y DOI del archivo de pesos]**

## Referencias

- [1] J. H. Conway y N. J. A. Sloane. *Sphere Packings, Lattices and Groups*. Springer, 3.<sup>a</sup> ed., 1999.

- [2] E. B. Saff y A. B. J. Kuijlaars. Distributing many points on a sphere. *The Mathematical Intelligencer*, 19(1):5–11, 1997.
- [3] V. Pappayan, X. Y. Han y D. L. Donoho. Prevalence of neural collapse during the terminal phase of deep learning training. *Proceedings of the National Academy of Sciences*, 117(40):24652–24663, 2020.
- [4] Z. Zhu, T. Ding, J. Zhou, X. Li, C. You, J. Sulam y Q. Qu. A geometric analysis of neural collapse with unconstrained features. *Advances in Neural Information Processing Systems* (NeurIPS), 2021.
- [5] F. Pernici, M. Bruni, C. Baecchi y A. Del Bimbo. Regular polytope networks. *IEEE Transactions on Neural Networks and Learning Systems*, 2021.
- [6] W. Liu, Y. Wen, Z. Yu, M. Li, B. Raj y L. Song. SphereFace: deep hypersphere embedding for face recognition. *IEEE Conference on Computer Vision and Pattern Recognition* (CVPR), 2017.
- [7] H. Wang, Y. Wang, Z. Zhou, X. Ji, D. Gong, J. Zhou, Z. Li y W. Liu. CosFace: large margin cosine loss for deep face recognition. *IEEE Conference on Computer Vision and Pattern Recognition* (CVPR), 2018.
- [8] J. Deng, J. Guo, N. Xue y S. Zafeiriou. ArcFace: additive angular margin loss for deep face recognition. *IEEE Conference on Computer Vision and Pattern Recognition* (CVPR), 2019.
- [9] P. Michel, O. Levy y G. Neubig. Are sixteen heads really better than one? *Advances in Neural Information Processing Systems* (NeurIPS), 2019.
- [10] E. Voita, D. Talbot, F. Moiseev, R. Sennrich y I. Titov. Analyzing multi-head self-attention: specialized heads do the heavy lifting, the rest can be pruned. *Annual Meeting of the Association for Computational Linguistics* (ACL), 2019.
- [11] A. Dosovitskiy, L. Beyer, A. Kolesnikov *et al.* An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations* (ICLR), 2021.
- [12] A. Vaswani, N. Shazeer, N. Parmar *et al.* Attention is all you need. *Advances in Neural Information Processing Systems* (NeurIPS), 2017.
- [13] S.-Y. Wang, O. Wang, R. Zhang, A. Owens y A. A. Efros. CNN-generated images are surprisingly easy to spot... for now. *IEEE Conference on Computer Vision and Pattern Recognition* (CVPR), 2020.
- [14] R. Corvi, D. Cozzolino, G. Zingarini, G. Poggi, K. Nagano y L. Verdoliva. On the detection of synthetic images generated by diffusion models. *IEEE International Conference on Acoustics, Speech and Signal Processing* (ICASSP), 2023.
- [15] M. Zhu, H. Chen, Q. Yan *et al.* GenImage: a million-scale benchmark for detecting AI-generated images. *Advances in Neural Information Processing Systems* (NeurIPS), Datasets and Benchmarks, 2023.
- [16] B. Chen, J. Zeng, J. Yang y R. Yang. DRCT: diffusion reconstruction contrastive training for synthetic image detection. *International Conference on Machine Learning* (ICML), 2024.